联接 Agent 记忆系统技术报告：基于 CoALA 的长短期分层管理、经验提炼与混合检索注入

—— 短期工作记忆与三类长期记忆（语义记忆、情景记忆、程序化/经验记忆）的架构与工程设计

对应代码仓：`memory_system` · 业务域：6G NGC · 2026 年 11 月

摘要：围绕 6G NGC 网络体验保障中网元结构化保障单据与用户自然语言对话交织的数据特征，参考普林斯顿大学 `CoALA`（*Cognitive Architectures for Language Agents*, arXiv:2309.02427）认知架构，介绍联接 Agent 记忆系统的**“短期记忆与长期记忆”两级分层与四类记忆模块设计**。其中，**短期记忆（Short-Term Memory）**为当前会话活跃的**工作记忆（Working Memory）**，负责维护本轮输入、多轮澄清中间槽位以及当轮从长期记忆检索读入的活跃上下文；**长期记忆（Long-Term Memory）**跨会话持久存储在外部数据库中，细分为三类：① **语义记忆（Semantic Memory，事实记忆—语义层）**，记录跨周期长期稳定的周期作息习惯、分场景常驻偏好、默认档位、服务与应用映射及个性化表述映射；② **情景记忆（Episodic Memory，事实记忆—情景层）**，原样保存每次历史保障单据记录与网元实际运行结果（`SerialNo`、`AppQuality=good/bad`），以及绑定具体时间窗的差旅/赛事事件、带有效期 `TTL` 的临时偏好与显式纠正记录；③ **程序化记忆 / 经验记忆（Procedural / Experiential Memory）**，记录从短期工作记忆慢路径澄清与长期情景记忆正反单据对比中提炼的因果调参规则、多单消歧流程（Workflows）与交互策略。

章节概览：长短期分层与分表 → 演变萃取 → 经验提炼 → 混合检索 → 工作记忆拼装与写回 → 样本与评测

第 1 章 · 记忆要记什么：CoALA 四类记忆分工、长短期分层管理与分表存储结构：说明单层向量库混存的四类问题，基于 `CoALA` 定义短期工作记忆与三类长期记忆（语义、情景、程序化/经验）的双向读写闭环（`Retrieval` 读入与 `Learning` 写回）、六维对比表、“记与不记”五条标准、8 个决策环节分解表及 SQLite 分表存储结构。

第 2 章 · 记忆从短期到长期的演变机制与萃取更新规则：拆解北邮 `MemoryOS (STM→MTM→LPM)` 与 `Mem0`、`Zep/Graphiti`、`Letta/MemGPT`、上海 AI Lab `MemOS`、`MemoryBank/A-MEM` 5 套架构，归纳从短期工作记忆经中期候选池升格为三类长期记忆的四步演变逻辑，给出单据过滤、候选池晋升参数与保持率衰减算式。

第 3 章 · 程序化 / 经验记忆要学到什么：从“多轮澄清/理解失败”到“快速闭环”：对比 5 篇经验学习代表论文，总结程序化/经验记忆构建的五个方法论重点，说明如何串联情景记忆中的异常单据、工作记忆中的澄清对话与调整后正常单据提炼规则，并展示落盘 JSON 示例。

第 4 章 · 三类长期记忆的混合检索流程：阐述长句否定子句分离与滑动窗口切分，语义记忆、情景记忆、程序化（经验）记忆三类长期记忆的并行检索与二阶段关联表补全，以及综合排序算式与多记忆联合检索优先级。

第 5 章 · 短期工作记忆的上下文拼装注入与长短期写回闭环：说明如何将检索出的长期记忆过滤、预计算时间偏移并拼装加载进短期工作记忆（Working Memory），以及单据执行完毕后如何从工作记忆向三类长期记忆写回与更新。

第 6 章 · 完整样本示例与评测指标：通过主播用户 `USER_001` 跨周期业务样本串联短期工作记忆与三类长期记忆的协同全流程，并汇总三阶段评测指标。

第 7 章 · 总结与工程检查项：汇总表字段边界、无效单据过滤、经验排除范围与长短期双向同步的四项工程核对要求。

目 录

1 记忆要记什么：CoALA 四类记忆分工、长短期分层管理与分表存储结构 **01**

1.1 单层向量库混存的问题与 CoALA“一短期 + 三长期”记忆分工 01

1.2 短期工作记忆与三类长期记忆的分层管理及六维横向对比 02

1.3 按 8 个决策环节分解要记的内容与每条记忆必备元信息 03

1.4 整体处理流程与三类长期记忆 SQLite 分表存储结构设计 04

1.5 本章小结 05

2 记忆从短期到长期的演变机制与萃取更新规则 **05**

2.1 北邮 MemoryOS（arXiv:2506.06326）的三级演变机制：STM → MTM → LPM 05

2.2 经典与主流 5 套 Agent 记忆系统横向对比 06

2.3 对联接 Agent 的思路启发：从短期工作记忆到三类长期记忆的四步演变逻辑 07

2.4 单据预处理、候选池累积参数与记忆保持率衰减计算 08

2.5 本章小结与拓展阅读 09

3 程序化 / 经验记忆要学到什么：从“多轮澄清/理解失败”到“快速闭环” **09**

3.1 经验学习领域的 5 篇代表性论文与核心工作 09

3.2 程序化 / 经验记忆要抓住的五个重点与三种经验类型 10

3.3 从长周期记录中定位慢路径源头与正反单据对比提炼 11
3.4 短期工作记忆与三类长期记忆的结构化数据示例 11
3.5 本章小结与拓展阅读 12
4 三类长期记忆的混合检索流程 **12**
4.1 滑动窗口切分与否定子句处理 12
4.2 语义、情景、程序化（经验）三类长期记忆并行检索与二阶段关联补全 13
4.3 综合排序评分与多记忆联合检索 13
4.4 本章小结 14
5 短期工作记忆的上下文拼装注入与长短期写回闭环 **14**
5.1 短期工作记忆的容量控制与长期检索结果结构化拼装 14
5.2 工作记忆上下文文本示例与向三类长期记忆的写回闭环 15
5.3 本章小结 15
6 完整样本示例与评测指标 **16**
6.1 跨周期业务样本串联示例（USER_001） 16
6.2 萃取、检索与注入三阶段评测指标 16
6.3 本章小结 17
7 总结与工程检查项 **17**

1 记忆要记什么：CoALA 四类记忆分工、长短期分层管理与分表存储结构

1.1 单层向量库混存的问题与 CoALA“一短期 + 三长期”记忆分工

在 6G NGC 网络体验保障场景中，系统输入同时包含网元结构化保障单据及网络实际运行结果（记录小区标识 `CGI`、地点、起止时间、保障规格及事后体验质量 `AppQuality=good/bad`）与用户多轮自然语言对话。如果把当前对话上下文、用户长期习惯和历史单据直接混存在同一个无分层的文本向量库中，会出现以下四个问题：

1. **用户的口语叫法与单次外出地点混在一起**：用户的口语表达（如“小破站开播”）如果与某次外出场馆的地点、时长存在同一条文本中，回到常驻地点再次使用该叫法时，容易误带出上次外出场馆的参数。
2. **短期临时改动覆盖平时的固定习惯**：用户因异地出差、月末流量紧张或某天暴雨临时将画质降为 `720p`，如果不与长期常驻习惯分开存储，会直接覆盖平时稳定的 `1080p / 4K` 默认配置。
3. **同一地点的正常单据与卡顿单据难以区分**：同一场馆如果先后存在运行顺畅的单据（`good`）与发生卡顿的单据（`bad`），纯文本向量相似度几乎一致，用户说“照上次没卡那笔办”时很容易选错记录。
4. **多轮沟通确定的参数调整无法直接用于同类新场景**：首次在大型场馆遇到拥塞并经多轮沟通确定提前开启上行切片后，如果只保存当次单据而不提炼通用规则，下次换到其他体育场时仍需重复追问；反过来如果不做适用业务限制，在场馆内看视频点播时又会误触发上行切片。

参考普林斯顿大学提出的 `CoALA`（*Cognitive Architectures for Language Agents*, arXiv:2309.02427）认知架构，系统首先按生命周期将记忆划分为**短期记忆（Short-Term Memory）**与**长期记忆（Long-Term Memory）**两级，其中**只有工作记忆属于短期记忆，而语义记忆、情景记忆、程序化（经验）记忆三者均属于跨会话持久保存的长期记忆**：

- **短期记忆（Short-Term Memory）—— 1. 工作记忆（Working Memory，解决“当前会话正在处理什么、中间槽位与当轮上下文是什么”）：**仅在当前单次会话或当前决策周期内活跃的瞬时上下文草稿板（Scratchpad），也是大模型推理核心唯一直接读取的内存区域。工作记忆负责维护：① 本轮用户输入与当前任务目标；② 多轮澄清交互中的活跃槽位状态（已确认槽位、待澄清冲突项、中途改口修正状态、旁人插话过滤状态）与定长对话页链（`FIFO` 缓冲）；③ 当轮通过检索（`Retrieval`）从三类长期记忆中召回并过滤拼装后的活跃记忆上下文。会话结束后，工作记忆中的有效信息通过学习写回（`Learning`）沉淀至长期记忆，自身随会话终结而释放。
- **长期记忆 ①（Long-Term）—— 2. 语义记忆（Semantic Memory，事实记忆—语义层，解决“用户平时稳定要什么、口语怎么对应标准字段”）：**脱离单次具体事件背景、跨周期长期稳定的客观事实与常驻偏好（*What is true*）。记录用户的静态身份与套餐权益、长期周期作息习惯（`periodic_preference`，如工作日午间固定直播时段）、分场景常驻网络偏好与体验三档底线（`scene_preference`，如常驻基地与高铁移动会议）、服务与应用映射（`service_to_app`）、个性化表述映射（`expression`，如“小破站开播”对应 `bilibili:openlive`）以及基础默认档位（`preferred_value`）。隐式行为需经中期候选池跨周期累积达标（满足跨度 W_{span} 与得分阈值 θ_{long}）后晋升生效；档位升级时采用双时间戳接替（旧记录标为 `superseded`）；长期未触发按遗忘曲线自然衰减。
- **长期记忆 ②（Long-Term）—— 3. 情景记忆（Episodic Memory，事实记忆—情景层，解决“过去具体发生过哪些单据与事件、当前处于什么阶段性情境”）：**绑定具体时间戳与时空背景的过往具体事件记录、历史单据流水与阶段性状态（*What happened & when*）。包含两部分内容：① **历史保障单据记录与网元实际运行结果（`episodic_order_record`）**：原样保存过去每次实际执行

过的保障单据（单号 `SerialNo`、执行日期、地点、`CGI`、起止时间、保障参数）与实际运行结果（`AppQuality=good/bad`），**按单号逐笔原样追加、不跨单合并为平均习惯、不随时间衰减**，用于按时间、地点或运行结果好坏精确回溯特定历史单据（如“照上周六在奥体没卡那次来”）或叠加改期平移；② **阶段性事件窗与带有效期 `TTL` 的临时偏好（`episodic_event_preference`）**：记录异地差旅/赛事事件窗、短期临时降档/省流偏好（带到期时间 `TTL`）、历史主动诉求（`active/closed`）与当面显式纠正记录，在有效期内局部覆盖常驻语义记忆，到期后自动标为 `expired` 失效回退。

- **长期记忆 ③（Long-Term）—— 4. 程序化记忆 / 经验记忆（Procedural / Experiential Memory，解决“遇到特定无线场景或歧义情况时，系统该怎么调参与处置”）：**关于“如何执行动作、流程与调参规则”的显式程序化知识（*How to do*，对应 `CoALA` 中的显式程序化记忆 Explicit Procedural Memory）。记录从短期工作记忆的慢路径多轮澄清对话以及长期情景记忆的正反单据（`bad` 与 `good`）对比中提炼的**网络问题因果调参规则**（`触发条件 Condition → 问题根因 Cause → 参数调整规则 Action → 预期结果 Outcome`）、**同地多单消歧处理流程（Workflows）**与**交互免打扰策略**，显式绑定适用与不适用范围（`scope.exclude`），供后续同类场景直接召回复用。

短期记忆（工作记忆）与三类长期记忆（语义、情景、程序化/经验）的分层管理原则

1. **读写隔离（Retrieval & Learning 双通道）**：大模型在单步推理时只直接读取**短期工作记忆（Working Memory）**；长期语义记忆、长期情景记忆与长期程序化（经验）记忆存储在外部 SQLite + 向量数据库中，必须通过**混合检索**（`Retrieval`）按需筛选并拼装加载进短期工作记忆后才能参与当轮推理；会话与单据执行产生的反馈则通过**异步学习**（`Learning`）从短期工作记忆写回或经中期候选池晋升至三类长期记忆。

2. **三类长期记忆分表独立更新**：**长期语义记忆**靠跨周期重复累积达标晋升并按双时间戳新旧更替；**长期情景记忆**中的历史单据按单原样追加、不合并、不衰减，阶段性临时偏好按 `TTL` 到期失效；**长期程序化（经验）记忆**靠后续单据的实际运行结果（`AppQuality` 好坏）持续升降置信度。分表存储、独立更新，才能避免单次临时变动或单笔异常单据污染常驻语义习惯。

1.2 短期工作记忆与三类长期记忆的分层管理及六维横向对比

表 1.1 从生命周期层级、回答的核心问题、网络保障具体内容、归属范围、数据来源、更新机制与使用方式对**短期工作记忆**及**三类长期记忆（语义记忆、情景记忆、程序化/经验记忆）**进行横向对比。

表 1.1：基于 CoALA 的短期工作记忆与三类长期记忆（语义、情景、程序化/经验）横向对比表

对比维度	短期记忆： 1. 工作记忆 （Working Memory）	长期记忆 ①： 2. 语义记忆 （Semantic Memory）	长期记忆 ②： 3. 情景记忆 （Episodic Memory）	长期记忆 ③： 4. 程序化 / 经验记忆 （Procedural / Experiential）
1. 生命周期与存储介质	**短期（Short-Term）**：仅在当前单次会话存活；存于内存与活跃提示词上下文窗口	**长期（Long-Term）**：跨会话持久保存；存于外部结构化与短语向量数据库	**长期（Long-Term）**：跨会话持久保存；历史单据永久追加，阶段性偏好带 `TTL`	**长期（Long-Term）**：跨会话持久保存；存于外部显式规则与流程库
2. 回答什么问题	当前这轮对话正在办什么、哪些槽位已确认、刚检索出什么上下文	用户是谁、平时常驻默认要什么、口语怎么对应标准字段（*What is true*）	过去具体办过哪些单据且结果如何、当前处于什么差旅/临时阶段（*What happened*）	遇到这类无线场景或歧义情况，系统该怎么调参与处置（*How to do*）
3. 网络保障记什么	本轮用户输入；多轮澄清/改口中的中间槽位状态；`FIFO` 对话页链；当轮检索拼装的活跃记忆块	长期周期作息习惯；分场景常驻偏好与体验三档底线；基础默认档位；服务与应用映射；个性化表述映射	① **历史保障单据记录**（单号、日期、地点、参数、运行结果 `good/bad`）；② 差旅事件窗、短期临时偏好（`TTL`）、诉求与纠正记录	“场景与业务 → 根因 → 参数调整规则 → 结果”的因果规则；同地多单消歧流程（Workflows）；交互免打扰策略与 `scope`
4. 主要来源	当前会话实时用户输入 + 当轮从三类长期记忆检索读入（`Retrieval`）的结果	从工作记忆滑入中期候选池跨周期重复归纳 + 对话中的长期显式声明	网元结构化保障单据与实际运行结果回写 + 对话中声明的差旅/临时变动与纠偏	工作记忆中的慢路径多轮澄清轨迹 + 情景记忆中同场景正反单据（`bad/good`）对比
5. 怎么更新	每轮交互实时刷新槽位状态（支持中途改口覆写与旁白过滤）；会话终结后写回长期库并清空释放	候选池累积达标后晋升（`candidate → active`）；新档位替代旧档位（`superseded`）；长期未用按保持率衰减	历史单据按单号逐笔原样追加，**不跨单合并、不随时间衰减**；短期临时偏好按 `TTL` 到期自动转为 `expired`	同类规则增量合并；按后续单据实际运行结果升降置信度，连续异常则降级停用
6. 怎么被使用	直接作为大模型当前决策步的输入上下文，支撑槽位核对与指令生成	被检索读入工作记忆，将口语转为标准字段并自动补全用户省略的常驻应用、时段与默认档位	被检索读入工作记忆，在有效期内用临时偏好局部覆盖常驻档位，或按时间/地点/体验好坏精确锁定历史单据	被检索读入工作记忆，在适用边界内自动提供场馆提前预热/切片调整参数及多单消歧流程

决定一条信息是否从短期工作记忆写入长期记忆的五条过滤标准见表 1.2。

表 1.2：从短期工作记忆写入长期记忆的五条判断标准（写入长期库与仅留工作记忆）

判断标准	应当写入三类长期记忆库的内容	仅在短期工作记忆处理或直接丢弃的内容
1. 以后跨会话会再用	周期作息习惯、常用参数档位、个人口语映射、历史有效保障单据、场馆排障与预热经验规则	一次性日常寒暄闲聊、通用通信常识科普问答、未授权执行的假设性试探咨询（仅在当前工作记忆应答后释放）

判断标准	应当写入三类长期记忆库的内容	仅在短期工作记忆处理或直接丢弃的内容
2. 当下实时接口拿不到	用户个人历史偏好、过往单据实际运行结果好坏、过去约定过的多单消歧处理方式	能通过接口实时查询的瞬态信息（当前基站实时负载、当前套餐剩余流量）直接查接口读入工作记忆，不存长期记忆
3. 有足够支撑证据	跨周期多次重复出现的稳定行为（满足最小频次阈值 N_{min} 与得分阈值 θ_{long}），或用户明确要求长期记住的内容	只出现 1~2 次的偶发行为先停留在中期候选池（`candidate`），未达标前不升格为长期语义记忆默认参数
4. 时效与作用域明确	长期稳定习惯入**长期语义记忆**；带明确有效期 `TTL` 的临时偏好与历史单据入**长期情景记忆**	单次临时变动（如“今天下雨降 720p”）严禁写入长期语义记忆覆盖常驻习惯；已被替代的旧值标为 `superseded` 归档备查
5. 与保障业务相关	直接影响业务类型、时间、地点、保障参数与交互方式的信息	与网络保障无关的个人敏感隐私；网元单据中的背景短时单据（不足 $T_{\min}$）、断流碎片、中途取消的无效单据（入长期情景库前先清洗剔除）

1.3 按 8 个决策环节分解要记的内容与每条记忆必备元信息

联接 Agent 生成保障工单的 **8 个决策环节**及对应的长短期记忆分工见图 1.1 与表 1.3。

```
flowchart TB
  subgraph CoALATiers["一、CoALA 短期工作记忆与三类长期记忆的分层管理（Retrieval 读入 + Learning 写回）"]
    direction LR
    T_wm["【短期记忆】1. 工作记忆 (Working)
当前会话活跃上下文草稿板
本轮输入 + 多轮澄清中间槽位
+ 当轮检索读入的活跃长期记忆"] ~~~ T_sem["【长期记忆 ①】2. 语义记忆 (Semantic)
常驻周期习惯 / 场景偏好 / 默认档位
服务→应用映射 / 个性化表述映射
更新：候选池达标晋升 · 新代旧 · 衰减"] ~~~ T_epi["【长期记忆 ②】3. 情景记忆 (Episodic)
历史保障单据记录 + 实际运行结果(good/bad)
+ 差旅事件窗 / 短期临时偏好(TTL)
更新：单据逐笔原样追加 · 临时项按TTL失效"] ~~~ T_proc["【长期记忆 ③】4. 程序化/经验记忆
场景与业务→根因→调整规则→结果
因果调参规则 / 消歧流程(Workflows)
更新：慢路径对比提炼 · 按运行结果升降级"]
  end

  subgraph StepsRow1["二、前 4 个决策环节：从三类长期记忆检索读入短期工作记忆（Retrieval）"]
    direction LR
    S1["环节 1：听懂用户话
查【长期-语义】口语与应用映射"] --> S2["环节 2：补全常驻缺省参数
查【长期-语义】周期习惯与默认档"]
    S2 --> S3["环节 3：定位历史单据指代
查【长期-情景】历史单据记录与运行结果"]
    S3 --> S4["环节 4：判断当次临时例外
查【长期-情景】临时偏好(TTL)与事件窗"]
  end

  subgraph StepsRow2["三、后 4 个决策环节：工作记忆内调参汇总与事后向长期记忆写回（Learning）"]
    direction LR
    S5["环节 5：预判风险调参
查【长期-程序化/经验】场馆预热规则"] --> S6["环节 6：确定降级底线
查【长期-语义】场景体验三档边界"]
    S6 --> S7["环节 7：工作记忆汇总与消歧
查【长期-程序化/经验】消歧流程与交互策略"]
    S7 --> S8["环节 8：事后运行结果写回
从【工作记忆】追加【情景单据】并更新【经验】"]
  end

  CoALATiers ==> StepsRow1
  StepsRow1 ==> StepsRow2
```

图 1.1：基于 CoALA 的“短期工作记忆 + 三类长期记忆”分层管理原理与八步保障决策映射架构图。

第一排展示短期工作记忆（Working Memory）与三类长期记忆（语义记忆、情景记忆、程序化/经验记忆）的职责边界；第二排展示环节 1–4 如何将长期语义与长期情景记忆检索读入工作记忆；第三排展示环节 5–8 如何结合长期程序化/经验记忆完成决策并在事后写回长期库。

表 1.3：按生成保障工单的 8 个决策环节分解所需记忆内容与长短期归属

下游决策环节	需要读取或维护的核心记忆内容	CoALA 记忆归属	网络保障具体实例	产生它的故事线因子
1. 听懂用户说的话	个性化表述映射（`expression`）、服务与应用映射（`service_to_app`）	长期 — 语义记忆	“小破站开播” = `bilibili:openlive`；“开会”默认指腾讯会议	口语表达习惯、显式声明
2. 补全常驻缺省参数	周期作息习惯（`periodic_preference`）、场景常驻偏好（`scene_preference`）与基础默认档位（`preferred_value`）	长期 — 语义记忆	“照常开播” = 工作日午间 12:30~14:00、滨江基地、抖音开直播、4K / 90min	时间规律、活动空间、业务时长、偏好演化
3. 找到用户指的那次	历史保障单据记录与实际运行结果（`episodic_order_record`：计划值、实测值、`good/bad`）	长期 — 情景记忆	“按上周六在奥体没卡那次来” → 排除拥塞单 `NE-05`，锁定顺畅单 `NE-09`	历史单据指代、同地多单冲突、运行结果状态
4. 判断这次是否特殊	差旅/赛事事件窗、带有效期 `TTL` 的短期临时偏好、当面纠正记录（`episodic_event_preference`）	长期 — 情景记忆	“今天暴雨先降 720p”或“出差三天省流模式”仅在有效期内局部生效	短期支线事件窗、有效期 `TTL`、单次豁免声明
5. 预判风险并调参	“场景与业务 → 问题根因 → 参数调整规则”的因果经验（`procedural_experience`）	长期 — 程序化/经验记忆	人流聚集场馆推流开场易拥塞 → 提前 20~30 分钟开启专网切片预热	基站拥塞事件、慢路径澄清与正反单据对比
6. 确定参数妥协边界	分场景体验三档（偏好档、可接受降级档、不可接受底线）与互斥 KQI 权重	长期 — 语义记忆	高速大巴移动会议画质在弱网下可降到 720p，但跨区切换绝不能断流	降级容忍度、互斥指标权重、无线覆盖条件
7. 跨轮槽位跟踪与消歧	当前会话已确认槽位、中途改口覆写状态（工作记忆）+ 多单冲突消歧流程（程序化/经验记忆）	短期 — 工作记忆 + 长期 — 程序化/经验	用户在第 2 轮改口“保满 3 小时到 22:30”时，工作记忆更新时长并保持第 1 轮已确认的 4K 画质不丢失	多轮澄清交互、中途改口、同伴旁白干扰
8. 执行后写回长期记忆	将当次完结单据与运行结果（`AppQuality=good/bad`）从工作记忆写回长期情景记忆，并更新经验置信度	短期 — 工作记忆 → 长期 — 情景/经验	按经验提前预热后单据运行结果 `AppQuality=good` → 新单据追加进情景记忆，经验成功计数 +1	实际运行结果状态、用户后续反馈

每条落入三类长期记忆库的条目携带五项基础治理元信息：① **来源与证据指针**（来自网元单据还是对话，挂载对应的 `SerialNo` 或会话轮次 ID）；② **状态标签**（`candidate` 候选 / `active` 生效 / `reinforced` 稳固 / `superseded` 已被替代 / `expired` 已过期）；③ **适用范围**（全局、限定场景或地点、限定时段、仅本次）；④ **时效窗口**（生效时间 \(t_{\text{valid}}\)、失效时间 \(t_{\text{invalid}}\) 或 `TTL` 到期时间戳）；⑤ **置信度**（随重复次数与运行结果验证动态升降）。

1.4 整体处理流程与三类长期记忆 SQLite 分表存储结构设计

记忆系统的运行过程围绕**“短期工作记忆 ↔ 三类长期记忆”**展开，分为**短期感知与清洗、候选萃取与写入长期分表、三类长期记忆混合检索、读入短期工作记忆拼装与事后写回**四个阶段，如图 1.2 所示。

```
flowchart LR
    S1["短期工作记忆感知
当前会话槽位 · 单据与对话流"] --> S2["Learning 写回与晋升
写入语义 / 情景 / 程序化(经验)分表"]
    S2 --> S3["Retrieval 并行混合检索
三类长期记忆短语向量 + 二阶段关联"]
    S3 --> S4["拼装读入短期工作记忆
注入活跃上下文 · 事后运行结果闭环"]
```

图 1.2：短期工作记忆与三类长期记忆之间的双向读写（Learning 写回与 Retrieval 读入）整体流程

短期工作记忆维护当前会话状态；完结后的单据与对话经预处理后分别写入或晋升至语义记忆、情景记忆、程序化（经验）记忆三类长期分表；新一轮会话时再通过混合检索将相关长期记忆读入短期工作记忆。

在持久化存储层（`memory.db`）中，**短期工作记忆**作为会话期内存状态结构（`WorkingMemoryState`）驻留内存；而跨会话持久保存的**三类长期记忆（语义记忆、情景记忆、程序化/经验记忆）**存储在 SQLite 与向量索引表中，每条长期记忆同时包含**结构化槽位列**（用于 SQL 精确条件过滤）和**受长度上限 \(L_{\text{phrase}}\) 约束的短语向量列**（`phrase_text` 及其稠密向量）。具体存储表划分与字段边界见表 1.4。

表 1.4：短期工作记忆内存结构与三类长期记忆（8 个存储子项）的职责、主键及字段边界

层级与记忆类别	存储子项（`category`）	唯一主键（`memory_key`）	结构化槽位列与内容限制	短语向量文本（`phrase_text`）与更新方式
【短期记忆】 **1. 工作记忆** （Working Memory）	0. 会话活跃草稿板 `working_session_state` （驻留内存）	`session_id | turn_id`	当前轮输入、已确认 7 槽位字典、待澄清冲突项、`FIFO` 近期对话页链、当轮检索读入的 Top-\(k\) 长期记忆引用	不建持久化向量索引；每轮实时更新槽位，会话终结后触发 `Learning` 写回长期库并释放
【长期记忆 ①】 **2. 语义记忆** （Semantic Memory）	1. 个性化表述映射 `expression`	`alias` （如 `"小破站开播"`）	`alias_col`，`target_col`（如 `"bilibili:openlive"`）；不存时间窗与时长	用户口语表达原文；明确声明即生效，新声明覆盖旧值
	2. 业务默认应用 `service_to_app`	`business` （如 `"openlive"`）	`biz_col` → `app_col`（如 `"openlive"` 对应 `"douyin"`）；不存画质与地点	纯业务名称；明确指定或累计达到阈值 \(\theta_{\text{app}}\) 后生效
	3. 基础默认档位 `preferred_value`	`app | business` （如 `"douyin|openlive"`）	`app_col`，`biz_col` 及默认分辨率、时延、时长、套餐档位；不存具体地点与时段	`"{应用} {业务}"`；档位升级时将旧记录记下 \(t_{\text{invalid}}\) 并标为 `superseded`
	4. 固定时段习惯 `periodic_preference`	`time_window | app:biz`	`time_window_col`，周期类型，`app_col`，`biz_col`，`scene_col`；仅存时段与业务对应关系，不存画质	时段名称（如 `"午间例行直播"`）；跨期满足 \(W_{\text{span}}\) 且累计达 \(\theta_{\text{long}}\) 后生效
	5. 空间场景常驻偏好 `scene_preference`	`scene | app | business`	`scene_col`，`app_col`，`biz_col` 及该场景特定参数与体验三档降级底线；不存固定时间窗	场景名称（如常驻基地与高铁移动走廊）；达 \(\theta_{\text{long}}\) 后生效，主支线独立存储
【长期记忆 ②】 **3. 情景记忆** （Episodic Memory）	6. 历史保障单据记录 `episodic_order_record`	`serial_no` （如 `"NE-09"`）	`executed_date`，`scene_col`，`cgi`，`app_col`，`biz_col`，起止时间与时长，保障参数，实际运行结果 `app_quality`（`good/bad`）	单据地点与业务短语；**逐笔原样追加、不跨单合并、不随时间衰减**，入库前过滤不足 \(T_{\min}\) 的无效单据
	7. 阶段事件与临时偏好 `episodic_event_preference`	`event_id | scope_time`	事件/差旅名称，`scene_col`，临时覆写槽位（如临时 `720p` 省流）、主动诉求状态（`active/closed`）、显式纠正记录、生效与到期时间 `ttl`	短期事件或临时诉求短语；有效期内局部优先，到期后自动标为 `expired` 不污染长期语义记忆
【长期记忆 ③】 **4. 程序化 / 经验记忆** （Procedural / Experiential）	8. 因果调参规则与流程 `procedural_experience`	`scene_type | biz_type | risk`	触发条件（通用场景类别+业务+无线特征）、原因、参数调整规则（如提前预热时长、切片类型）、消歧流程、适用与不适用范围 `scope`、验证统计	通用场景与业务特征短语；由短期工作记忆慢路径澄清与长期情景记忆正反单据对比提炼生成

1.5 本章小结

本章严格对齐 `CoALA` 认知架构，确立了“**1 个短期记忆（工作记忆）+ 3 个长期记忆（语义记忆、情景记忆、程序化/经验记忆）**”的两级分层体系，明确了短期工作记忆与三类长期记忆之间的 `Retrieval`（检索读入）和 `Learning`（学习写回）管理边界，并给出了对应的分表存储结构。

2 记忆从短期到长期的演变机制与萃取更新规则

2.1 北邮 MemoryOS（arXiv:2506.06326）的三级演变机制：STM → MTM → LPM

短期工作记忆中的单次对话或单张实时单据不能直接等同于长期语义记忆，否则单次偶发改期或基站故障异常单据会污染用户的常驻习惯。**北京邮电大学与腾讯 AI Lab 联合提出的《Memory OS of AI Agent》（MemoryOS, arXiv:2506.06326）**借鉴操作系统的分层内存管理思想，在短期记忆与长期记忆之间引入中期缓冲层，划分为**短期记忆（STM）→ 中期记忆（MTM）→ 长期个人记忆（LPM）**三级架构：

1. **① 短期记忆（STM，对应 CoALA 工作记忆）：对话页 + 对话链 FIFO 缓冲**。系统把当前会话的每一轮问答封装为一个“对话页（`page = {Q, R, T, meta_chain}`）”，放入定长 FIFO 队列（如容量为 7 页）；若前后页语义连贯，则自动串联成“对话链”并生成链级摘要。当定长队列满或会话结束时，按**先进先出（FIFO）**将对话页弹出，移交至中期记忆（MTM）。

2. ② **中期记忆（MTM）：操作系统“段页式（Segmented Paging）”话题聚合**。借鉴 OS 段页式内存设计——**“段（Segment）”对应话题摘要，“页（Page）”对应该话题下的具体对话页或单据记录**。当新页从短期工作记忆滑入时，计算向量余弦相似度与关键词 Jaccard 重合度；若超过阈值（如 `0.6`）则归并入已有话题段累积证据，否则开辟一个新话题段。
3. ③ **长期个人记忆（LPM，对应 CoALA 长期语义/程序化记忆）：热度分（Heat）驱动晋升与累积清零**。系统为每个中期话题段维护一个综合热度分：$\text{Heat} = \alpha\cdot\text{被检索次数} + \beta\cdot\text{段内累积页数} + \gamma\cdot\exp(-\Delta t/\mu)$。当段数超限时优先淘汰 `Heat` 最低的冷段；一旦某个话题段的热度分越过晋升阈值，便从该段中提炼出长期稳定事实与偏好特征写入长期记忆，随后**将该段的累积页数清零使热度回落**，防止同一批证据被重复提炼。

2.2 经典与主流 5 套 Agent 记忆系统横向对比

表 2.1 横向对比了学术界与工业界具有代表性的 **5 套经典 Agent 记忆架构**（包括 `Mem0`、`Zep/Graphiti`、`Letta/MemGPT`、上海 AI Lab `MemOS` 以及 `MemoryBank / A-MEM`），梳理它们**如何划分短期与长期层级、如何触发短期向长期演变、以及如何处理冲突、过期与容量上限**。

表 2.1：5 套主流 Agent 记忆架构的长短期分层、晋升机制与冲突治理对比表

团队 / 系统名称	短期与长期分层怎么建	短期 → 长期怎么演变（触发与提炼逻辑）	怎么处理冲突、过期与容量上限
1. Mem0（arXiv:2504.19413）	**短期滑动窗口 + 长期向量库与知识图谱（Mem0g）**：长期库只存提炼后的原子事实句与“实体—关系—实体”三元组。	**两步抽取 + 四动作判定**：每轮新对话进来，先结合当前工作记忆与近期滑动摘要抽出候选事实；再去长期向量库召回最相似的 Top-S 条已有记忆，由大模型通过工具调用判定执行 `ADD`（新增）、`UPDATE`（更新）、`DELETE`（删除矛盾）、`NOOP`（跳过）。	靠 `UPDATE / DELETE` 原地消解冲突（如新偏好直接覆盖旧偏好节点），避免同一件事存出多条相互矛盾的向量记录。
2. Zep / Graphiti（arXiv:2501.13956）	**三层时序知识图谱**： ① 原始事件子图（Episode，对应情景流水）； ② 语义实体子图（Entity & Fact，对应语义关系边）； ③ 社区聚类子图（Community，长期高层画像）。	每次会话或业务数据先写入 Episode 情景节点；异步抽取实体与关系边并入语义子图（通过向量+文本匹配合并同名实体）；再按图连通度将高频共现实体聚合成长期社区摘要。	**双时间戳有效期接替（不物理删旧边）**：每条关系边带 `事件生效/失效时间 (t_valid ~ t_invalid)` 与 `系统记录时间`。偏好改变时给旧边打上截止时间 `t_invalid` 并建新边，完整保留演变历史。
3. Letta / MemGPT（arXiv:2310.08560）	**仿 OS 虚拟内存两层**： ① **核心内存（Core Memory / RAM，对应短期工作记忆常驻块）**； ② **外部存储（Disk，对应长期记忆）**：回溯表（Recall）与归档库（Archival）。	**上下文压力中断 + Agent 自主换页**：短期对话在工作记忆窗口内累积，当达到上下文容量告警线（如 70%）时触发系统中断，Agent 自主调用函数把关键事实写进常驻块或刷入长期外存，再把早期对话移出短期窗口。	短期工作记忆设固定字符上限，写满时自主重写压缩；历史原始明细全部退入长期外存按需检索读入。
4. MemOS（上海 AI Lab）（arXiv:2507.03724）	**按计算介质分三层**： ① **激活记忆（Activation，短期 KV Cache 与工作状态）**； ② **明文记忆（Plaintext，长期外部文本、图谱与规则块）**； ③ **参数记忆（Parametric，模型权重）**。	用统一容器 `MemCube`（带来源、版本号、访问频次与权限）封装记忆：短期工作上下文中的高频知识先提升为可复用的激活缓存；经过长期高频调用、验证稳定的用户固定习惯与规则，进一步固化至长期明文或参数记忆。	由调度器（`MemScheduler`）监控访问频次与衰减率：低频过期的从激活层降级或归档淘汰，带版本号控制回滚。
5. MemoryBank / A-MEM（2305.10250 / 2502.12110）	· **MemoryBank**：短期对话日志 → 长期每日事件摘要（情景）+ 全局用户肖像（语义）。 · **A-MEM**：仿卡片盒笔记法（Zettelkasten）的双向关联长期记录网。	· **MemoryBank**：按**艾宾浩斯遗忘曲线** $R = \exp(-t / S)$ 演化——初建记忆强度 $S=1$，每次被重新提及或召回命中则 $S + 1$ 且时间 t 清零，多次强化后升入长期肖像。 · **A-MEM**：新记录先生成带标签的结构化记录，再自动与历史记录建链并**反向更新旧记录的上下文描述**。	MemoryBank 中单次偶发且长期未被召回的条目随 $\exp(-t/S)$ 自然跌破阈值被遗忘；A-MEM 通过反向更新旧记录总结避免旧记录语义脱节。

2.3 对联接 Agent 的思路启发：从短期工作记忆到三类长期记忆的四步演变逻辑

综合 `CoALA` 的长短期架构与北邮 `MemoryOS`、`Zep`、`Mem0`、`Letta / MemGPT` 的工程机制，联接 Agent 中**从短期工作记忆向三类长期记忆（情景记忆、语义记忆、程序化/经验记忆）演变的四步逻辑**如图 2.1 与表 2.2 所示。

```
flowchart TB
  subgraph Step1["第 1 步：短期工作记忆感知成链与长期情景记忆直写（Working Memory → Episodic Memory）"]
    direction LR
    S1_A["当前会话在短期工作记忆中维护活跃槽位
串联『提单 → 追问澄清 → 纠正 → 事后运行结果』"] --> S1_B["有效单据 + 网元实际运行结果 (good/bad)
清洗后原样追加写入【长期-情景记忆】（不合并、不衰减）"]
    S1_B --> S1_C["差旅事件窗与带有效期 TTL 的临时变动
写入【长期-情景记忆】，到期自动失效不入语义候选池"]
  end
```

```
  subgraph Step2["第 2 步：中期候选池按主题段页式归并（MTM Segment 候选缓冲池）"]
    direction LR
    S2_A["从工作记忆滑出的常规单据与对话按『场景/小区簇 + 业务 + 时间窗』
计算相似度归并到同一中期候选段累积证据（挂载 SerialNo 列表）"] --> S2_B["未满门槛保持候选态 candidate
未达最小跨度 W_span 与阈值 θ_long 前保持 candidate
不作为【长期-语义记忆】常驻默认参数直接生效"]
  end

  subgraph Step3["第 3 步：越过阈值升格为长期语义记忆与长期程序化/经验记忆（LTM Promotion）"]
    direction LR
    P1["通道 ①：隐式重复晋升 (→ 长期-语义记忆)
同一中期段内跨越 W_span 且累计得分达 θ_long
升格为 active 周期/场景常驻习惯并清零中期计数"] ~~~ P2["通道 ②：显式指令直通 (→ 长期-语义记忆)
用户对话明确声明常驻偏好（“以后都保4K”）
或给出口语映射 → 高权重直接写入长期语义记忆"] ~~~ P3["通道 ③：慢路径对比提炼 (→ 长期-程序化/经验记忆)
串联情景库前序异常单 + 工作记忆澄清 + 调整后正常单
提炼因果调参规则与消歧流程写入长期程序化/经验记忆"]
  end

  subgraph Step4["第 4 步：三类长期记忆的有效期接替、遗忘衰减与工作记忆容量控制"]
    direction LR
    S4_A["长期语义记忆：双时间戳接替与遗忘衰减
旧档位打失效时间 t_invalid 标为 superseded；长期未用按 R 衰减"] --> S4_B["长期情景与经验记忆：TTL 失效与运行结果验证
情景单据永久保留、临时项按 TTL 失效；经验连续异常则降级停用
短期工作记忆仅按需读入 Top-k 有效长期记录，控制上下文长度"]
  end

  Step1 ==> Step2
  Step2 ==> Step3
  Step3 ==> Step4
```

图 2.1：从短期工作记忆（Working Memory）经中期候选段向三类长期记忆（情景、语义、程序化/经验）演变的四步方法论架构图。

第 1 步在短期工作记忆内完成当次会话成链，并将完结单据与短期 `TTL` 临时项直写长期情景记忆；第 2 步对常规行为在中期候选池做段页式归并；第 3 步通过三条通道分别升格为长期语义记忆与长期程序化/经验记忆；第 4 步执行双时间戳版本接替、遗忘衰减与工作记忆常驻容量控制。

表 2.2：从短期工作记忆向三类长期记忆演变的四步规则与真实样本对照表

演变阶段	涉及的 CoALA 记忆层级	具体流转与晋升规则（吸收 CoALA + MemoryOS + Zep + Mem0）	网络保障真实样本例子
第 1 步：短期工作记忆成链与长期情景记忆直写	**短期 — 工作记忆 → 长期 — 情景记忆**	· 会话进行中，**短期工作记忆**实时跟踪多轮槽位并串联“提单 → 追问澄清 → 用户纠正 → 事后网元运行结果”； · 单据完结后，清洗剔除不足 $T_{\min}$ 的无效单据，将有效单据与运行结果（`good/bad`）原样追加写入**长期情景记忆**（`episodic_order_record`）； · 若含异地差旅或 `今天 / 本次临时` 声明，带有效期 `TTL` 写入**长期情景记忆**（`episodic_event_preference`），不进入语义晋升池。	用户周三说“今天下雨，晚八点直播先降到 720p” → 完结后单据原样追加进长期情景记忆 `SN_004`，临时降档带当日 `TTL` 写入长期情景记忆，不改长期语义记忆中的常驻 1080p 偏好。
第 2 步：中期候选池按主题段页式归并	**中期候选缓冲池**（`MTM candidate`）	· 借鉴北邮 MemoryOS 的**段页式归并**：当常规单据或对话从短期工作记忆滑出时，按**“场景/小区簇 + 业务类型 + 时间窗”**计算相似度，归并到同一个中期候选段下累积证据（挂载情景单据 `SerialNo` 列表）； · 未满足最小时间跨度 W_{span} 与得分阈值 θ_{long} 前保持 `candidate`，不写入长期语义记忆。	第 1、2 次在周六晚去奥体中心用抖音推流（`SN_008, SN_011`）→ 归并进“周末场馆推流”中期候选段（候选态 `candidate`）。

演变阶段	涉及的 CoALA 记忆层级	具体流转与晋升规则（吸收 CoALA + MemoryOS + Zep + Mem0）	网络保障真实样本例子
第 3 步：越过阈值升格为长期语义与程序化记忆	**长期 — 语义记忆** & **长期 — 程序化/经验记忆**	参考北邮 `Heat` 热度机制与 PersonaMem-v3 证据门限，设三**条长期化通道**： ① **隐式重复晋升（→ 长期语义记忆）**：同一中期候选段内，一致记录跨越 \(W_{\text{span}}\) 且累计得分达 \(\theta_{\text{long}}\)（或频次达 \(N_{\text{min}}\)） → 升格为 `active` 写入长期语义记忆，并清零中期未处理计数； ② **显式指令直通（→ 长期语义记忆）**：用户在对话中明确声明常驻偏好或口语映射 → 高权重直接写入长期语义记忆； ③ **慢路径对比提炼（→ 长期程序化/经验记忆）**：串联长期情景记忆中的前序异常单据、短期工作记忆中的多轮澄清轨迹与调整后正常单据 → 提炼因果调参规则或消歧流程写入长期程序化/经验记忆。	· 多次周六在奥体中心推流达标后 → 升格为长期语义记忆中的周期场景习惯； · 从首次去场馆拥塞（`NE-05`）经澄清改为提前 20min 预热成功（`NE-09`）的对比中 → 提炼出大型聚集场馆程序化/经验规则。
第 4 步：长期记忆接替衰减与工作记忆容量控制	**三类长期记忆** ↔ **短期 — 工作记忆**	· **长期语义记忆双时间戳接替与遗忘**：当用户升级套餐或新档位连续达标时，给旧语义记录写入失效时间 \(t_{\text{invalid}}\) 并标为 `superseded`，新记录标为 `active`；长期未触发习惯按保持率衰减； · **长期情景与经验记忆治理**：情景单据永久保真，阶段性临时偏好按 `TTL` 转为 `expired`；程序化/经验规则若后续运行结果连续异常则降级停用； · **短期工作记忆换页控制（借鉴 Letta）**：每轮只将 Top-\(k\) 生效长期记忆加载进短期工作记忆。	用户升级 4K 直播套餐后 → 长期语义记忆中原 `1080p / 60min` 记录标为 `superseded`，新一轮会话检索时只将 `active` 的 `4K / 90min` 读入短期工作记忆。

2.4 单据预处理、候选池累积参数与记忆保持率衰减计算

原始网元单据流中混有持续时间很短的后台流量记录、基站切换产生的断流拆分记录，以及用户的临时改动或偶发行为。工程实现时，具体业务阈值用可配置参数表示（不在代码里写死固定数值），从短期工作记忆向长期情景记忆、长期语义记忆流转的处理流程与参数定义如图 2.2 与表 2.3 所示：

1. **过滤时长过短的无效单据，合并因断流拆开的多笔记录** —— **参考** `BehaviorMem` **(arXiv:2610.34790)**：系统按最小有效时长参数 \(T_{\min}\) 剔除无对话对应的短时后台记录及中途取消的无效单据；对于同一用户、同一业务因基站切换在短时间间隔 \(\Delta t_{\text{gap}}\) 内断开重连产生的多笔记录，合并为 1 笔完整单据追加写入**长期情景记忆**（`episodic_order_record`），避免同一次连续保障被切碎并重复计算次数。
2. **区分对话明确声明与单据重复行为的权重，将短期变动写入长期情景记忆** —— **参考** `PersonaMem-v3` **(arXiv:2608.21381)**：系统分别为对话显式声明与单据隐式行为配置权重参数 \(w_{\text{exp}}\) 与 \(w_{\text{imp}}\)（满足 \(w_{\text{exp}} > w_{\text{imp}}\)）。对话中说明“今天临时”、“出差这几天”的记录附带有效期 `TTL` 只写入**长期情景记忆**（`episodic_event_preference`），到期自动失效；累计得分低于噪声下限 \(\theta_{\text{noise}}\) 的单次偶发行为不进入长期语义库。
3. **先放入中期候选池累积，满足跨度与得分阈值后再晋升为长期语义记忆** —— **参考北邮** `MemoryOS` **(arXiv:2506.06326)**：常规记录先按“所在区域、应用与业务、时间段”归并到中期候选池（状态标为 `candidate`）。当同一类记录跨越最小时间范围 \(W_{\text{span}}\) 持续出现，且累计得分达到长期阈值 \(\theta_{\text{long}}\) 时，状态转为正式生效（`active`）写入**长期语义记忆（Semantic Memory）**，同时清零该候选段的未处理计数。
4. **偏好变化时保留旧记录并标记失效时间** —— **参考** `Zep / Graphiti` **(arXiv:2501.13956)**：当默认档位或常驻时段更新时，给长期语义记忆中的旧记录写入失效时间 \(t_{\text{invalid}}\) 并标为 `superseded`，同时写入新记录并标为 `active`（记录生效时间 \(t_{\text{valid}}\)）。



图 2.2：从短期工作记忆清洗写入长期情景记忆、并经中期候选池晋升为长期语义记忆的处理流程

有效单据与带有效期的短期变动先写入长期情景记忆；常规记录在中期候选池中按权重累计得分，满足最小时间跨度与得分阈值后晋升为正式生效的长期语义记忆。

表 2.3：单据过滤、候选累积与长短期流转的可配置参数说明及参考依据

处理步骤	可配置参数	判断规则与流转方式	参考评测集与记忆系统
1. 过滤无效记录与合并断流单据	\(T_{\min}\)（最小有效时长） \(\Delta t_{\text{gap}}\)（断流合并最大间隔）	时长不足 \(T_{\min}\) 且无对话对应的记录直接剔除；间隔在 \(\Delta t_{\text{gap}}\) 内的同业务断流记录合并为 1 笔完整单据写入长期情景记忆。	`BehaviorMem`：剔除浅层瞬时访问，按时间间隔合并同一次连续行为
2. 区分信号权重与写入阶段情景记录	\(w_{\text{exp}}, w_{\text{imp}}\)（对话与单据权重） \(\theta_{\text{noise}}, \theta_{\text{short}}\)（噪声下限与短期阈值）	对话明确声明的权重高于单据行为（\(w_{\text{exp}} > w_{\text{imp}}\)）；累计得分低于 \(\theta_{\text{noise}}\) 的偶发记录不入长期语义库；绑定差旅/短期事件且达 \(\theta_{\text{short}}\) 的记录带 `TTL` 写入长期情景记忆。	`PersonaMem-v3`：区分显式与隐式行为分值，划分持续稳定、逐渐消退、近期新增与单次偶发四类轨迹
3. 候选池累积与晋升长期语义记忆	\(W_{\text{span}}\)（最小时间跨度） \(\theta_{\text{long}}\)（转为长期习惯的得分阈值）	未达阈值前保持 `candidate` 候选状态；时间跨度满足 \(W_{\text{span}}\) 且累计得分达到 \(\theta_{\text{long}}\) 后转为 `active` 写入长期语义记忆，并清零已处理计数。	北邮 `MemoryOS`：按主题段页归并候选记录，达到热度阈值后晋升长期记忆并清零计数
4. 新旧记录更替与长期未用衰减	\(t_{\text{valid}}, t_{\text{invalid}}\)（生效与失效时间） \(\lambda, \kappa\)（衰减率与复现强化参数）	档位变化时给旧语义记录写入失效时间 \(t_{\text{invalid}}\) 并标为 `superseded`；长期不再触发的周期/场景语义习惯按保持率自然衰减。	`Zep / Graphiti`：双时间戳保留历史；`MemoryBank`：按遗忘曲线衰减与强化

参考 `MemoryBank` (arXiv:2305.10250) 的遗忘曲线计算方式，**长期语义记忆**中的周期与场景习惯如果长期不再触发，其保持率随间隔时间下降；累计确认和检索使用的次数越多，衰减越平缓：

$$R = \exp\!\left(-\frac{\lambda t}{1 + \kappa \ln(1 + n)}\right)$$

符号解释如下：

1. \(t\)：距离该条记忆最近一次被确认或使用的间隔天数；\(n\)：累计有效出现与被检索命中的次数。
2. \(\lambda, \kappa\)：分别为基础日衰减率参数与强化系数（作为配置参数按业务周期设定；**长期情景记忆中的历史单据记录固定取 \(\lambda = 0\)，不随时间自然衰减**，阶段性临时偏好按到期时间戳 `TTL` 判定失效）。

2.5 本章小结与拓展阅读

- **长短期三级缓冲与四步演变：**结合 `CoALA` 与北邮 `MemoryOS (STM → MTM → LPM)`，短期工作记忆负责会话内成链，完结单据与带 `TTL` 临时项直写长期情景记忆，常规行为经中期候选池段页式归并累积（跨度 \(W_{\text{span}}\) 且达 \(\theta_{\text{long}}\)）后晋升为长期语义记忆，并通过双时间戳版本接替（`superseded`）保留历史。
- **拓展阅读：**普林斯顿 *CoALA* (arXiv:2309.02427)；北邮+腾讯 AI Lab *MemoryOS* (arXiv:2506.06326)；上海 AI Lab *MemOS* (arXiv:2507.03724)；*Mem0* (arXiv:2504.19413)；*Zep/Graphiti* (arXiv:2501.13956)；*Letta/MemGPT* (arXiv:2310.08560)；*MemoryBank* (arXiv:2305.10250)；*A-MEM* (arXiv:2502.12110)。

3 程序化 / 经验记忆要学到什么：从“多轮澄清/理解失败”到“快速闭环”

3.1 经验学习领域的 5 篇代表性论文与核心工作

在 `CoALA` 的三类长期记忆中，长期语义记忆记录“用户常驻要什么”，长期情景记忆记录“过去具体办过哪些单据且结果如何”，而**长期程序化 / 经验记忆（Procedural / Experiential Memory）记录“遇到特定无线场景或歧义情况时，系统该怎么调参与处置（*How to do*）”**。程序化/经验记忆要学习的是具备可迁移性的因果规则与办事流程：**在什么条件下（Condition）、因为什么原因（Cause）、该执行什么参数调整规则或消歧流程（Action / Workflow）、执行后实际运行结果如何（Outcome）**。表 3.1 列出学术界在智能体程序化与经验学习方向具有代表性的 5 篇核心论文。

表 3.1：智能体程序化与经验学习领域的 5 篇代表性工作拆解

代表性论文与编号	核心工作与机制贡献
1. Reflexion Shinn et al. (arXiv:2303.11366)	把任务执行后的环境反馈信号转成文字反思（Verbal Reflection），存进记忆缓冲区，下一次尝试前直接读入短期工作记忆以修正行为。
2. ExpeL Zhao et al. (arXiv:2308.10144)	从一批尝试轨迹中自动收集成功案例与**成对的成功/失败对比轨迹**，用自然语言增删改操作提炼出通用结论（Insights），推理时同时召回结论规则与相似成功轨迹读入工作记忆。
3. Agent Workflow Memory (AWM) Wang et al. (arXiv:2409.07429)	从历史轨迹中归纳经常复用的**多步处理流程（Workflows，即显式程序化记忆）**，离线或在线更新进长期记忆库，帮助智能体在后续同类任务中直接复用成熟流程、减少重复摸索步骤。
4. ReasoningBank arXiv:2509.25140 (2025)	从智能体自评的成功和失败经验中提炼可泛化的高层推理策略，实证验证了**“同时学成功与失败并抽象成策略”显著优于只存原始轨迹或只存成功流程**。

代表性论文与编号	核心工作与机制贡献
5. 经验跟随实证研究 arXiv:2505.16067 (2025)	系统分析了检索到的历史经验如何影响当前输出：发现经验与当前输入越相似，模型越倾向于盲目照搬，容易造成**错误经验传播与不匹配经验误导**；并提出**用后续任务的执行结果作为经验质量的验证标签**，持续过滤低质经验。

3.2 程序化 / 经验记忆要抓住的五个重点与三种经验类型

针对给定的多轮澄清对话提取“问题 → 参数调整规则 → 结果”较为直接，实际难点在于：① **从长周期混杂会话与单据流中识别并关联值得沉淀的慢路径源头样本；② 当后续请求更换口语表述或具体场馆名称时，跨字面差异召回相关经验规则，并过滤字面相似但无线环境条件不符的干扰项**。结合上述论文与网络保障场景，长期程序化/经验记忆的构建包含以下五个重点（图 3.1 与表 3.2）：

```
flowchart TB
  subgraph SlowPath["一、经验的产生源头：短期工作记忆慢路径澄清 + 长期情景记忆正反单据对比 (ExpeL / ReasoningBank)"]
    direction LR
    S_fail["前序异常单据（长期情景记忆）
情景单据 NE-05：去体育馆按普通参数下发
开场空口拥塞导致卡顿掉帧 (AppQuality=bad)"] --> S_clar["慢路径多轮澄清与纠正（短期工作记忆 S-03）
经过多轮追问与用户纠正
确定方案：提前 20~30min 开启专网切片预热"]
    S_clar --> S_succ["调整后正常单据验证（长期情景记忆）
情景单据 NE-09：按预热方案执行后
网元运行结果 DelayAn 正常, AppQuality=good"]
  end

  subgraph Card["二、长期程序化 / 经验记忆条目沉淀（抽象到可迁移粒度 + 明确适用与不适用边界）"]
    direction LR
    C1["触发条件 Condition
场景类别=大型演艺与体育聚集场馆
业务=上行推流 | 时段=演出/赛事日"] --> C2["根因与参数调整规则 Cause & Action
原因：开场并发接入空口拥塞
调整：start_time 提前20-30m, 专网切片"]
    C2 --> C3["适用边界与验证 Scope & Validation
适用：同类高密场馆 | 不适用：非赛事日/下行点播/室内驻地
挂载情景证据：[NE-05, S-03, NE-09] | 置信度=0.90"]
  end

  subgraph FastPath["三、后续跨场馆检索读入短期工作记忆与事后运行结果验证 (AWM / 2505.16067)"]
    direction LR
    F1["后续同类请求（去另一体育馆工体中心开播）
检索命中程序化/经验规则并读入短期工作记忆"] --> F2["工作记忆内预计算提前预热与切片参数
无需重复多轮追问，支撑下游 1 轮闭环"]
    F2 --> F3["事后网元运行结果闭环验证
运行结果 AppQuality=good 则置信度上升
若连续异常则降级停用防止错误经验传播"]
  end

  SlowPath ==> Card
  Card ==> FastPath
```

图 3.1：从“长期情景记忆正反单据对比 + 短期工作记忆多轮澄清”中提炼长期程序化/经验记忆并在后续复用的架构图。

上方通过长期情景记忆中的正反单据对比与短期工作记忆中的多轮澄清对话提炼因果规律；中部将其封装为带适用边界（`scope`）的长期程序化/经验规则条目；下方在后续同类新场馆中检索读入短期工作记忆并用运行结果持续验证。

表 3.2：程序化 / 经验记忆构建要抓住的五个方法论重点及网络保障实例

方法论重点	核心机制含义	网络保障中的具体实例
1. 从多轮澄清与理解失败中提炼规则	复盘首次交互时系统为什么没能一次办成（漏了什么参数、误解了哪个指代、经过几轮追问/纠正才对齐），把最终验证有效的做法记入长期程序化/经验记忆。	首次去奥体中心按普通参数下发发生卡顿（情景单据 `NE-05`），后续会话 `S-03` 经多轮沟通确定提前 20~30 分钟开启上行切片预热 → 沉淀为场馆推流经验规则。
2. 读入工作记忆支撑后续快速闭环	程序化/经验记忆的核心价值是在下次遇到相同场景特征时，被检索读入短期工作记忆直接补齐调整参数，使下游不再重复追问或配错普通档位。	后续用户换去工人体育场说“今晚开播”，检索召回场馆预热经验读入短期工作记忆，直接提供提前预热与切片参数。
3. 条件抽象到可迁移的通用粒度	触发条件用**通用场景类别、业务类型、无线特征**描述；具体小区 ID、情景单据号只作为底层证据挂载，确保跨具体地点可迁移。	触发条件不写死“奥体中心”，而归纳为“大型演艺与体育聚集场馆 + 上行推流”，用户换去工人体育场、五棵松体育馆也能直接召回。
4. 情景正反单据对比锁定调整动作	对比长期情景记忆中“初次未预热的异常单据（`bad`）”与“澄清调整后的正常单据（`good`）”（参考 `ExpeL`），锁定真正起作用的参数调整规则。	对比奥体未预热异常单据 `NE-05` 与提前预热正常单据 `NE-09`，锁定差异动作是“开始时间前移 20 分钟 + 上行专网切片”。

方法论重点	核心机制含义	网络保障中的具体实例
5. 写明适用边界与运行结果验证	标明什么情况下**不适用**（`scope.exclude`）（防止相似字面盲目套用 —— 参考 `arXiv:2505.16067`），并用后续单据的网元实际运行结果持续更新置信度。	写明 `exclude = ["下行视频点播", "普通室内常驻场所", "语音通话"]`；用户在体育场看台刷点播视频或回室内基地看球开播时自动排除该规则。

长期程序化 / 经验记忆涵盖三**种互补类型**：① **网络问题因果调参规则**（什么场景、什么业务容易出什么无线问题，该怎么调提前预热、专网切片或弱网降级保语音）；② **多单消歧与排障处理流程（Workflows）**（遇到某类请求按什么顺序查记忆与核实，如“指代历史单据 → 先在长期情景记忆中排除卡顿异常单据 → 若仍有多笔有效单据冲突则列明差异供确认”）；③ **交互免打扰策略**（哪些已稳固的常驻语义参数无需每次重复向用户确认）。

3.3 从长周期记录中定位慢路径源头与正反单据对比提炼

在实际业务流中，慢路径对话与历史单据穿插在大量日常快路径工单与闲聊之间。参考 `ExpeL` (arXiv:2308.10144) 与 `ReasoningBank` (arXiv:2509.25140)，系统通过长期情景记忆中的单据号与场景标签串联以下三条记录定位经验源头（见图 3.2）：

1. **长期情景记忆中的前序同场景异常单据**（NE_{bad}）：同一类空间场景下，存在事后实际运行结果为异常（`AppQuality = bad`，如基站 `PRB ≥ 95%` 拥塞导致掉帧）的历史单据，或同一地点存在多笔不同规格单据冲突。
2. **短期工作记忆捕获的多轮澄清或用户纠偏对话**（S_{slow}）：后续会话中针对该异常或歧义发生多轮追问确认或用户主动纠偏（如“上次开场太卡了，这次提前二十分钟把上行切片开上”，或纠正“对抖音的词其实是微信视频通话”）。
3. **长期情景记忆中调整参数后的正常单据**（NE_{good}）：按沟通后的调整参数执行工单，事后网元实际运行结果恢复为正常（`AppQuality = good`）。（注：仅做假设性咨询而未实际落单闭环的对话不提炼为程序化/经验规则。）

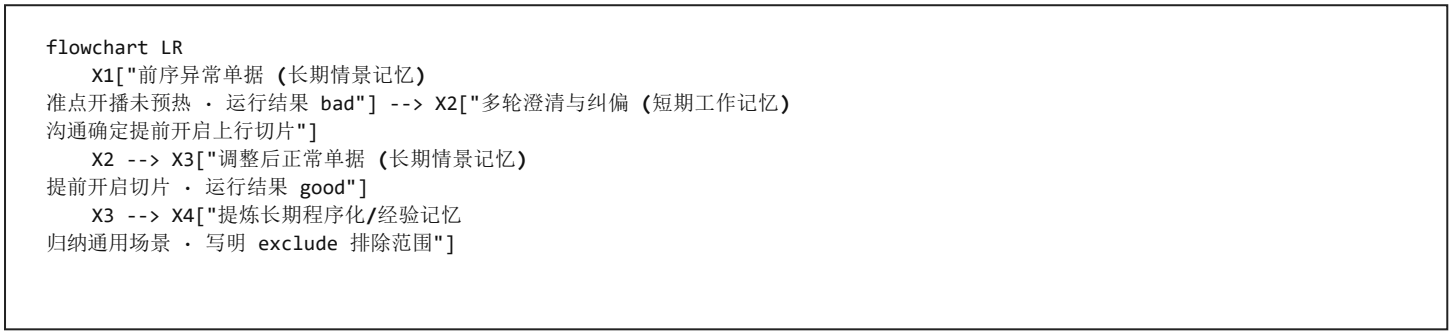


图 3.2：串联长期情景记忆中的异常单据、短期工作记忆中的澄清对话与调整后正常单据提炼长期程序化/经验记忆的流程

通过对比调整前后的两笔情景单据锁定起作用的参数调整规则，将具体地名归纳为通用场景类别，并写明不适用的业务范围。

3.4 短期工作记忆与三类长期记忆的结构化数据示例

清单 3.1 给出了用户 `USER_001` 在第 28 天会话进行时的**短期记忆（工作记忆 `working_memory_short_term`）**内存快照，以及数据库中持久保存的三**类长期记忆（语义记忆 `semantic_memory_long_term`、情景记忆 `episodic_memory_long_term`、程序化/经验记忆 `procedural_experiential_memory_long_term`）**的实际 JSON 结构：

清单 3.1：CoALA 短期工作记忆与三类长期记忆（语义、情景、程序化/经验）结构化数据示例 source: memory_system/storage/index.py & runtime/working_memory.py

```
{
  "working_memory_short_term": {
    "session_id": "S-06", "current_turn": 1, "lifecycle": "short_term_active_session_only",
    "current_user_utterance": "到工体了，19:30用小破站开播，别用卡顿那套，照奥体没卡那次办",
    "active_slot_state": {
      "location": "北京工人体育场", "app": "bilibili", "service": "openlive",
      "resolution": "4K", "start_time": "19:10", "end_time": "21:30", "duration": "140min",
      "unresolved_conflicts": []
    },
    "retrieved_long_term_memory_ids": [
      "expr|小破站开播", "pref|bilibili|openlive|v2", "NE-09", "exp|stadium_crowd|openlive"
    ]
  },
  "long_term_memories": {
    "semantic_memory_long_term": {
      "expression": [
        {
          "memory_key": "expr|小破站开播",
          "alias_col": "小破站开播", "target_col": "bilibili:openlive",
          "phrase_text": "小破站开播", "status": "active", "confidence": 0.95
        }
      ],
      "preferred_value": [
        {
          "memory_key": "pref|douyin|openlive|v1",
          "payload": {"resolution": "1080p", "duration": "60min"},
```

```
          "t_valid": "2026-11-01", "t_invalid": "2026-11-19",
          "status": "superseded", "superseded_by": "pref|douyin|openlive|v2"
        },
        {
          "memory_key": "pref|douyin|openlive|v2",
          "app_col": "douyin", "biz_col": "openlive",
          "payload": {"resolution": "4K", "bitrate_ul": "25Mbps", "duration": "90min", "package": "6G_NGC_Live_Pro"},
          "phrase_text": "抖音 开直播", "t_valid": "2026-11-20", "t_invalid": null,
          "status": "active", "evidence_score": 6.5, "confidence": 0.92
        }
      ],
      "periodic_preference": [
        {
          "memory_key": "period|12:30-14:00|douyin:openlive",
          "time_window_col": "12:30~14:00", "app_col": "douyin", "biz_col": "openlive", "scene_col": "杭州滨江基地",
          "phrase_text": "午间例行直播", "status": "active", "evidence_score": 8.0, "confidence": 0.94
        }
      ]
    },
    "episodic_memory_long_term": {
      "episodic_order_record": [
        {
          "memory_key": "NE-05", "executed_date": "2026-11-09", "scene_col": "北京奥体中心",
          "app_col": "douyin", "biz_col": "openlive", "time_window": "19:30~21:30", "duration": "120min",
          "payload": {"resolution": "1080p", "prewarm_min": 0, "stall_count": 6},
          "app_quality": "bad", "phrase_text": "北京奥体中心 抖音直播", "status": "active"
        },
        {
          "memory_key": "NE-09", "executed_date": "2026-11-15", "scene_col": "北京奥体中心",
          "app_col": "douyin", "biz_col": "openlive", "time_window": "19:10~21:30", "duration": "140min",
          "payload": {"resolution": "4K", "prewarm_min": 20, "slice": "6G_NGC_UL_Slice", "stall_count": 0},
          "app_quality": "good", "phrase_text": "北京奥体中心 抖音直播", "status": "active"
        }
      ],
      "episodic_event_preference": [
        {
          "memory_key": "epi|2026-11-16|temp_720p_override",
          "scene_col": "杭州滨江基地", "override_slots": {"resolution": "720p"},
          "reason": "用户声明仅今天临时改 720p，不修改常驻语义默认档位",
          "t_valid": "2026-11-16T00:00:00", "ttl": "2026-11-16T23:59:59",
          "phrase_text": "今天临时降画质 720p", "status": "expired"
        }
      ]
    },
    "procedural_experiential_memory_long_term": [
      {
        "memory_key": "exp|stadium_crowd|openlive",
        "condition": {"scene_category": "大型演艺与体育聚集场馆", "biz_type": "openlive"},
        "cause": "演出开场前后高并发接入导致上行拥塞，准点开启保障来不及收敛",
        "recommended_adjustments": {"start_time_offset_min": -20, "duration_offset_min": 20, "slice": "6G_NGC_UL_Slice"},
        "scope": {
          "include": ["体育场", "体育馆", "演唱会场馆", "会展中心"],
          "exclude": ["下行视频点播", "普通室内常驻场所", "语音通话"]
        },
        "phrase_text": "大型聚集场馆 演出赛事 上行推流",
        "evidence": ["NE-05", "S-03", "NE-09"], "validation": {"success": 2, "fail": 0}, "confidence": 0.90, "status": "active"
      }
    ]
  }
}
```


3.5 本章小结与拓展阅读

- **程序化/经验归纳与边界控制：**从长期情景记忆中的前序异常单据（NE_{bad}）、短期工作记忆中的多轮澄清对话（S_{slow}）与调整后正常单据（NE_{good}）对比中提炼显式程序化/经验规则，将触发条件抽象至可跨地点迁移的通用场景类别，并显式绑定适用与不适用边界（`scope.exclude`）及运行结果验证计数。
- **拓展阅读：**CoALA (arXiv:2309.02427)；Reflexion (arXiv:2303.11366)；ExpeL (arXiv:2308.10144)；AWM (arXiv:2409.07429)；ReasoningBank (arXiv:2509.25140)；Empirical Study of Experience Following (arXiv:2505.16067)。

4 三类长期记忆的混合检索流程

4.1 滑动窗口切分与否定子句处理

当短期工作记忆接收到包含多个子句的用户长句输入（如“今天不去滨江基地了，今晚七点半在工体中心用小破站开播，别用卡顿那套，照奥体没卡那次办”）时，整句直接转成单个向量会稀释局部口语表达（如“小破站开播”）的权重，而且容易把否定词后面的地点（“滨江基地”）误召回。因此，在向三类长期记忆发起检索（`Retrieval`）前，先切分子句并处理否定表达（见图 4.1）：

1. **否定子句分离与权重衰减过滤** —— 参考 `BlendX` (arXiv:2403.18277)：按标点与连词切分子句，识别带否定词的子句（如“不去”、“别用”、“取消”），提取其中被排斥的地点或状态；如果某条长期记忆候选记录匹配了被排斥项且未被后续正向子句重新指定，将其向量相似度扣减 δ_{neg}。
2. **按滑动窗口切分短语并匹配向量**：对正向子句按窗口长度参数 L_{win}、步长参数 S_{step} 切分为多个重叠的短窗口，批量编码为向量后与长期记忆库内 `phrase_text` 的短语向量计算余弦相似度，取所有正向窗口中的最高值作为该记录的向量匹配得分。

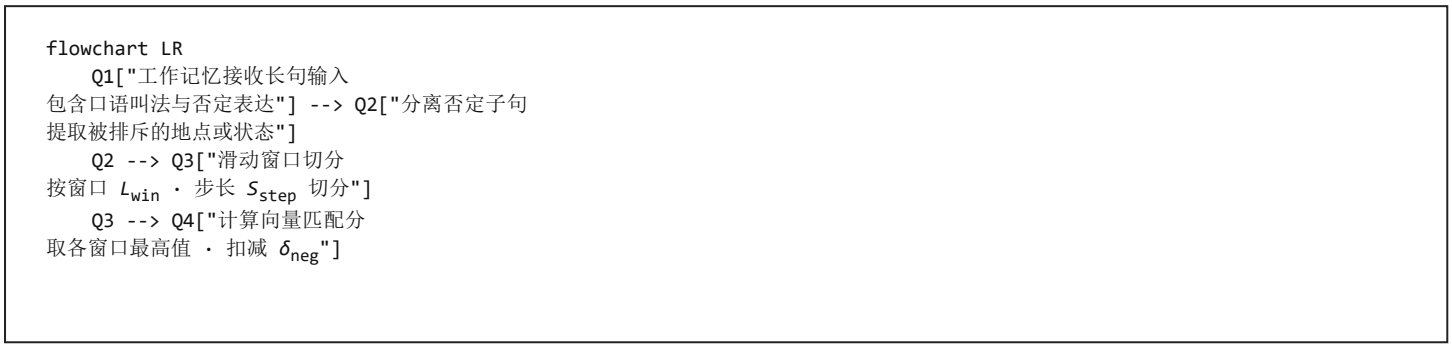


图 4.1：短期工作记忆输入长句的滑动窗口切分与否定子句处理流程

先分离包含否定词的子句避免反向误召回，再将正向子句切分为多个短窗口与长期记忆库内的短语向量逐一比对，保留局部口语表达的匹配精度。

4.2 语义、情景、程序化（经验）三类长期记忆并行检索与二阶段关联补全

得到短语窗口的向量匹配结果后，系统通过**向量相似度检索定位候选记录，读取同行结构化槽位列，再做二阶段关联表补全**，从三类长期记忆中并行检索并读入短期工作记忆（见图 4.2）：

- **长期记忆 ① — 语义记忆检索（Semantic Memory Retrieval）**：正向窗口向量命中 `expression`（达到相似度阈值 τ_{sim}）后，读取同行 `target_col` 将口语叫法转为标准应用与业务；若只提到业务而未指定应用，查询 `service_to_app` 补全默认应用；结合当前时间与地点匹配常驻周期习惯 `periodic_preference` 或场景常驻偏好 `scene_preference`（仅查询 `active` 记录，分开管理常驻主线与外出支线 —— 参考 `MemPABench`），再通过二阶段关联查询 `preferred_value` 补齐最新默认分辨率与时长（自动跳过标为 `superseded` 的旧记录 —— 参考 `LongMemEval`）。
- **长期记忆 ② — 情景记忆检索（Episodic Memory Retrieval）**：① **查询历史保障单据记录（`episodic_order_record`）**：将口语时间词（如“上周六”）换算为具体日期范围，结合地点向量匹配查询历史单据。如果用户要求“照没卡那次办”，优先保留 `app_quality = 'good'` 的正常单据并降低同地点 `bad` 异常单据的排名；如果同一地点命中多笔不同规格单据，则将候选单据及各自运行结果一并读入短期工作记忆；② **查询阶段性事件与临时偏好（`episodic_event_preference`）**：核查当前时间 `reference_time` 下处于有效期内（未超过 `ttl`）的差旅事件窗、短期临时降档偏好及最新显式纠正记录，已过期记录（`expired`）直接过滤。
- **长期记忆 ③ — 程序化 / 经验记忆检索（Procedural / Experiential Memory Retrieval）**：将当前地点归入通用场景类别（如“工体中心”归为“大型演艺与体育聚集场馆”），匹配 `procedural_experience` 记录的触发条件与多单消歧流程，并检查不适用列表 `scope.exclude` ——如果当前请求属于下行视频点播或普通室内常驻场景，直接剔除该条经验记录。

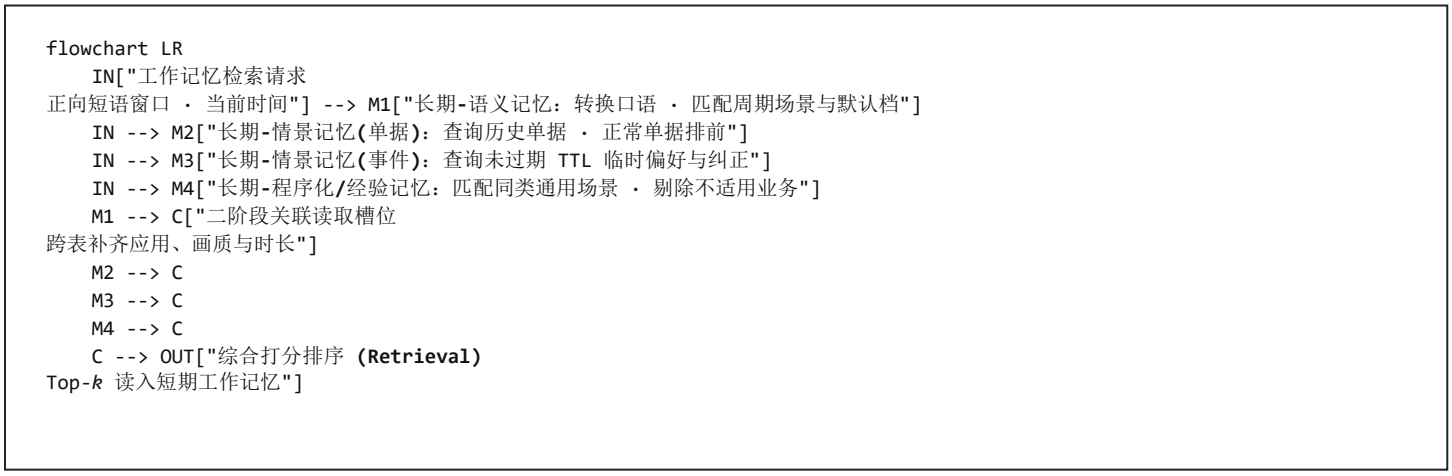


图 4.2：三类长期记忆（语义、情景、程序化/经验）并行检索、二阶段关联补全并读入短期工作记忆的流程

长期语义记忆、长期情景记忆（含历史单据流水与带 `TTL` 阶段事件）以及长期程序化/经验记忆并行完成匹配与跨表槽位补齐，统一排序后将 Top-\(k\) 有效记录读入短期工作记忆。

4.3 综合排序评分与多记忆联合检索

对通过条件过滤的长期记忆候选记录，综合向量相似度、记忆保持率、近期访问热度与置信度加权计算排序得分：

$$S_i = \alpha_i \big(w_s s_i + w_r R_i + w_h h_i + w_c c_i\big)$$

符号解释如下：

1. \(s_i, R_i, h_i, c_i\)：分别为正向窗口最高余弦相似度（命中否定表达已扣减 \(\delta_{\text{neg}}\)）、时间保持率、近期访问热度与记录置信度；\(w_s, w_r, w_h, w_c\) 为对应的权重参数（满足 \(w_s + w_r + w_h + w_c = 1\)）。
2. \(\alpha_i\)：状态过滤系数；正常生效记录取 \(1\)，用户指代顺畅体验时的同地点卡顿异常情景单据取降权系数 \(\gamma_{\text{bad}}\)（\(0 < \gamma_{\text{bad}} < 1\)，排在正常单据之后），已替代的旧语义档位（`superseded`）、已过期的情景临时偏好（`expired`）或落入不适用列表 `scope.exclude` 的程序化/经验记录取 \(0\)（直接剔除）。

在实际复杂请求中，通常需要三类长期记忆配合读入短期工作记忆。表 4.1 列出了四类常见联合检索场景的配合顺序与优先级规则：

表 4.1：三类长期记忆联合检索读入短期工作记忆的配合顺序与冲突优先级

长期记忆组合类型	用户请求示例	配合检索顺序（Retrieval → 工作记忆）	工作记忆内的槽位优先级规则
长期语义 + 长期情景（临时事件）	（出差或月末省流有效期内）“中午照例开播”	先查**长期语义记忆**得到固定时段 `12:30~14:00` 与默认 `4K` 档位；再查**长期情景记忆**命中未过期的临时 `720p` 省流偏好。	有效期内（未过 `TTL`）的情景临时偏好在工作记忆中局部覆盖画质槽位；过期后自动恢复常驻 `4K`。
长期语义 + 长期情景（历史单据）	“今晚在奥体用**小破站开播**，按**上周没卡那次**办”	先查**长期语义记忆**将“小破站开播”转为 `bilibili:openlive`；再查**长期情景记忆（单据表）**找到奥体上周运行结果为 `good` 的正常单据读取规格。	当轮明确指定的应用优先于旧单据中的应用；正常情景单据（`good`）排在卡顿单据（`bad`）之前。
长期语义 + 长期程序化/经验	（周六晚演出日）“到工体了，按周末习惯开抖音直播”	先查**长期语义记忆**读取常用档位 `4K`；再按“大型演艺与体育聚集场馆 + 上行推流”从**长期程序化/经验记忆**召回提前 20 分钟开启上行切片规则。	在常驻档位基础上叠加程序化/经验调整参数（开始时间前移 20 分钟并开启上行专网切片）。
三类长期记忆全联合 → 短期工作记忆	“今晚 19:30 去**工体**用**小破站开播**，照**奥体那次**办”（奥体存在多笔不同规格单据）	**长期语义记忆**转换口语叫法 + **长期情景记忆**核查当晚短期日程并查出奥体多笔候选历史单据 + **长期程序化/经验记忆**跨场馆召回预热规则与多单消歧流程。	将多笔候选情景单据差异与消歧流程一并读入**短期工作记忆**，供下游向用户核实确认。

4.4 本章小结

本章通过滑动窗口切分与否定表达扣分保留了长句中局部短语的匹配精度，按长期语义记忆、长期情景记忆（含历史单据与阶段性临时事件）与长期程序化/经验记忆并行检索与二阶段关联补全，并通过状态过滤系数实现了正常单据优先、过期记录屏蔽与不适用经验剔除。

5 短期工作记忆的上下文拼装注入与长短期写回闭环

5.1 短期工作记忆的容量控制与长期检索结果结构化拼装

在 `CoALA` 架构中，**短期工作记忆（Working Memory）是连接外部长期记忆库与大模型推理核心的唯一枢纽**。如果把外部长期记忆库中的原始长对话或已失效的历史记录全部塞进短期工作记忆，一方面会超出上下文窗口容量上限，另一方面容易让下游模型混淆当前生效值与历史旧值。参考 `CoALA` 与 `Letta / MemGPT` (arXiv:2310.08560) 的工作记忆换页管理机制，系统按以下三项原则将检索出的三类长期记忆拼装进短期工作记忆（见图 5.1）：

- **常驻摘要与按需明细分离（控制短期工作记忆容量）**：短期工作记忆中仅常驻保留当前会话的活跃槽位状态、生效中（`active`）的长期语义映射/默认档位摘要以及未过期（未超 `TTL`）的情景临时偏好；长期情景记忆中的具体历史单据明细与长期程序化/经验记忆条目仅在当轮检索命中时按需换入短期工作记忆，且严禁混入标为 `superseded` 或 `expired` 的旧记录。
- **程序化/经验偏移参数预计算与时间算术自洽**：当检索命中长期程序化/经验记忆中的提前预热偏移规则（如 `start_time_offset_min = -20`）时，在读入短期工作记忆时直接基于基准起止时间算好调整后的推荐时间窗与总时长（保证 \(t_{\text{end}} - t_{\text{start}} = \text{duration}\)），避免下游大模型口算时间出错。
- **同地多笔候选情景单据与状态差异显式呈递**：当长期情景记忆在同一地点命中多笔不同规格或不同运行结果的单据（如奥体中心同时存在顺畅单 `NE-09 [good]` 与卡顿单 `NE-05 [bad]`）时，在短期工作记忆上下文中明确列出每笔候选单据的单号、规格差异与 `AppQuality` 运行结果状态，并附上程序化消歧流程供下游使用。



图 5.1：从三类长期记忆检索加载至短期工作记忆（Retrieval）并在执行后写回长期记忆（Learning）的闭环流程

先剔除已替代或已过期记录并完成程序化经验的时间偏移预计算，按结构化分块加载进短期工作记忆供当前轮推理；单据执行完毕后，再从短期工作记忆向三类长期记忆执行异步写回与更新。

5.2 工作记忆上下文文本示例与向三类长期记忆的写回闭环

清单 5.1 给出了两种典型场景下，短期工作记忆（Working Memory）整合当轮槽位状态与检索读入的三类长期记忆后，实际注入提示词的结构化上下文文本：

清单 5.1：短期工作记忆（整合当轮活跃槽位与三类长期记忆检索结果）的上下文拼装示例 source: memory_system/api.py & runtime/working_memory.py

```
# ================== 场景 A：跨场馆直播请求（三类长期记忆读入短期工作记忆，含预热偏移计算结果） ==================
[短期工作记忆 (Working Memory - Active Session Context)]:
  0. [当前会话活跃槽位状态 (Active Slots)]:
     - 当轮输入: "到工体了，19:30用小破站开播，别用卡顿那套，照奥体没卡那次办"
     - 已解析槽位: 地点=北京工人体育场, 原始请求开始时间=19:30
  1. [读入的长期记忆 ① - 语义记忆 (Semantic Memory)]:
     - 口语映射 (expression): "小破站开播" -> 应用=哔哩哔哩 (bilibili), 业务=上行开直播 (openlive)
     - 当前生效默认档位 (preferred_value, active): 分辨率=4K, 上行码率=25Mbps, 时延上限=20ms
  2. [读入的长期记忆 ② - 情景记忆 (Episodic Memory)]:
     - 阶段性临时偏好 (episodic_event_preference): 当前无未过期临时覆写项
     - 历史保障单据记录 (episodic_order_record):
       * 命中顺畅参考单据 NE-09 (2026-11-15, 北京奥体中心, 4K/20ms, 基准时长 120min, 运行结果 AppQuality=good)
       * 同地点异常单据 NE-05 (2026-11-09, 1080p 未预热, 运行结果 AppQuality=bad, 卡顿6次 -> 已降权排除)
  3. [读入的长期记忆 ③ - 程序化 / 经验记忆 (Procedural / Experiential Memory)]:
     - 命中规则 exp|stadium_crowd|openlive (适用场景: 大型演艺与体育聚集场馆 + 上行推流)
     - 调整动作与预计算时间窗: 在 19:30~21:30 (120min) 基础上提前 20min 开启 6G_NGC_UL_Slice 切片
     - 工作记忆合成后的推荐参数 (已核对 end - start == duration): 开始=19:10, 结束=21:30, 总时长=140min

# ================== 场景 B：模糊指代同地多单且存在日程重叠（工作记忆呈递多单差异与消歧流程） ==================
[短期工作记忆 (Working Memory - Active Session Context)]:
  0. [当前会话活跃槽位状态 (Active Slots)]:
     - 当轮输入: "19:30 准备用抖音看直播，按上周六在鸟巢没卡的那单办"
     - 待消解冲突项: ① 口头说『看直播』与所指代历史顺畅单『开直播』方向不一致；② 与当晚 19:00~20:00 预约单时段重叠
  1. [读入的长期记忆 ① - 语义记忆 (Semantic Memory)]:
     - 当前生效默认档位 (preferred_value, active): 抖音 (douyin) | 开直播 (openlive) | 4K / 20ms
  2. [读入的长期记忆 ② - 情景记忆 (Episodic Memory)]:
     - 当晚已生效预约日程: ORD_20260815_01 (19:00~20:00, 抖音-看直播, 与当轮 19:30 请求时段重叠)
     - 同地点历史保障单据记录 (episodic_order_record):
       * 候选单据 1: SN_20260808_A (鸟巢下午场, 15:00~17:00, 120min, 抖音-开直播, 4K/20ms, 运行结果 AppQuality=good)
       * 候选单据 2: SN_20260808_B (鸟巢晚高峰, 20:00~22:00, 120min, 抖音-开直播, 1080p/50ms, 运行结果 AppQuality=bad [禁用参考])
  3. [读入的长期记忆 ③ - 程序化 / 经验记忆 (Procedural / Experiential Memory)]:
     - 命中多单消歧流程 EXP_OVERLAPPING_ORDER_01: 存在同地多单或同应用预约重叠时，列明候选单规格与重叠时段核实确认
```

当会话终结且保障单据执行完毕后，系统触发从**短期工作记忆向三类长期记忆的写回闭环**（`Learning`）：① 将本次完整单据与网元实际运行结果（`AppQuality = good / bad` 及实测时延、丢包）作为新事件原样追加写入**长期情景记忆**（`episodic_order_record`）；② 将常规执行记录滑入中期候选池累加证据得分，跨越 W_{span} 且达 θ_{long} 时晋升写入**长期语义记忆（Semantic Memory）**；③ 若本次会话在短期工作记忆中经历了慢路径多轮澄清纠偏，则结合情景单据对比提炼新规则写入**长期程序化/经验记忆**；若本次单据直接复用了已有程序化/经验规则，则根据实际运行结果（参考 `arXiv:2505.16067`）更新该规则的成功/失败验证计数与置信度，随后清空释放当前短期工作记忆。

5.3 本章小结

本章明确了短期工作记忆与三类长期记忆之间的上下文拼装与写回闭环：通过常驻摘要与按需明细分离控制短期工作记忆长度，屏蔽已替代与已过期长期记录，在读入工作记忆时预计算经验时间偏移以保证起止时间与总时长一致，并在事后根据网元实际运行结果从短期工作记忆写回更新三类长期记忆。

6 完整样本示例与评测指标

6.1 跨周期业务样本串联示例（USER_001）

以技术主播用户 `USER_001` 在 30 天评测周期内的关键时间节点为例，串联展示**短期工作记忆**如何与**长期情景记忆、长期语义记忆、长期程序化/经验记忆**协同完成写入、晋升、隔离与跨场馆联合检索（见图 6.1 与表 6.1）。

```
flowchart LR
    T1["Day 09-10 · 写入长期情景记忆
奥体未预热发生拥塞 · 原样记入情景单据表"] --> T2["Day 12-15 · 提炼长期程序化/经验记忆
工作记忆多轮澄清 + 情景正反单据对比立规"]
    T2 --> T3["Day 16-20 · 情景 TTL 隔离与语义晋升
单日720p带TTL入情景库 · 90min晋升长期语义库"]
    T3 --> T4["Day 28 · 三类长期记忆读入工作记忆
前往工体中心开播 · 联合召回配齐全部参数"]
```

图 6.1：样本 `USER_001` 在 30 天周期内短期工作记忆与三类长期记忆的协同演化及跨场馆联合召回过程

长期情景记忆原样记录奥体正反单据并隔离单日临时 720p 变动，长期程序化/经验记忆从工作记忆慢路径澄清与情景单据对比中提炼场馆预热规则，长期语义记忆完成常驻档位升级，最终在第 28 天前往新场馆（工人体育场）时将三类长期记忆联合读入短期工作记忆配齐参数。

表 6.1：第 28 天工人体育场会话（`S-06`）在长短期记忆各环节的处理明细

处理步骤	输入内容	短期工作记忆与三类长期记忆内部交互结果	输出结果
1. 工作记忆接收与滑动窗口切分	`"到工体了，19:30用小破站开播，别用卡顿那套，照奥体没卡那次办"`	短期工作记忆接收本轮输入，分离否定子句 `"别用卡顿那套"`（标记降低长期情景记忆中 `bad` 异常单据排名）；切分正向窗口：`"到工体了"`、`"用小破站开播"`、`"照奥体没卡那次"`。	正向短语窗口向量组与异常单据降权标记。
2. 三类长期记忆并行检索（Retrieval）	短语窗口向量 + 当前日期 `Day 28`	· **长期语义记忆：**将 `"小破站开播"` 转为 `bilibili:openlive`，查得最新生效默认档位 `4K`（跳过 `superseded` 旧版）； · **长期情景记忆：**核查 Day 16 的临时 `720p` 记录已过期（`expired`）；在历史单据表中定位奥体顺畅单据 `NE-09 (120min, 4K, good)`，将卡顿单据 `NE-05 (bad)` 乘降权系数 γ_{bad} 排后； · **长期程序化/经验记忆：**“工体”归入大型演艺与体育聚集场馆且业务为上行推流，召回提前 20 分钟开启上行切片规则。	前 5 条结果内集齐长期语义、长期情景与长期程序化/经验全部所需记录（$\text{Hit}_{\text{all}}@5 = 1.0$）。
3. 读入短期工作记忆拼装与时间预计算	召回的三类长期记忆记录	读入短期工作记忆后，在奥体顺畅情景单据基准时间窗（`19:30~21:30, 120min`）上叠加程序化/经验规则偏移量（提前 `20min`），预计算开始时间为 `19:10`、结束时间为 `21:30`、总时长为 `140min`（核对 $21:30 - 19:10 = 140\text{min}$）。	短期工作记忆输出完整活跃上下文，支撑下游 1 轮直接生成准确保障单据，事后将新单据写回长期情景记忆。

6.2 萃取、检索与注入三阶段评测指标

为分别评估长短期记忆系统各环节的准确性，评测按**阶段 1：从短期工作记忆向长期记忆的萃取与更新（Learning）、阶段 2：三类长期记忆的混合检索与排序（Retrieval）、阶段 3：读入短期工作记忆后的下游应用与边界**三个阶段计算指标（见表 6.2）：

表 6.2：记忆系统三阶段评测指标与判分说明

评测阶段	比对对象	核心指标	判分规则与考察重点
阶段 1：长期记忆萃取与更新（Learning）	系统落盘长期记忆集 $\mathcal{N}$ 对比 Ground Truth 标准记忆状态快照 $\mathcal{M}$	1. 记忆抽取准确率与召回率（Extraction P / R / F1）	按“三类长期记忆类别 + 适用范围 + 核心槽位 + 生效状态 + 证据单号交集”比对；考察长周期混杂流中程序化/经验规则是否漏抽（防 `FN`），以及仅属于短期工作记忆的闲聊、假设试探、过短记录和单次偶发行为是否被误记为长期语义习惯（防 `FP`）。
		2. 偏好整合与状态更新准确率	考察长期语义记忆升级后旧记录是否正确写入失效时间 t_{invalid} 并标为 `superseded`，以及长期情景记忆中带有效期 `TTL` 的短期临时偏好到期后是否自动失效、未污染长期语义习惯。

评测阶段	比对对象	核心指标	判分规则与考察重点
阶段 2：长期记忆混合检索（Retrieval）	检索读入工作记忆的前 \(k\) 条结果集 \(\mathcal{Q}\) 对比 当轮所需长期证据集 \(\mathcal{P}\)	3. 多级召回率 \(\text{Recall}@k\) 与跨层全齐率 \(\text{Hit}_{\text{all}}@k\)	在多类记忆耦合请求中，检查长期语义映射、长期情景记忆中的未过期临时偏好与目标历史正常单据、以及长期程序化/经验规则是否在前 \(k\) 条结果内全部召回读入短期工作记忆。
		4. 优先级排序 \(\text{NDCG}@k\) 与负向排除准确率	检查当前生效的正常记录（\(\text{rel}=2\)）是否排在同地点卡顿异常情景单据、已替代旧语义档位以及不适用经验记录（\(\text{rel}=0\)）之前，并主动排除用户明确反感的负向 KQI 档位。
阶段 3：工作记忆应用与边界	工作记忆支撑下的下游决策输出 对比 Ground Truth 标准答案	5. 决策与约束满足率（含一票否决红线）	套用已过期旧档位、照搬长期情景记忆中卡顿异常单据参数或违规刺探隐私直接触发一票否决判 0 分（\(V_{\text{veto}}=1\)）；未踩红线前提下核算短期工作记忆跨轮槽位保持率、长期语义/情景槽位补全率与程序化/经验规则顺应准确率。
		6. 无关场景克制率 与未知事实拒答率	在日常闲聊或通用科普中克制不强行带入长期个人记忆；当用户指代长期情景记忆中不存在的虚假历史单据或未覆盖的陌生属性时，杜绝未校验参数生成并如实拒答或追问。

6.3 本章小结

本章以 30 天业务样本串联说明短期工作记忆与三类长期记忆（语义记忆、情景记忆、程序化/经验记忆）的演化与联合召回过程，并列出萃取、检索与下游应用三个阶段的评测指标。

7 总结与工程检查项

围绕 6G NGC 网络体验保障场景，本报告基于 `CoALA` 架构给出了**短期工作记忆（Working Memory）与三类长期记忆（语义记忆、情景记忆、程序化/经验记忆）分层管理**的记忆系统方案。工程实现与参数配置时需核对以下四项要求：

工程实现检查项

1. **长短期分层与分表字段边界**：**短期工作记忆**（`working_session_state`）仅驻留当前会话内存，维护当轮活跃槽位与检索读入的上下文，会话终结后释放；**长期语义记忆**的固定时段记录（`periodic_preference`）不重复保存画质与时延，基础默认档位（`preferred_value`）的短语向量文本中不带入具体地点词；**长期情景记忆**（`episodic_order_record`）逐笔原样保存历史单据与运行结果而不跨单合并；最小有效时长 \(T_{\min}\)、断流合并间隔 \(\Delta t_{\text{gap}}\)、晋升长期语义记忆的时间跨度 \(W_{\text{span}}\) 与得分阈值 \(\theta_{\text{long}}\) 统一放入配置文件管理。
2. **无效单据过滤与阶段性情景隔离**：不足最小有效时长 \(T_{\min}\) 的后台流量记录或中途取消的无效单据在写入长期情景记忆前剔除，间隔在 \(\Delta t_{\text{gap}}\) 内的同业务断流记录合并计算；带有效期 `TTL` 的差旅或单次临时改动只写入长期情景记忆（`episodic_event_preference`），到期自动转为 `expired`，严禁污染长期语义记忆。
3. **程序化/经验规则的正反单据证据链与排除范围**：每条长期程序化/经验记忆记录（`procedural_experience`）均需关联对应的长期情景记忆前序异常单据（`bad`）、短期工作记忆多轮澄清对话与调整后正常单据（`good`）编号，同时将触发条件归纳为通用场景类别，并写明非空的不适用业务列表（`scope.exclude`）。
4. **Retrieval 读入工作记忆与 Learning 写回长期记忆闭环**：检索读入短期工作记忆前自动过滤 `superseded` 与 `expired` 记录，叠加程序化经验提前预热偏移后在工作记忆拼装层核对 \(t_{\text{end}} - t_{\text{start}} = \text{duration}\)；单据执行完毕后根据网元实际运行结果从短期工作记忆异步追加长期情景单据并更新程序化/经验规则的验证计数与置信度。