故事线两层因子构造、双流样本合成自检与全流程评测技术路线报告

—— 面向联接 Agent（网元单据 + 自然语言对话）的合成数据与评测体系设计

2026 年 11 月

报告摘要：围绕联接 Agent（移动网络体验保障，包含网元事后上报的保障单据与用户主动发起的自然语言对话）场景，系统整理故事线两层正交因子设计、四类记忆构建映射、六步构造与多源融合方法、2024–2026 记忆与意图交互评测基准调研、双流完整样本实例（`USER_001` 30 天 21 节点穿插样本与 `USER_002` 4 周 12 事件并发/双模式对照样本）、合成数据集六层自检审查方案，以及“萃取 → 召回 → 决策”三阶段全流程评测指标体系。

核心合并范围：完整保留原报告第 1~3 章全部正交因子表、四类记忆构建映射表（1.4 节）、跨 3 个月演进示例（1.5 节）、22+ 篇基准拆解与 18 类变体/16 对交互动作矩阵、三阶段 6 项核心指标体系，并有机融入三层可见性边界、四类时间区分、关键事件前后状态表、六步逐字段融合顺序、两套完整落盘样本实例及合成数据 Ground Truth 充分最小性自检方案。

章节摘要

1. 故事线的正交因子方法论（排布层与内容层解耦设计） — 第一层排布因子与第二层内容因子解耦、三层可见性与四类时间区分、四类记忆（语义/情景/工作/经验及多记忆耦合）构建因子完整映射表、六步构造流程与多源逐字段融合顺序及跨 3 个月示例

2. 记忆与意图交互评测数据集调研 — 五大方向代表性基准拆解、语法/语义/语用 18 类变体盲区、多轮会话“用户 ⇄ Agent” 16 对正交动作映射与 6 类多轮组合模式

3. 从故事线到单据与对话样本的完整构造实例 — 实例一：巡回技术讲者 30 天 21 节点双流穿插样本（`USER_001` 全套单据/对话 JSON 与 Ground Truth 快照）；实例二：现场运维人员 4 周 12 事件并发冲突状态表推演与 “仅单据”与“单据+对话”双输入对照（`USER_002`）

4. 合成评测数据集自检与质量审查方案 — 数据自检与 Agent 评测职责分离、六层审查流水线、单据确定性约束与截止时间可见性 5 项缺陷率、Ground Truth 证据充分性（Sufficiency）与最小性（Minimality）校准及 8 类受控扰动一致性测试（Metamorphic Testing）

5. Agent 全流程评测指标方法论（萃取 → 召回 → 决策） — 三阶段 6 项核心指标与 12 个细分子项拆解、子集可测性分母与多等价充分证据集 \(\mathcal{E}^*\)、\(\text{NDCG}@k\) 与一票否决决策算式

目录

1 故事线的正交因子方法论（排布层与内容层解耦设计） Ch.1
- 1.1 故事线两层解耦设计思路（含三层可见性边界与四类时间区分） 1.1
- 1.2 第一层：故事线排布因子（表 1.1） 1.2
- 1.3 第二层：故事线内容因子（表 1.2） 1.3
- 1.4 四类记忆用哪些故事线因子构造及对应评测内容（表 1.3 完整版） 1.4
- 1.5 两层组合规则、六步构造流程、多源六步融合顺序与跨 3 个月完整示例（表 1.4、表 1.5） 1.5
- 1.6 本章小结与拓展阅读 1.6

2 记忆与意图交互评测数据集调研 Ch.2
- 2.1 记忆、意图与多轮交互评测基准拆解（表 2.1） 2.1
- 2.2 意图理解数据集在“语法 · 语义 · 语用”三层 18 类变体上的拆解与现有盲区（表 2.2） 2.2
- 2.3 多轮会话“用户 ⇄ Agent” 16 对正交动作映射与 6 类多轮组合模式（表 2.3、表 2.4） 2.3
- 2.4 本章小结与拓展阅读 2.4

3 从故事线到单据与对话样本的完整构造实例 Ch.3
- 3.1 实例一：巡回技术讲者 30 天 21 节点双流穿插完整样本（`USER_001`） 3.1
- 3.2 实例二：现场运维人员 4 周 12 事件状态表推演与 “仅单据”与“单据+对话”双输入对照（`USER_002` 现场运维工程师） 3.2

4 合成评测数据集自检与质量审查方案 Ch.4
- 4.1 数据集自检与 Agent 评测的职责分离及六层审查流水线 4.1
- 4.2 单据确定性约束、状态图回放与截止时间可见性审查（表 4.1） 4.2
- 4.3 Ground Truth 证据充分性（Sufficiency）、最小性（Minimality）与受控扰动一致性测试（Metamorphic Testing）（表 4.2） 4.3

5 Agent 全流程评测指标方法论（萃取 → 召回 → 决策） Ch.5
- 5.1 三阶段 6 项核心指标与 12 个细粒度子项拆解（表 5.1） 5.1
- 5.2 核心指标的判分逻辑与精简算式表达 5.2
- 5.3 本章小结与拓展阅读 5.3

1 故事线的正交因子方法论（排布层与内容层解耦设计）

1.1 故事线两层解耦设计思路

面向移动网络体验保障（联接 Agent）的长期记忆与多轮意图评测，需要**构造跨度数周至数月、包含自然语言对话与网元单据的长周期测试数据**，覆盖记忆萃取（偏好抽取、合并更新、分场景组织、画像生成、噪声抑制）与记忆检索（直接、排序、条件、排除、组合、缺失拒答）的各项测试点。

然而，传统的固定剧本模板或单层平铺变量表在实际构造中面临三方面局限：其一，**时间线排布与事件内容耦合**，调整干扰密度或主支线穿插方式时会影响单点业务内容；其二，**同层因子之间存在条件依赖或跨层重复**，例如将受时间窗口约束的“事件规模”与“时间跨度”并列，将仅在存在支线时生效的“支线归宿”与“事件线结构”并列，或在排布层与内容层重复定义“偏好演进”与“闲聊干扰”；其三，**边界与噪声场景覆盖不足**，缺少对负向排斥偏好、短期临时偏好过期、未提及属性拒答边界以及闲聊、试探、情绪发泄、单次偶发等非偏好噪声的控制参数。

为此，参考 `PersonaMem-v3`、`LoCoMo`、`DynamicMem`、`MemoryAgentBench` 与 `LongMemEval` 的主流做法，我们将故事线生成解耦为**排布层与内容层**两层结构（图 1）：

- **第一层定排布（时间线与多任务穿插结构）：**控制整条时间线的跨度、事件规模与疏密分布、主支线任务的穿插关系、跨期演化趋势以及测试点编排。具体而言，**当用户诉求包含主线与支线交织（或单轮复合意图）时，系统在入口处先通过意图拆解（Intent Decomposition）将其拆分为彼此独立的业务任务（`task_id`）**；每个任务映射至对应的业务场景（`scenario_id`），时间轴上的主支线交织即体现为不同业务任务之间的交替执行、同窗并发或中断恢复。
- **第二层定内容（业务画像属性与分场景独立记忆）：**按“**用户级 → 业务场景/任务级 → 节点级**”三级粒度，覆盖**用户身份与资产、应用与业务行为、时空轨迹与流量、网络环境与 KQI 偏好、信息来源与噪声干扰、多轮交互与反馈纠正**六个维度。在此基础上，**每个用户按不同的业务场景（`scenario_id`）各自维护一份独立的场景记忆分片（Scenario-Scoped Memory）**；与此同时，由于单个用户的日常活动范围有限，**每个用户并不一定在所有业务场景下都存在记忆（Sparse Scenario Coverage）**——系统仅在该用户实际发生并达到沉淀门限的业务场景下建立记忆分片，未涉及的业务场景则自然留空（`null`）。

工程落地边界补充：三层信息可见性隔离与四类时间维度区分

1. 三层信息可见性边界隔离（防止作者上帝视角泄漏）：

- **故事层（作者设定真值，Ground-Truth Story State）：**包含人物真实职业、家庭借用关系、活动线真实业务目的及细粒度房间状态，仅供数据生成器与标准答案推导使用；
- **观测层（Agent 物理可见记录，Observable Records）：**严格遵循真实系统触发机制——**网元单据均为单次网络保障任务结束后的事后统计上报**（仅含起止时间、基站小区标识 `cell_id`、应用名、吞吐量、时延抖动与卡顿异常记录，不含室内房间名或主观借用原因），**自然语言对话（Sessions）仅在用户主动发起咨询、报障、改期或预订时稀疏产生**；
- **评测层（测试截止点可答范围，Cutoff-Valid Scope）：**给定评测截止时刻 t_{cut}，Ground Truth 答案仅允许依赖到达时间满足 $t_{\text{arrive}} \le t_{\text{cut}}$ 的已观测记录推导；任何仅在作者设定中存在但截止前未露出到观测层的属性均归入“当前未知（需拒答或主动澄清）”。

2. 四类时间维度显式区分：每条记录显式区分**事件实际发生时间 t_{event}**、**未来预约计划时间 t_{plan}**、**单据统计窗口 $[t_{\text{start}}, t_{\text{end}}]$** 与 **单据到达/可见时间 t_{arrive}**。当网元单据存在批处理延迟上报（$t_{\text{arrive}} > t_{\text{end}}$）或乱序补报时，处于 $[t_{\text{end}}, t_{\text{arrive}}]$ 区间内的测试点严禁引用尚未到达的单据。

3. 入口意图拆解（Intent Decomposition）与分业务场景稀疏记忆管理：① **先拆解任务再路由场景**：面对主支线交织或复合诉求，系统在入口处先通过意图拆解将其拆分为独立的业务任务（`task_id`），如基地固定直播任务、高速大巴移动会议任务、高密场馆赛事推流任务、播前视频对词任务），每个任务各自具备独立的终端、应用与 KQI 目标，避免不同任务的参数在同一槽位表内相互覆盖；② **每个业务场景各自存一份记忆且允许场景留空**：每个用户（`user_id`）名下按业务场景（`scenario_id`）分别存储各自的长期记忆（语义记忆、情景单据记录与程序化/经验记忆）。然而，具体到单个用户，其业务场景覆盖是稀疏的（即**每个用户不一定每个业务场景都存在**）——未发生过或仅偶发 1 次未达标的业务场景在该用户名下保持为空（`null`）；反之，当测试请求落入该用户尚未建档的陌生业务场景时，系统不得跨场景借用其他任务的参数硬套，而应如实拒答或转入慢路径追问。

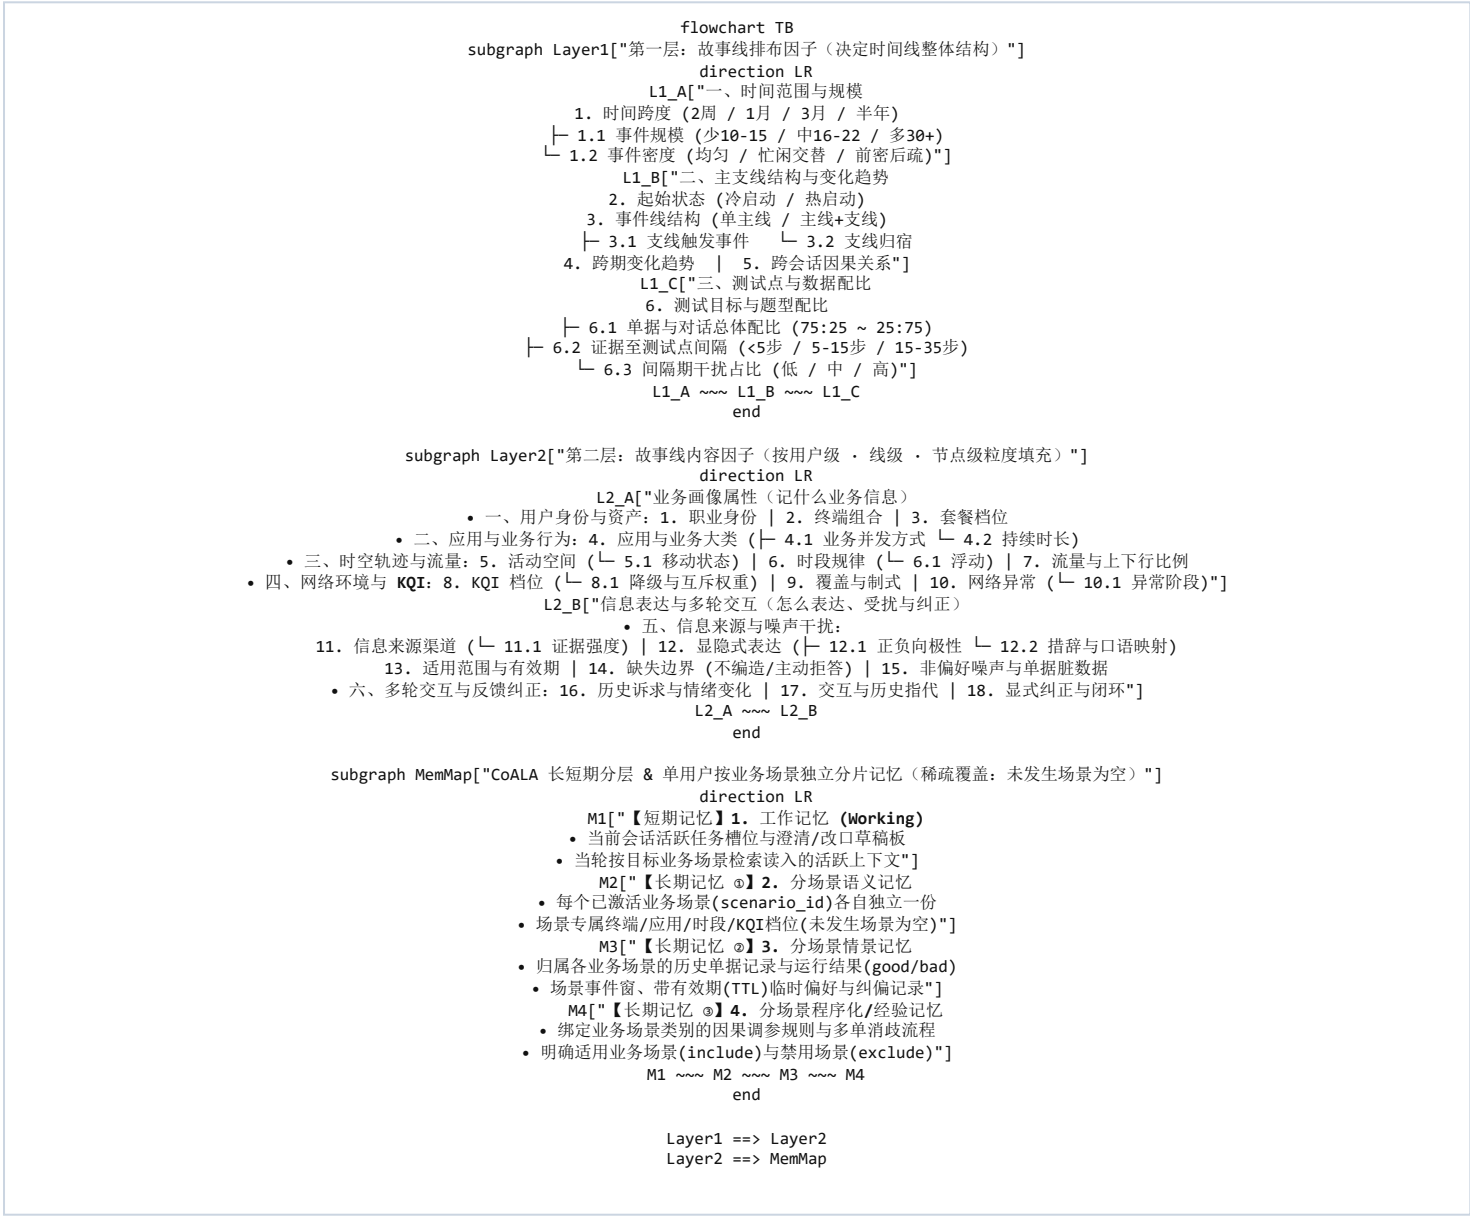


图 1：故事线第一层排布因子与第二层内容因子的分层解耦及四类记忆对应关系图。

上方第一层决定时间跨度、主支线结构、跨期变化趋势与测试点安排；中间第二层将“业务画像属性（身份、应用、时空、网络 KQI）”与“信息表达及多轮交互（双源一致性、显隐式、正负向、分场景/临时有效期、缺失拒答边界、非偏好噪声、多轮指代与纠正）”分开定义；下方说明各因子如何分别构造 CoALA 架构下的短期工作记忆（Working Memory）与三类长期记忆（语义记忆、情景记忆、程序化/经验记忆）。

1.2 第一层：故事线排布因子

第一层排布因子围绕**时间范围与规模、主支线结构与变化趋势、测试点与数据配比**三个维度定义时间线的整体骨架（表 1.1）。其中存在条件约束的维度采用主从结构：先由 `1. 时间跨度` 确定总时间窗口，再在其下采样 `1.1 事件规模` 与 `1.2 事件密度`；先由 `3. 事件线结构` 确定是否包含支线，当存在支线时再采样 `3.1 支线触发事件` 与 `3.2 支线归宿`；先由 `6. 测试目标与题型配比` 确定考核重点，再配置 `6.1 单据与对话总体配比`、`6.2 证据至测试点间隔` 与 `6.3 间隔期干扰占比`。

表 1.1：第一层故事线排布因子定义与学术参考

因子分组	排布因子（含主从子因子）	可取值范围（MECE 切分）	决定时间线结构的什么特征	学术界参考做法
一、时间范围与规模	**1. 时间跨度**	2 周 / 1 个月 / 3 个月 / 半年（~15 个月）	决定整条故事线的物理时间窗口上限、可容纳的周期规律跨度及长期记忆保持周期	PersonaMem-v3：30 天；DynamicMem：15 个月
	├─ **1.1 事件规模**	少（10~15 个节点）/ 中（16~22 个节点）/ 多（30 个节点以上）	在父因子“时间跨度”范围内，决定总事件节点数与上下文累积长度（避免短跨度配超大节点数冲突）	LoCoMo：最多 35 会话；LongMemEval：多档规模
	└─ **1.2 事件密度**	均匀分布 / 忙闲交替 / 前密后疏 / 前疏后密	在给定时间跨度与事件规模后，控制事件节点在时间轴上的整体疏密走势	LAMP、EasyTPP 时序点过程
二、主支线结构与变化趋势	**2. 起始状态**	冷启动（全新用户，历史记忆全空）/ 热启动（已预置前一周期历史记忆快照）	决定首轮交互时系统处于零记录状态（直接考核未知拒答边界）还是增量演化状态	PersonaMem-v1/v2；MemoryAgentBench
	3. 主支线意图拆解与多任务穿插结构	**前期意图拆解即拆分为独立任务（`task_id`）：**单主线任务 / 主线任务 + 1 条支线任务 / 主线任务 + 多条支线任务交织； **跨任务穿插五类关系：**独立交替穿插 / 主次支持（如播前对词任务支撑主线直播任务）/ 同窗资源竞争（两任务同时段争抢热点上行带宽）/ 打断与恢复 / 阶段角色转移	在前期意图拆解阶段将主线与支线拆解为不同业务任务（绑定各自 `scenario_id`），决定多任务穿插方式与分场景记忆边界	RHELM：日常主线穿插阶段支线
	├─ **3.1 支线触发事件**	搬家或入职入学 / 法定节假日 / 大型赛事或展会 / 异地出差或旅行 / 突发恶劣天气（仅含支线时生效）	在时间线上注入外部环境或生命阶段突变窗口，驱动分场景存储与跨事件推理	LoCoMo 全局事件图谱；PERMA 事件驱动时间线
	└─ **3.2 支线归宿**	结束后回到原主线（单次偶发或临时偏好过期回退）/ 转为新主线（永久迁移）/ 周期性复现	决定支线事件是作为短期偶发事件回退，还是沉淀为独立的长期常驻场景习惯	PersonaMem-v3：偶发回退 与 新习惯接替
	4. 跨期变化趋势	平稳保持型（跨会话同义多表述重复）/ 单次迁移覆盖型（升档或降档、换机、迁居，新版 `active` 覆盖旧版 `superseded/obsolete`）/ 逐渐弃用型 / 多次波动与纠正后改回型	统一控制画像属性在时间线上的形成与版本演化轨迹（检验跨会话同义合并去重、新旧覆盖更新、旧版本过期归档及多次纠正时序排序）	PersonaMem-v3 四类轨迹；DynamicMem 状态演化；PERMA 时间线
	5. 跨会话因果关系	无 / 1 条短链（首次缺参或冲突 → 澄清/纠正 → 沉淀经验）/ 1 条完整闭环（沉淀经验后再次遇同类请求 → 快路径一次闭环）/ 多条交叉	控制跨会话的前因后果闭环，专门定义经验记忆从何处产生、在何处验证快路径加速效果	LoCoMo 事件因果图；MemoryAgentBench TTL
三、测试点与数据配比	**6. 测试目标与题型配比**	**萃取侧（画像形成过程）：**偏好抽取 / 偏好整合 / 偏好组织 / 画像生成 / 噪声抑制； **检索侧：**直接召回 → 排序召回 → 条件召回 → 排除召回 → 组合召回 → 缺失召回（两线独立配比评测）	将“画像形成过程（零碎、显/隐式、长短程、分场景）”与“检索类型（直接找 → 排序 → 加场景 → 加负向约束 → 跨维组合 → 未知拒答）”解耦编排	LongMemEval（索引/检索分离）；MemoryAgentBench（AR/TTL/LRU/CR）；LoCoMo
	├─ **6.1 单据与对话总体配比**	**同故事骨架双模式配对：**仅网元单据输入 与 网元单据+自然语言对话混合输入；在混合输入下支持单据为主（`75 : 25`）/ 双源均衡（`50 : 50`）/ 对话为主（`25 : 75`）	在故事线全局层面控制记忆证据主要分布在网元单据还是自然语言对话中	PersonaMem-v3：95% 行为流 + 5% 对话
	├─ **6.2 证据至测试点间隔**	短间隔（`< 5 步`）/ 中间隔（`5~15 步`）/ 长间隔（`15~35 步`）；**同步按四维距离核算：**日历时间差 Δt、跨记录数 N_{rec}、跨关键事件数 N_{evt} 与间隔 token 数	控制关键记忆写入节点与下游测试提问点之间的跨会话步数距离	LongMemEval：证据与提问点距离可调
	└─ **6.3 间隔期干扰占比**	低干扰（`< 20%`）/ 中干扰（`20%~50%`）/ 高干扰（`> 50%`）	控制证据节点与测试点之间混入非偏好背景事件的比例，考核长程抗遗忘与抗干扰能力	LongMemEval 背景干扰会话占比

1.3 第二层：故事线内容因子

在第一层时间线结构确定后，第二层内容因子按**“用户级（整条故事线取一次）→ 线级（主线、支线各取一次）→ 节点级（每个事件节点独立取）”**三种粒度填入具体属性（表 1.2）：

- **业务画像属性（一至四类，决定记什么业务信息）：**覆盖**用户身份与资产、应用与业务行为、时空轨迹与流量、网络环境与 KQI 偏好**四个方面。其中应用下的并发方式与持续时长、活动空间下的物理移动状态、活跃时段下的时间窗浮动幅度、KQI 下的降级容忍与互斥权重、以及网络异常下的发生阶段均作为对应主因子的子因子采样（如无网络异常时不采样异常发生阶段）。
- **信息表达与多轮交互（五至六类，决定怎么表达、受扰与纠正）：**第五类控制**信息来源渠道与双源冲突（含证据强度与置信度）、显隐式表达方式（含正负向极性与口语映射）、偏好作用域与临时有效期、信息缺失边界、以及非偏好噪声与单据脏数据**；第六类控制**历史诉求与情绪变化、跨轮历史单据指代与显式纠正闭环**。

表 1.2：第二层故事线内容因子与三级取值粒度表

因子类别	内容因子（含主从子因子）	可取值范围（含评测覆盖特征）	取值粒度	决定的故事线属性与支撑的评测点
一、用户身份与资产 （对应身份归属域）	**1. 职业与角色身份**	游戏主播 / 外卖骑手 / 网约车司机 / 程序员 / 教师 / 医生 / 护士 / 学生 / 短视频创作者 / 电商主播 / 证券交易员 / 健身教练 / 货	用户	决定用户的基础作息、主力应用与上下行网络诉求基线（支撑显式声明抽取、

因子类别	内容因子（含主从子因子）	可取值范围（含评测覆盖特征）	取值粒度	决定的故事线属性与支撑的评测点
		车司机 / 快递员 / 房产中介 / 自媒体UP主 / 自由撰稿人 / 电竞选手 / 记者 / 银行柜员等		从大上行流量隐式推断身份及“职业+场景”跨维组合召回）
	2. 终端设备与指纹状态	移动终端类型（华为、苹果、小米、荣耀、OPPO/vivo、三星等 5G 手机 + 蜂窝平板、5G 插卡笔记本、智能车机、蜂窝可穿戴设备）、**主备关系**（`1主1备` / `1主多备` / 双主并重 / 无主备）、**人机映射关系**（`专人专机` / `家庭成员临时借用如孩子借手机看动画或打游戏` / `新旧换机接替`）、**设备指纹状态**（`单指纹稳定` / `多指纹切换` / `跨周重定向` / `无指纹或已清除`）	用户（可跨期换机）	决定网元单据中的终端与指纹记录（支撑主从设备优先级排序、换机覆盖更新、指纹记录直接召回与无指纹/多指纹无法确认时的缺失拒答）
	3. 套餐档位与资费约束	移动流量档位（`30GB~200GB`）+ 5G/5G-A 专网权益档位（标准档/黄金档/钻石VIP档）+ 移动附加服务包（上行直播加速包/移动电竞低时延包/高铁商旅保障包/定向免流包）、**资费倾向（低价敏感 与 品质优先；升档与降档）**	用户（可跨期升降档）	决定物理签约速率上限与资费边界（支撑新旧套餐排序、排除低于现档方案、排除高延迟低价档及夜间限速/时段溢价不划算包）
二、应用与业务行为 （对应应用行为域）	**4. 目标应用与业务大类**	**应用层级结构：**业务大类（视频、语音、IM、游戏、直播、办公、下载、网页）→ 细分场景子类（长视频/短视频、手游/端游/云游戏/电竞档、视频会议/远程办公/云桌面/在线文档）→ 具体应用；配 **占比分布**（`Top3 集中` / `Top5 / Top10` / `并列占比长尾均摊`）与**同 APP 不同用途区分（如抖音开播 与 刷短视频、微信聊天 与 开播前视频连线对词）**	线	决定核心业务负载、应用至大类的层级归档及使用占比分布（支撑主力应用与业务构成按占比排序、画像去重只留 Top 项、以及排除不用/零占比子应用服务包）
	├── **4.1 业务并发方式**	单业务独立运行 / 同类双业务并发（如 B站 与 爱奇艺同开竞争）/ 主辅异类业务并发（如“前台腾讯会议或游戏 + 后台 Steam 大文件下载”）	节点	决定单次事件节点是否出现多业务争抢带宽，触发分流优先级决策与复合多意图拆解
	└── **4.2 单次持续时长**	短时（`15~45min`）/ 中时（`60~120min`）/ 长时（`150~240min`），在区间内连续随机采样	线（节点随机浮动）	保证网元单据的业务时长具备真实多分布特征（杜绝固定时长硬编码，并与 1~8min 噪声短时单据拉开差距）
三、时空轨迹与流量 （对应时空轨迹域）	**5. 活动场景空间**	**场景层级：**标准场景（家、办公、学校、通勤、出差、旅行、户外、应急、游戏厅、医院）及下属微场景（如电梯/地下室/郊区/酒店/商场/短差/长差/高铁/跨境）→ 归入驻留/移动大场景；**区分位置可见粒度（网元单据仅见基站小区级标识 `cell_id`，对话才见“书房/会议室”等细粒度位置）**	线	决定事件发生的空间位置与多级场景归属（支撑分场景独立存储不串味、当前场景优先于通用偏好排序、带场景条件召回与未记录场景拒答）
	└── **5.1 物理移动状态**	固定静止 / 步行移动 / 城市车载移动（早晚高峰通勤 与 长途通勤）/ 高速公路或高铁跨区高速移动	节点	决定网元单据中是否伴随高频基站小区切换（Handover）与移动性断流风险
	6. 活跃时段与周期规律	显式时段（清晨 5-8、上午 8-12、午间 12-14、下午 14-18、晚高峰 19-23、凌晨 0-3）+ 隐式作息时段（下班后→晚高峰、睡前→凌晨、午休→午间、通勤→早晚峰、摸鱼→上午、加班→深夜）；配 **峰型分布**（`单峰` / `双峰` / `三峰` / `零散均匀`）与**“时段→日→周（工作日/周末/节假日）→季”多级归档**	线	决定业务在时间轴上的分布规律与多峰排序（支撑零散时段归并为峰值段、多活跃时段按活跃度排序、工作日/周末/节假日条件过滤与免打扰时段排除）
	└── **6.1 时间窗浮动幅度**	准点守时（`±2min`）/ 小幅自然浮动（`±10min`）/ 大幅弹性浮动（`±30min`）	线	控制网元单据起止时间戳的抖动方差，调节从行为流中挖掘周期规律的算法难度
	7. 流量消耗与上下行比例	日均流量档位（微量 `<100MB`、常规 `100M~1G`、大流量 `1~5G`、超大 `>5G`）、上下行比例（下行主导消费型 `1:9`、上下行均衡型、上行主导创作型）、月末流量余量状态（充裕 与 月底流量吃紧）	线	决定网元单据中的上下行吞吐量比例与流量约束（支撑流量量级与上下行比例直接召回、以及“月底流量紧+打游戏卡”保时延省流组合推理）
四、网络环境与 KQI 偏好 （对应网络体验与意图偏好域）	**8. 核心 KQI 与画质档位要求**	时延（`≤30ms / ≤50ms / ≤100ms / ≤200ms / 不敏感`）、丢包（`≤0.01% / ≤0.1% / ≤0.5% / <1% / 不敏感`）、移动上下行速率（下行 `≥50Mbps ~ ≥500Mbps`、上行 `≥10Mbps ~ ≥100Mbps`）、抖动（`≤5ms`）、**画质分辨率**（`360p / 480p / 720p / 1080p / 4K~8K HDR`）；**严格区分下行侧与上行侧 KQI（上行时延/上行带宽/上行丢包）**及**“单指标→场景级→全局”层级结构**	线	定义各场景下的核心网络质量底线（支撑 KQI 多维完整性、上行/下行独立抽取、仅提下行问上行时的缺失拒答、以及高延迟/高丢包方案排除）
	└── **8.1 降级容忍与互斥权重**	**多 KQI 偏好强度排序（如** `时延 > 丢包 > 带宽`**）**/ 互斥指标冲突取舍（`带宽 与 时延`、`时延 与 丢包`、`带宽 与 抖动`）/ **KQI 三档门限（理想目标档 / 可降级接受档 / 不可接受底线）**；严格区分**应用被动自适应降级（因弱网或并发抢占被迫降至 540p，用户真实高画质偏好未变）**与**用户主动调低档位**	线	决定多指标并存时的优先级排序（支撑网络硬性要求排序召回、互斥 KQI 不可兼得时的权重推理及禁用降级档位排除）
	9. 覆盖环境、制式与切片偏好	无线覆盖（稳定覆盖 / 一般覆盖 / 边缘弱覆盖 / 重度弱覆盖）、网络制式（`5G 速率优先` / `4G 稳定优先` / `混合自适应`，含 `SA 与 NSA`）、**网络切片偏好**（`eMBB 高带宽切片` / `URLLC 低时延切片` / `S-NSSAI 切片 ID` / `未知未存储`）	线	决定底层无线信道条件、制式与切片选择（支撑弱覆盖应急预期召回、排除不喜制式及对应切片方案、以及切片 ID 未存储时的缺失拒答）
	10. 网络异常与卡顿优先级	无异常 / **业务卡顿（游戏、直播、视频、会议、通话；支持单类发生或多类卡顿齐现并按影响程度排序，如** `游戏卡顿 > 直播 > 会议 > 视频`**）** / 切换断流 / 同地多单冲突	节点	决定当次节点是否触发体验劣化及多类卡顿并存时的处置优先级（支撑卡顿 KQI 偏好召回、多类卡顿优先处理排序与综合排障组合推理）
	└── **10.1 异常发生阶段**	开场前期拥塞 / 整场持续劣化 / 短暂波动（仅当 `10. 网络异常 ≠ 无异常` 时生效）	节点	决定针对性的保障参数调整动作（如开场前期拥塞对应“提前 20min 预热切片”经验规则）
五、信息来源与噪声干扰 （控制怎么表达、生效与抗干扰）	**11. 信息来源渠道与双源冲突**	**来源标注**（`会话声明 sessions` / `网元单据实测记录 inferred` / `行为推断 corrections`）、**观测选择偏差（日常顺畅体验大多沉默无对话，仅严重卡顿或重要场合才主动发起对话）**、**双源关系（单源体现 / 声明与实测一致 / 声明 // 实测并列保留且各注来源 / 声明与实测矛盾冲突［如说对网速无要求但实测高流量、说早睡但凌晨活跃、说爱玩原神但占比仅 1%］）**	节点	控制信息来源与冲突仲裁策略（检验分源标注准确性、检索侧实测优先于口头声明排序、以及冲突时体验/时段取实测并将矛盾声明记入 `conflict_log` 或降权为 `weak`）
	└── **11.1 证据强度与置信度**	强证据高置信（`strong`：网元单据高频实测或跨会话多次重申）/ 弱证据低置信（`weak`：单次口头自称、间接暗示或占比 `1%` 偶现；按场景与时间分别标注置信度）	线 / 节点	决定生成画像条目的置信度等级（检验画像按场景/时间标注 `strong/weak` 置信度，以及检索侧高置信优先于低置信排序）

因子类别	内容因子（含主从子因子）	可取值范围（含评测覆盖特征）	取值粒度	决定的故事线属性与支撑的评测点
	12. 显隐式表达方式	显式直接陈述（直接说出身份/套餐/场景/KQI/诉求）/ 隐式行为推断（从持续大上行流量推断直播创作者、从高频打开推断主力应用、从“下班后/睡前”推断活跃时段、从反复抱怨“又卡了/转圈”推断时延与抖动偏好、从叹气推断不满情绪）	节点	决定记忆萃取需走直接槽位提取还是跨多轮/多单据统计归纳（全面覆盖各画像维度的显式陈述识别与隐式行为推断）
	├─ 12.1 偏好极性方向	正向偏好（喜欢某应用/要求某档位/满意评价）/ 负向排斥禁忌（别推贵的、最烦某 App 弹窗广告、晚上别推广告打扰、最讨厌高延迟、出差别限速、不要降画质、强烈不满投诉）	节点	控制偏好的正负符号（检验萃取侧正负向极性不混淆，以及检索侧主动避开反感选项与负向口语档位的“排除召回”）
	└─ 12.2 措辞与口语映射	标准带单位数值 / **易混淆数值与对象消歧（“129块100G流量包”取 100G 非 129、“延迟低于30”取 `≤30ms` 非 30s/30G、“八点到十二点”消歧为 `20:00-24:00`、“投诉5G加速包非月租话费”）** / 应用别名归一（“小破站/哔哩”→Bilibili）/ **口语体感词映射（高清→1080p、别卡→100ms、流畅→360p、要快→高带宽、不卡就行→200ms、极致丝滑→30ms）**	用户 / 节点	控制单据标准名称与用户口语之间的差异（检验数值单位精准抽取不张冠李戴、跨会话同义多措辞合并去重与口语档位正/负向映射）
	13. 偏好作用域与有效期	全局常驻通用 / 限定特定场景空间（家 与 出差 与 办公 与 校园独立存储）/ **短期临时偏好（本周、本月、假期、出差期间、特殊事件期）、 有效期状态（** `全部未过期 / 临近过期 / 已过期 / 未过期+已过期混合` **）**	线 / 节点	界定记忆生效的时空边界（支撑未过期排在已过期前、带场景条件返回对应偏好、无场景条件返回通用偏好、以及临时偏好全部过期时主动说明而不返回旧值）
	14. 信息完备度与缺失边界	画像属性齐备 / **典型缺失形态：① 冷启动全新用户（对话与单据全空）、② 仅有会话无结论或仅有单据无身份标签、③ 单侧或单项 KQI 未提及（仅提下行未提上行、未提抖动、缺切片** `S-NSSAI` **）、④ 特定场景未记录（如校园/应急/医院/出国未记录）、⑤ 应用从未出现或仅出现 1 次无占比、⑥ 活跃样本不足 1 周或被截断**	用户 / 线	构造“已知与未知”的边界（检验画像生成阶段对未提及身份/应用/时段/抖动/场景/诉求绝不编造，以及检索侧缺失召回如实拒答并引导补充）
	15. 非偏好噪声与单据脏数据	无噪声 / **对话侧非偏好噪声：① 日常寒暄闲聊（天气/八卦/刷到好玩的不抽偏好）、② 假设性试探（“如果升级5G-A钻石包…”“要不试试原神”“以后周末可能多户外开播”标待确认不入库）、③ 纯情绪发泄（“烦死了”“这网真烂”只记入** `feedback_signal` **不抽成稳定偏好）、④ 单次偶发行为（单次优惠购卡/单次大下载/单次熬夜加班/单次卡顿/单次出差/单次查话费不固化为长期习惯）** / 单据侧 1~8min 短时单据与无效单据	节点	模拟真实对话与网管日志中的高频干扰（全面检验记忆萃取的噪声抑制能力，杜绝把闲聊、假设、情绪气话与一次性行为写入稳定画像）
六、多轮交互与反馈纠正（对应反馈记忆域与慢路径交互）	**16. 历史诉求与情绪轨迹**	主动诉求（提速、换套餐、改画质、查账单、解除限速、补流量；含提出时间、解决时间及 `active` 未完结 与 `closed` 已完结/已停用状态）、 情绪变化轨迹（满意、中性、不满、强烈不满投诉、事后改观；含全局整体评价汇总）	节点	记录用户与系统的历史服务交互记录（支撑诉求多轮重申合并、新诉求关闭旧诉求、带历史投诉条件召回、整体评价汇总及“情绪+诉求+偏好”组合推理）
	17. 会话交互与历史指代方式	一次说清（快路径）/ 缺参或歧义需主动追问澄清（慢路径）/ 跨轮指代历史单据（按时间“上周三那次”、按特征“没卡那次”、按地点别名“老地方”、按排除“不是晚上那场”）/ 单轮复合多意图	节点	决定当轮对话走快路径还是慢路径，以及检索器如何通过多跳条件定位历史情景单据
	18. 显式纠正与闭环结果	无纠正一次闭环 / 澄清后达成 / **用户显式纠正系统记忆偏差（涵盖时段纠正、档位纠正、应用纠正、身份纠正、来源纠正；含单次纠正、多次连续纠正与纠正后又改回等时序）** / 撤销原诉求或取消定向包；**经验沉淀双层分级（区分“用户已确认交互与保障安排［后续直接执行］”与“网络物理根因待验证假设［后续优先排查］”）**	节点	检验系统被用户纠正后能否立即覆写旧值、标注 `source=corrections`、按最新纠正时序优先排序、并在推荐时主动排除已纠正与已撤销项

1.4 四类记忆用哪些故事线因子构造及对应评测内容

参考普林斯顿大学 `CoALA`（arXiv:2309.02427）认知架构，联接 Agent 的记忆系统按生命周期实行**“短期记忆与长期记忆”两级分层管理**：其中**只有工作记忆（Working Memory）属于短期记忆**（仅在当前单次会话存活，维护本轮输入、多轮澄清/改口中间槽位以及当轮通过 `Retrieval` 从长期记忆检索读入的活跃上下文）；其余三类均为**跨会话持久保存的长期记忆（Long-Term Memory）**，包括：① **长期语义记忆（Semantic Memory，事实记忆—语义层）**、② **长期情景记忆（Episodic Memory，事实记忆—情景层：含每次历史保障单据记录及运行结果、以及绑定时间窗的差旅事件与带 `TTL` 短期临时偏好）**、③ **长期程序化 / 经验记忆（Procedural / Experiential Memory：含从短期工作记忆慢路径澄清与长期情景记忆正反单据对比中提炼的因果调参规则与消歧流程）**。四类记忆及跨层耦合场景的构造因子与评测内容见表 1.3。

表 1.3：四类记忆及多记忆耦合的核心场景、所用故事线因子（排布层 + 内容层）与支撑的评测内容

目标记忆类型	构造该记忆的核心场景	用来构造该场景的故事线因子（第一层排布因子 + 第二层内容因子）	该场景支撑的具体评测内容（萃取侧与检索/应用侧）
一、【长期记忆 ①】事实 — 语义记忆（Semantic Memory） 跨会话持久存储：记长期稳定的主力业务、周期作息习惯、分场景常驻 KQI 偏好、服务与应用映射、口语映射及基础套餐档位	**1. 日常主力应用、规律作息与基础套餐**	· **排布层：** `1. 时间跨度（≥1月）`、`1.1 事件规模`、`1.2 事件密度（均匀/忙闲交替）` · **内容层：** `1 & 3. 职业身份与流量/加速包套餐档位`、`4. 应用层级（业务→子类→应用）与占比`、`6~7. 周期活跃时段（按日/周规律、多峰、±10~60min浮动）与上下行流量比例`	· **萃取：** 跨周重复（`≥3` 次）晋升长期周期习惯、零散时段归并成段、主力业务应用多级归档与套餐基线抽取； · **检索：** 按业务占比与活跃度优先级排序、工作日/周末条件召回、排除零占比应用与免打扰时段。
	2. 不同地点（居家、通勤、高铁、场馆）下的网络偏好	· **排布层：** `3. 事件线结构（主线+多支线并行）`、`3.2 支线归宿（转新主线/周期复现）` · **内容层：** `5. 活动空间（室内驻地/地铁通勤/高铁高速/商圈户外）与移动状态`、`8~9. 上下行 KQI 指标、无线覆盖与网络切片偏好`、`13. 场景空间作用域`	· **萃取：** 不同空间下的 KQI 与网络保障偏好按场景槽位独立存储（如驻地直播保上行 1080p 与 高铁会议保跨区切换防抖，互不串味）； · **检索：** 当前所处场景优先排序、带空间/无线覆盖条件召回与跨维组合推荐。
	3. 用户个人口语习惯、业务对应关系与不可接受底线	· **排布层：** `1.1 事件规模`、`6.1 单据与对话配比` · **内容层：** `4. 服务与应用映射（service_to_app）`、`8.1 降级容忍与互斥权重`、`12. 显隐式表达（比喻反讽/历史对比）`、`12.1 正负向极性`、`12.2 口语映射（“阿抖/极致丝滑”→30ms、易混淆数值）`	· **萃取：** 口语体感词与业务黑话向标准网元字段映射（`expression / service_to_app`）、隐式反讽解码、正向偏好与负向排斥底线（如“绝不降帧率”）分离存储； · **检索：** 口语提问直接命中标准参数、显式优先于隐式排序、严格排除负向排斥项。
	4. 用户口头说法与网元单据记录一致或冲突	· **排布层：** `6.1 单据与对话总体配比（纯单据/纯对话/均衡混合）` · **内容层：** `11. 来源标注（对话与网元单据）与双源关系`	· **萃取：** 双源一致强化置信度；双源冲突时按证据强度整合（如口称“平时对网速没要求”但网元实测长期高上行直播流量，以 `strong` 实测为准或双源并列注记来源）；

目标记忆类型	构造该记忆的核心场景	用来构造该场景的故事线因子 （第一层排布因子 + 第二层内容因子）	该场景支撑的具体评测内容 （萃取侧与检索/应用侧）
		（一致/并列保留/口头声明与网元实测矛盾冲突）、11.1 证据强度（strong 多次实测 与 weak 随口声明）	· **检索：**高置信度实测偏好优先于单次低置信度口头记录排序。
	5. 使用习惯改变、套餐升级与未提及信息留空	· **排布层：** 2. 起始状态（冷启动）、4. 跨期变化趋势（单次迁移覆盖/渐进演变/习惯消退弃用） · **内容层：** 3~4 & 8. 直播时长/画质习惯跨期升级、主力应用迁移或套餐加速包升档、14. 信息缺失边界（仅提下行未提上行、未提抖动、无切片 ID）	· **萃取：**同义偏好合并去重、新版本偏好（active）覆盖旧版本（superseded），对未提及维度严格留空不编造默认值； · **检索：**最新生效版本排在历史旧版本之前、排除已弃用业务习惯，遇未存储属性主动拒答或追问。
二、【长期记忆 ②】事实 — 情景记忆（阶段事件与临时偏好） （Episodic Event Memory） 跨会话存储（带时间窗/ TTL）：记异地差旅/赛事事件、短期临时偏好、历史诉求情绪与显式纠正记录	**1. 出差、看比赛或月底流量紧张时的短期临时需求**	· **排布层：** 3.1 支线触发事件（异地出差/大型体育赛事/展会）、3.2 支线归宿（结束后回原主线） · **内容层：** 5.1 跨城移动状态、7. 月末流量余量吃紧、13. 短期临时偏好与有效期状态（未过期/临近过期/已过期/混合）	· **萃取：**短期差旅/赛事事件与临时省流或保障偏好绑定时间窗（TTL）独立存储，结束后自动回退不污染常驻语义记忆； · **检索：**未过期临时偏好排在已过期前、阶段条件召回、“月底流量紧+手游卡顿”省流保时延组合推理、全部过期时主动说明。
	2. 网络问题投诉、当面纠正系统错误与单次临时调整	· **排布层：** 4. 跨期变化趋势（多次波动与当面纠正后改回）、6.2 证据间隔 · **内容层：** 16. 主动诉求（弱覆盖提速/开加速包/解限速；active 与 closed）与情绪轨迹（不满投诉→改观）、18. 当面显式纠正与单次临时豁免声明	· **萃取：**同一诉求重申合并、新诉求关闭旧诉求、显式纠正最高优先级覆写、单场临时豁免（“仅今天改 720p”）隔离不改写常驻档案； · **检索：**未完结诉求（active）与最新纠正记录优先排序，排除已解决诉求与被纠正前的错误旧值。
	3. 日常闲聊、套餐咨询试探与偶尔一次的行为干扰	· **排布层：** 1.2 事件密度、6.3 间隔期干扰占比（低/中/高） · **内容层：** 15. 对话侧非偏好噪声（日常寒暄、假设试探“如果升级5G-A专网包…”、纯情绪抱怨、频次=1 的单次偶发看剧/熬夜）	· **萃取：**非偏好噪声抑制（防 FP 误抽：闲聊、未落单的假设试探与单次偶发行为严禁写入长期偏好，纯情绪仅记入反馈信号）； · **检索：**当历史仅有假设试探或单次偶发记录时，查询常驻偏好能如实拒答。
三、【长期记忆 ②】情景单据流水 & 【短期记忆】工作记忆 （Episodic Orders & Short-Term Working Memory） 长期情景库原样保存每次历史保障单据与实际运行结果（不合并、不衰减）；短期工作记忆在当轮会话中检索读入历史单据并跟踪改期/消歧槽位	**1. 记录每次保障单据的参数与实际运行结果（过滤误触取消单）**	· **排布层：** 1.2 事件密度（忙闲交替）、6.1 单据与对话配比 · **内容层：** 4.1~4.2 单双业务并发与 15~240min 连续随机时长、10~11. 基站 PRB 负载/弱覆盖异常与实际运行结果（AppQuality=good/bad）、15. 单据侧 1~8min 闪退/误触中途取消的无效单据	· **萃取：**按时间原样追加每张工单完整同行槽位与实际运行结果（不合并为平均习惯、不衰减），入库自动清洗剔除 1~8min 中途取消的无效单据； · **检索：**按日期/单号直接调取运行结果，或按卡顿严重度（游戏>直播>会议>视频）排序召回历史劣化单据。
	2. 对话中直接引用历史网元单据并修改时间	· **排布层：** 6.1 高单据占比、6.2 证据至测试点长间隔（15~35步） · **内容层：** 17. 跨轮历史单据指代（按时间“上周四”/按场景“在大巴车上那次”指代无历史对话的纯网元单据）与改期平移（“推迟半小时/时长改 60 分钟”）	· **检索与应用：**在无历史对话支撑时直接检索后台历史网元单据记录定位目标记录、提取同行全部结构化槽位，并在叠加改期/加时指令时准确重算起止时间窗与时长。
	3. 同一地点有多笔历史单据（正常单与卡顿单）时的区分与确认	· **排布层：** 1.2 事件密度（同日/同周同场馆密集多单） · **内容层：** 10. 同场馆先后埋入空场顺畅单 SN_A、正赛基站拥塞卡顿单 SN_B 与中途取消的无效单据、17. 模糊指代（“按上次在奥体那单来”）与不存在单据虚假指代	· **检索与消歧：**条件与排除检索（指定“没卡那次”时自动排除拥塞单 SN_B 与中途取消的无效单据、锁定顺畅单 SN_A）；仅提场馆名且存在多张有效候选单或指代单据不存在时，主动列明候选差异发起反问消歧。
四、【长期记忆 ③】程序化 / 经验记忆 （Procedural / Experiential Memory） 跨会话持久存储：从短期工作记忆慢路径澄清与长期情景单据正反对比中提炼因果调参规则与消歧流程（Workflows）	**1. 从历史多轮澄清和排障过程中提炼调参经验**	· **排布层：** 5. 跨会话因果关系、6.2 证据间隔、6.3 干扰占比（穿插大量日常快路径与闲聊） · **内容层：** 17~18. 缺参追问与显式纠偏（如字面陷阱纠偏、要求高密场馆提前预热锁流）、10~11. 同场馆前单拥塞 bad 改参后顺畅 good 正反对比、15. 未闭环试探噪声	· **萃取（源头样本定位与因果提取）：**评测能否从海量日常会话与单据流中识别已闭环的慢路径澄清/排障样本，提炼“场景条件→无线根因→调参动作→结果”因果规则，且不把未闭环试探误提炼为经验。
	2. 换个说法或换个同类场馆时直接复用已有经验	· **排布层：** 3. 事件线结构（支线 A 沉淀经验 → 切换至同类支线 B）、6.2 长间隔 · **内容层：** 5. 同属万人高密场馆或高速走廊的不同具体地名（如“奥体中心”→“工体中心”）、8.1/10.1 互斥权重与高峰 PRB 拥塞规律、12.2 口语换词	· **检索与应用（跨表述泛化召回与慢转快）：**评测当新请求更换具体场馆名或口语表述、但底层无线环境条件（高密场馆+上行直播推流）一致时，能否准确找回对应经验规则，自动补齐提前预热/高优切片实现 1 轮快路径闭环。
	3. 字面相似但实际网络环境不同时避免套错经验	· **排布层：** 3. 事件线结构（从高密场馆支线切回常规驻地主线） · **内容层：** 5. 空间切换（从“体育场馆看球开播”切回“常规室内驻地看球开播”）、9. 无线覆盖切换（从边缘弱覆盖高密拥塞小区切回常规 5G 宏站稳定覆盖小区）	· **检索与边界过滤（防经验误套用）：**评测当新请求与经验记录字面相似（同含“球赛、直播”）、但底层无线负载与覆盖条件不符时，能否核验适用边界（scope）并主动抑制场馆降画质/预热经验。
五、多类记忆交叉耦合场景 （Multi-Memory Coupling） 面向真实复杂请求的多层记忆联合检索、槽位拼接与优先级冲突裁决（预留复杂 Case 扩展空间）	**1.【语义 + 情景】平时的高画质习惯遇上出差或月底省流时的临时调整**	· **排布层：** 3.1 短期支线事件窗（异地漫游/月末最后3天）、4. 跨期变化 · **内容层：** 4~8. 常驻 1080p/50ms 直播语义偏好 + 7 & 13. 月末流量告急/异地弱网临时 720p 省流情景偏好（设未过期与已过期对照）	· **耦合评测：**在临时事件有效期内，以**情景记忆**的临时降档局部覆写画质槽位，其余缺省槽位（应用、时段、时延）仍由**语义记忆**补齐；事件过期后自动恢复常驻 1080p，严禁短期情景污染长期语义画像。
	2.【长期语义 + 长期情景单据 + 短期工作记忆】听懂口语简称并找到对应历史单据修改时间	· **排布层：** 6.1 高单据配比、6.2 跨周长间隔 · **内容层：** 12.2 口语词典与服务映射（语义记忆）+ 10~11 & 17. 指代同场馆历史顺畅网元单据（长期情景记忆排除拥塞单）并在短期工作记忆中叠加时段平移	· **耦合评测：**先查**长期语义记忆**解码口语别名与业务类型，再查**长期情景记忆（历史单据表）**在同地多单中排除基站拥塞单、锁定历史顺畅单提取基准参数，读入**短期工作记忆**后按当轮改期指令完成时间窗平移重算。
	3.【长期情景单据 + 短期工作记忆 → 长期程序化/经验】结合历史卡顿单据与用户反馈总结保障经验	· **排布层：** 5. 跨会话因果链、6.3 间隔期干扰 · **内容层：** 10~11. 前序网元单据 PRB=96% 拥塞卡顿运行结果（长期情景记忆）+ 18. 次日短期工作记忆中用户抱怨卡顿并显式纠正预热时长（长期程序化/经验记忆源头）	· **耦合评测：**评测系统能否将**长期情景记忆**中的客观基站 Telemetry 异常单据指标（PRB 拥塞、上行跌落、卡顿次数）与**短期工作记忆**中的用户慢路径纠偏联合对齐，沉淀出带物理根因与无线触发条件的**长期程序化/经验记忆**。
	4.【四类记忆协同】去新场馆开播时一句话自动补齐参数并提前预热	· **排布层：** 3. 异地场馆支线、4. 主线时长版本已升级、5. 前序已沉淀场馆预热与对词分流经验 · **内容层：** 12.2 首轮高省略口语指令 + 13. 赛事短期事件窗 + 10. 历史场馆拥塞单据 + 18. 多条候选经验规则（含适用与不适用规则）	· **耦合评测：**检验单轮复杂请求下的四类记忆协同：将三类长期记忆联合检索读入**短期工作记忆**：用**长期语义记忆**召回最新升级版主线参数与口语映射 → 用**长期情景记忆**对齐赛事日短期窗口并规避历史拥塞单据配置 → 用**长期程序化/经验记忆**触发“提前 30min 预热锁流”（同时抑制不匹配的微信对词规则），在工作记忆内合成参数实现 1 轮快路径闭环。

CoALA（arXiv:2309.02427）短期记忆与长期记忆分层管理说明

- **短期记忆（Short-Term Memory）—— 仅含工作记忆（Working Memory）：**仅在当前单次会话存活的瞬时上下文草稿板，维护本轮输入、多轮澄清/中途改口中间槽位状态，以及当轮通过 `Retrieval` 从三类长期记忆读入的活跃记忆上下文；会话结束后释放。
- **长期记忆（Long-Term Memory，跨会话持久保存）—— 含以下三类长期记忆：**① **语义记忆（Semantic Memory，事实记忆—语义层）**：跨周期常驻的主力业务、周期作息习惯、分场景常驻偏好、默认档位与口语映射；② **情景记忆（Episodic Memory，事实记忆—情景层）**：包含**每次历史保障单据记录与网元实际运行结果（** `SerialNo` **、** `good/bad` **，按单原样追加、不合并、不衰减）以及绑定具体时间窗的差旅/赛事事件与带** `TTL` **短期临时偏好**；③ **程序化 / 经验记忆（Procedural / Experiential Memory）**：从短期工作记忆慢路径澄清与长期情景单据正反对比中提炼的因果调参规则、同地多单消歧流程（Workflows）与交互策略。

1.5 两层组合规则、配置表结构与跨 3 个月完整组合示例

第一层排布因子与第二层内容因子组合为具体故事线时，遵循以下工程规则：

1. **先定时间线结构，再按三级粒度填内容：**先从第一层采样得到时间线结构；再按取值粒度填第二层——“用户”级因子整条故事线取一次，“线”级因子每条事件线取一次，“节点”级因子每个事件节点独立取一次。
2. **主从层级条件采样（消除父子条件冲突）：**先采样主因子，再在其范围内采样对应子因子。例如先定 `1. 时间跨度`，再定与之匹配的 `1.1 事件规模` 与 `1.2 事件密度`；仅当 `3. 事件线结构` 包含支线时才采样 `3.1 支线触发事件` 与 `3.2 支线归宿`；仅当 `10. 网络异常 ≠ 无异常` 时才采样 `10.1 异常发生阶段`。
3. **声明式合法性约束（不写死在代码分支中）：**只排除物理或逻辑冲突的组合，并统一声明在配置表的 `constraints` 列表中（例如排除“时间跨度 2 周与按月周期规律”、“平稳保持型节奏与套餐跨期升降级”、“仅网元单据体现与对话显式直接陈述”）。
4. **“先答案后会话”反向真值绑定与分阶段构建策略：**前期与中期采用**“先定义答案、再反向生成会话”**路线（参照 `LongMemEval`、`DynamicMem`、`PERMA`）：① 先定义评测骨架（测试维度、测试目的与难度分布）→ ② 先写出结构化标准答案（萃取侧写明 `gold_profile` 的生效值、过期值、来源与置信度，检索侧写明 `gold_answer` 与 `gold_memory_ids`）→ ③ 按成对覆盖（Pairwise Coverage）采样两层因子，反向生成能唯一推导出该答案的自然语言对话与网元单据序列 → ④ 通过多 LLM 交叉验证检验对话自然度与答案唯一性；到后期上线阶段再结合**“先有真实会话、后抽检标注答案”**路线（参照 `LoCoMo`、`MemoryAgentBench`）补充长尾边界样本。
5. **增量扩展：**新增测试维度时，直接在对应因子类别下补充主因子或子因子定义，不影响已有因子与数据。

真实组合示例：跨 3 个月“主线居家直播 + 支线异地场馆推流”的两层因子取值示例

1. 第一层排布因子取值： `1. 时间跨度 = 3 个月` → `1.1 事件规模 = 中（18 个节点）` & `1.2 事件密度 = 忙闲交替`；`2. 起始状态 = 冷启动`；`3. 事件线结构 = 主线 + 1 条支线` → `3.1 支线触发 = 大型赛事展会/出差` & `3.2 支线归宿 = 周期性复现`；`4. 跨期变化趋势 = 单次迁移覆盖型`；`5. 跨会话因果关系 = 1 条完整闭环`；`6. 测试编排` → `6.1 单据与对话配比 = 75 : 25`、`6.2 间隔 = 中（5~15 步）`、`6.3 干扰 = 中`。

2. 第二层用户级与线级因子取值：

- **用户级（全局取一次）：** `1. 职业身份 = 游戏主播`，`2. 终端组合 = 华为手机（主）+ iPhone（备）`，`3. 套餐档位 = 5G 畅享包 → 5G-A 钻石直播保障包（跨期升级）`，`12.2 措辞映射 = 口语体感词（“极致丝滑”→30ms、“高清”→1080p）`；
- **主线（日常居家）：** `4. 应用与业务 = 抖音/B站上行直播`，`5. 活动空间 = 家（固定静止）`，`6. 活跃时段 = 晚高峰 19-23（按日规律，±10min）`，`7. 流量与上下行比例 = 超大流量（>5G）+ 上行主导`，`8. KQI 要求 = 带宽 ≥100M、丢包 ≤0.1%`；
- **支线（周末异地场馆）：** `4. 应用与业务 = 户外赛事直播 + 微信语音`，`5. 活动空间 = 户外/人流聚集场馆`，`6. 活跃时段 = 周末下午`，`8. KQI 要求 = 时延 ≤30ms（8.1 允许画质降级保时延）`，`9. 覆盖环境 = 边缘弱覆盖`。

由上述两层配置生成的跨 3 个月时间线骨架、逐阶段填入的节点级属性及其分别构建的四类记忆如表 1.4 所示。

表 1.4：跨 3 个月故事线骨架、第二层节点属性填充与四类记忆构建演进表

阶段（第一层排布）	所属事件线	第二层节点级属性采样	构建的目标记忆类型	生成的对话与单据素材及支撑的评测点
1. 建立期 （第 1~3 周）	主线（家）	`11. 信息来源 = 仅网元单据体现`；`12. 表达方式 = 隐式行为推断`；`10. 网络异常 = 无异常`	**【长期记忆 ①】语义记忆** （常驻画像与分场景 KQI）	每晚在家直播的网元单据连续出现（上行大流量、时长 60~180min 随机分布），考验从纯单据行为流隐式推断“游戏主播”身份与居家常驻 KQI 偏好。
2. 支线工单与慢路径澄清期 （第 4~6 周）	支线（场馆）	`10. 网络异常 = 直播卡顿 与 顺畅同地双单` → `10.1 阶段 = 开场前期拥塞`；`17. 交互方式 = 缺参需澄清`；`18. 显式纠正 = 纠正活跃时段为周末`	**【长期记忆 ②】情景单据记录** **& 【长期记忆 ③】程序化/经验记忆**	场馆产生两张历史单据（下午顺畅单 `SN_A` 与晚上卡顿单 `SN_B`）原样记入**长期情景记忆（单据表）**；用户显式纠正“周末活跃”（记入情景记忆），并在**短期工作记忆**经慢路径澄清敲定“场馆开场前 20min 预热切片 + 降画质保 30ms 时延”规则（沉淀为**长期程序化/经验记忆**，因果链起点）。
3. 临时偏好与噪声干扰期 （第 7 周）	主线（家）	`13. 作用域 = 短期临时有效期（本周暂停推荐）`；`15. 噪声 = 寒暄闲聊 + 假设试探 + 单次熬夜 + 1~8min 短时单据`	**【长期记忆 ②】情景记忆（带 TTL）** **& 短期工作记忆噪声抑制**	声明“本周暂停套餐推荐”（作为带有效期的短期临时偏好记入情景记忆，到期自动失效不覆盖常驻习惯）；同时穿插天气寒暄、“如果升级5G-A专网包…”试探、单次熬夜与 1~8min 短时单据，检验萃取侧噪声抑制能力。
4. 迁移与双源冲突期 （第 8~10 周）	主线（家）	`3. 套餐升级 = 5G畅享包→5G-A钻石包`；`11. 信息来源 = 单据实测与对话声明矛盾`；`14. 缺失边界 = 从未提抖动指标`	**【长期记忆 ①】语义记忆更新** **& 缺失拒答控制**	移动套餐升至 `5G-A 钻石保障包`（旧版 `5G 畅享包` 标 `superseded`）；网元单据实测画质已升至 `4K` 但用户口头仍顺嘴说“按老规矩 1080p”（检验双源冲突仲裁与新旧排序）；当被问及从未提及的“抖动容忍度”时，严格执行缺失主动拒答。
5. 因果链闭环测试点 （第 11~12 周）	支线复现	`17. 交互方式 = 一次说清 + 按特征指代历史工单（“按上次场馆没卡那次来，再往后推半小时”）`；`5. 因果链闭环`	**【长期情景】历史单定位 + 【长期经验】→【短期工作记忆】闭环**	再次去场馆直播并指代历史单据，检验系统能否从**长期情景记忆**中排除卡顿单 `SN_B`、定位顺畅单 `SN_A` 读入**短期工作记忆**完成改期平移，同时命中**长期程序化/经验记忆**场馆预热规则，实现**1 轮快路径直接闭环**。

从两层因子到双模式记录的六步构造流程与多源逐字段融合顺序

从两层因子配置到生成单据与对话样本分为六个步骤，合成 Ground Truth 快照时对应表 1.5 的六步逐字段融合规则：

1. **第 1 步（选定评测目标与人物基底）：**锁定故事线要考核的核心记忆或交互能力，从人物库选定匹配的人物基底（固定职业、常驻空间、终端主备分工与口语词典）。
2. **第 2 步（主支线意图拆解为独立业务任务并绑定业务场景）：**在前期意图拆解阶段，将人物的主线与支线直接拆解为 2~4 个独立的业务任务（`task_id`），每个任务绑定全量场景池中的一个具体业务场景（`scenario_id`），明确各任务之间属于独立交替穿插、主次支持、同窗资源争抢还是打断恢复关系；该用户未分配任务的其余业务场景标记为“未覆盖场景（`uninitialized_scenarios`）”。
3. **第 3 步（按主从层级与跨维约束具体化因子）：**先采样主因子再采样条件子因子，过滤逻辑冲突组合。
4. **第 4 步（构建关键事件前后状态中间表）：**在展开具体记录前，先填写**关键事件前后状态表（Intermediate State Table）**，锁定每次状态跃迁的发生时间、触发原因、事件前状态、事件后新状态、以及网元单据可观测项（仅单据可见）与对话补充项（仅单据+对话可见）的边界。
5. **第 5 步（展开日常排期与并发/延迟窗口）：**围绕关键事件铺设周期日常事件与背景干扰，计算满足 `end - start == duration` 的时间戳，并按需注入单据延迟到达（$t_{\text{arrive}} > t_{\text{end}}$）、短时误触撤单或家庭成员临时借用等扰动。
6. **第 6 步（投影为“仅单据 / 单据+对话”双输入模式记录并绑定截止点真值）：**将事件流投影为仅单据输入版与单据+对话混合输入版输入，并按测试截止时刻 t_{cut} 与下方表 1.5 的六步融合顺序生成 Ground Truth 记忆快照与测试问答对。

表 1.5：网元单据与自然语言对话多源记录的六步逐字段融合判断顺序表

融合步骤	判断维度与对齐条件	具体融合与仲裁规则	典型业务实例
步骤 1	**同人 · 同业务场景（任务）· 同事件窗口对齐**	先按用户标识 `user_id`、拆解任务所属业务场景 `scenario_id`（结合基站位置、终端 `device_id` 与承载业务）及统计窗口 $([t_{\text{start}}, t_{\text{end}}])$ 判断多条单据与对话归属哪个业务场景记忆分片，严禁跨业务场景混存。	将用户在 Day 12 对话中提到的“前天中午在奥体卡顿那场”与 Day 10 的网元工单 `NE-10 (12:30-14:00)` 对齐。
步骤 2	**场景分片内部同槽位与时间作用域核验**	在定位到的业务场景分片（`scenario_memories[scenario_id]`）内部，核对两条记录是否描述同一槽位且处于同一时间作用域（场景常驻习惯 与 场景短期事件窗 `TTL` 与 单场临时豁免）；若目标 `scenario_id` 在该用户下不存在（未建档），直接判定为未知业务场景。	`S-04` 声明“单就今天这一场降为 720p”属单场临时豁免，与常驻主线的 `1080p` 分属不同作用域，互不覆盖。
步骤 3	**单源充分性判定**	若某一字段在单一渠道中已具备完整、无歧义的观测证据（如纯网元单据已完整记录历史会议的终端、时段与速率），则单源直接成立，无需强行要求另一渠道重复印证。	`S-02` 指代上周四高速大巴会议时，仅凭长期情景记忆中的纯网元历史单据 `NE-05` 即可完整提取全套槽位参数。
步骤 4	**跨源互补拼接与同义去重**	当单据提供客观指标与卡顿异常记录（如 `PRB=96%`、卡顿 8 次）、对话提供主观原因与调参要求（如“万人入场挤爆、提前半小时预热”）时，执行字段级互补拼接；同义重复则合并去重并提升置信度。	`NE-10` 的网元卡顿异常记录与 `S-03` 的用户慢路径反馈互补拼接，共同形成经验规则 `EXP_PREWARM_BUFFER_01`。
步骤 5	**新旧版本接替与双源冲突仲裁**	若属跨期习惯迁移或当面显式纠正（`corrections`），以最新生效版本标 `active` 并归档旧版（`superseded`）；若属同一时期口头随口声明与长期高频网元实测矛盾，客观行为与体验指标以高频实测为准，矛盾声明记入 `conflict_log`。	Day 20 起网元单据连续实测直播时长升至 `90min`，将 `MF_001` 从 `v1 (60min)` 升级为 `v2 (90min)`。
步骤 6	**客观实测校准可行性但不篡改主观意愿**	网元实测用于校准当前无线环境下的物理可行性与应用被动自适应降级状态，但严禁将“因弱网或并发抢占被迫降到 540p 的实测结果”篡改为“用户主观喜欢低画质”。	培训会议因后台上传抢占被动降至 `540p`，融合后用户的目标画质偏好仍保持 `1080p`，同时沉淀并发限速经验。

1.6 本章小结与拓展阅读

- **两层因子与主从结构：**第一层排布因子控制时间范围与规模、主支线结构、跨期变化趋势与测试点安排；第二层内容因子按“用户 / 线 / 节点”三级粒度覆盖业务画像属性与信息表达交互过程，存在条件依赖的属性作为对应主因子的子因子采样。
- **四类记忆构建划分（与第 4 章统一对齐）：**明确划分了哪些排布因子与内容因子分别用于构建**事实记忆**—**语义记忆**（跨周期稳定画像、周期习惯、默认档位、分场景常驻偏好与口语映射）、**事实记忆**—**情景记忆**（特定外部日程窗口、短期临时偏好、历史诉求、情绪轨迹与显式纠正记录）、**工作记忆（程序化记忆）**（原样保存的历史保障单据记录与网络运行结果，支撑跨会话单据指代复用、改期平移与同地多单消歧）以及**经验记忆**（慢路径澄清/纠正与排障沉淀的因果调参规则与快慢路径策略）。
- **覆盖下游评测特征：**内置显隐式表达、正负向极性、口语与易混淆数值、对话与单据双源冲突、分场景隔离、临时偏好过期、未提及属性拒答边界及非偏好噪声，用于下游记忆萃取与检索评测。
- **拓展阅读：** PersonaMem-v3 (arXiv:2608.21381)；LoCoMo (ACL 2024, arXiv:2402.17753)；DynamicMem (arXiv:2602.16756)；MemoryAgentBench (ICLR 2026)；LongMemEval (ICLR 2025, arXiv:2410.10813)。

2 记忆与意图交互评测数据集调研

本章围绕**意图理解、多轮消歧澄清、长程偏好补全及受控用户交互相关的评测基准**（不含代码生成、网页 DOM 操作或静态阅读理解任务），从以下三个问题梳理 2024–2026 年的 **22 篇代表性文献**：

1. **问题一（Benchmark 分布构建与构建参数）：**主流记忆、意图理解与多轮交互 Benchmark 各自是如何构建样本分布、如何定性切分不同记忆/意图类别、以及论文给出的构建参数（时间窗、积分、置信度、轮次）是什么？
2. **问题二（语法 · 语义 · 语用变体缺口）：**真实业务中的用户意图在**语法（Syntax）、语义（Semantics）、语用（Pragmatics）**三层有哪些核心变体类型？现有 Benchmark 已覆盖了哪些、还欠缺哪些盲区？
3. **问题三（多轮交互动作全集）：**多轮会话中**用户（User）与 Agent 之间交互动作的全集**包含哪些类型？



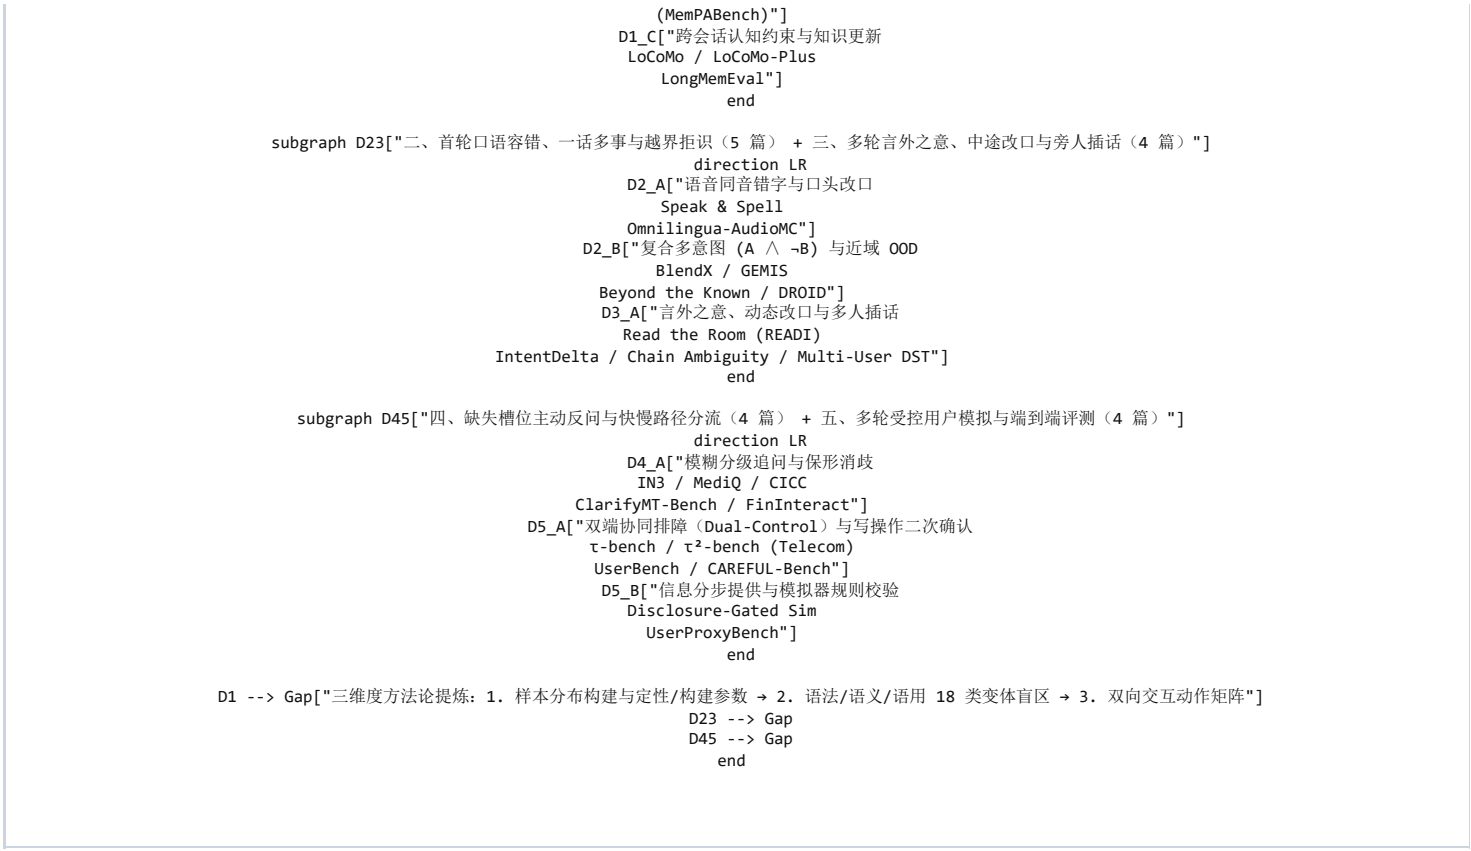


图 2：2024–2026 年五大方向 22 篇核心意图与记忆评测基准全景图。

上方汇总支撑缺省意图补全的长程记忆基准（5 篇）；中部汇总语法噪声、多意图 OOD 与语用改口基准（9 篇）；下方汇总多轮主动澄清与受控用户模拟器基准（8 篇）。

2.1 记忆、意图与多轮交互评测基准拆解

表 2.1 按一次多轮意图理解请求从**“前置记忆准备 → 首轮输入解析 → 多轮交互变化 → 主动反问消歧 → 端到端测试闭环”**的完整处理链路，将 22 篇核心代表性工作（2024–2026）划分为五个方向，聚焦拆解各基准**具体如何构建样本分布（数据规模、时间窗与子集配比）、如何定性切分不同记忆/意图类别（彼此如何定性）、以及论文给出的构建参数（得分、时间窗、置信度、轮次或覆盖率规则）**。

表 2.1：2024–2026 年记忆支撑意图、多轮消歧与受控交互 22 篇核心评测基准拆解表

研究方向	Benchmark（2024–2026）	评测集规模与分布构建（具体怎么构建分布）	类别定性边界与构建参数（彼此如何定性 & 具体数值规则）	核心评测方法与指标
一、历史习惯记忆与缺省槽位补全（前置记忆准备，6 组）	PersonaMem-v3 arXiv:2608.21381 (2026) (& v1/v2: 2504.14225)	· **数据规模与来源**：从 400 万事件池按每 10 名同好聚合重采样出 **200 名用户、30 天连续时间窗、超 100 万条事件**（人均 `~4,000` 条事件、`41.6 万 tokens`），扩写为 **6 张跨端 JSON 表**；v2 含 1,000 名用户、`128k–1M tokens`； · **信号与轨迹分布**：5% **显式互动** 与 95% **隐式浏览**（`63.8%` 划走、`36.2%` 长停留）；提炼 **1,554 条持续偏好轨迹**，按 4 类自然时间轨迹配比：**77% 强化稳定型、13% 逐渐消退型、8% 近期新增型、1% 单次偶发型**。	· **① 显/隐式赋分与长/短期定性阈值**：单次显式互动（发帖/对话明说）赋 `+1.0 分`，隐式长停留/完播赋 `+0.5 分`；单次划走（`< 1.5s`）忽略，连续密集划走同标签升级为反感候选。提取置信度门槛：**正向 `≥ 0.75`、负向 `≥ 0.55`**。30 天跨端累积阈值：**长期稳定偏好要求显式累加 `≥ 20 分`（纯隐式要求 `≥ 50 分`，即至少 100 次长停留）；短期临时意图（绑定旅行/就医等事件窗，事毕即失效）要求 `≥ 3 分`**；`< 3 分` 当噪声剪枝； · **② 4 类自然时间轨迹定性边界（30 天滑窗）**：**强化稳定（77%）**为全月前/中/后三旬持续复现且达长期门槛；**逐渐消退（13%）**为前中期高频但近 10~14 天交互归零；**近期新增（8%）**为前 20 天无记录、近 7~10 天密集涌现且跨过 `≥ 3 分`；**单次偶发（1%）**为仅在 1~3 天窄窗内爆发随后彻底消失，严禁升格为长期习惯。	① **问答四项一票否决红线 + 软评分**（踩中近期反感、泄露隐私、用消退过期偏好、生硬说破直接判 0 分）；② **信息流重排 `NDCG@5`**；③ **通用问题克制率**。
	BehaviorMem arXiv:2610.34790 (2026)	· **数据规模与来源**：采集淘宝 **2023.06–2026.06（跨度 3 年）**真实日志，保留有效访问 `≥ 50 次` **的 1,194 名用户**，共 **913,271 次访问、17,462 个行为批次（Batch）、16,268 个“历史批次 `B_≤t` → 未来批次 `B_t+1`”转移预测样本**。	· **① 行为批次（Batch）切分时间与数量阈值**：单批次累积满 `50 次访问` **或时间跨度达** `120 天` 后进入可闭合态，并在下一次**相邻访问间隔** `> 15 分钟` 处正式切分闭合（防止切断同次连续会话）；正样本仅取收藏、加购、购买及深度浏览，**剔除浅层单次点击**； · **② 记忆池（Remember Pool）与推理池（Infer Pool）定性边界**：**Remember Pool** 定性为“历史已直接访问过的 `L2` 类目或高频稳定 `L1` 大类下属类目”；**Infer Pool** 定性为“历史仅轻度涉足的相关类目或具跨大类生活场景关联的未知类目”。	分别在 Remember Pool 与 Infer Pool 上评测：① **具体证据回忆准确率与排序分**；② **跨类目潜在需求推理准确率**。
	Why Bother Me Again? (MemPABench) arXiv:2610.30485 (2026)	· **规模与分布**：构建 **4 名模拟用户、跨越 4 个月时间线、共 99 个多轮会话**，覆盖**工作（Work）与个人（Personal）双场景下的 14 个交互偏好维度**，每名用户埋入 **5 次事件驱动的偏好极性翻转（共 20 次突变）**。	· **① 内容记忆 与 交互方式偏好（Interaction Preference）定性**：内容记忆定性为“具体事实喜好（订哪家）”；交互偏好定性为“用户希望被如何协助的 14 维协作规矩”（语气正式度、回复详略、自主执行层级、主动推送边界、追问密度等）； · **② 双场景隔离与 4 个月翻转规则**：同一用户的 14 维偏好按**工作态 与 个人态物理隔离**（测跨场景串味污染）；每隔约 15~20 个会话植入升职、赶 deadline或休假事件，使指定维度从“每步先确认”反转为“高自主免确认直办”。	在测试决策点三层打分：① **偏好选择准确率（PSA）**；② **行为兑现率（BRS，是否真少问/少打扰）**；③ **用户感知满意度（PRS）**。

研究方向	Benchmark（2024–2026）	评测集规模与分布构建（具体怎么构建分布）	类别定性边界与构建参数（彼此如何定性 & 具体数值规则）	核心评测方法与指标
	LoCoMo (2402.17753) **LoCoMo-Plus** (2602.10715)	· **LoCoMo**：跨 6–12 个月、**16–35 个会话（均长 ~300 轮、`~9.2k tokens`）**长对话，配 1,986 道 5 类 QA（单跳 28%/多跳 21%/时序 24%/开放 15%/对抗 12%）； · **LoCoMo-Plus**：新增 **401 条隐式认知记忆测试对**。	· **① Level-1 显式事实记忆 与 Level-2 隐式认知记忆定性**：**事实记忆**定性为明文陈述、具唯一真值 `y*` 的具体事实；**认知记忆**定性为限制未来意图决策空间的 **4 类隐式约束（因果习惯变化 Causal、情绪状态 State-Based、长远目标 Goal-Oriented、价值准则 Value-Based）**； · **② 跨会话脱钩构建参数**：强制要求触发句（Trigger）与早先线索句（Cue）相隔 `≥ 10` 个会话（数周），且通过语义过滤使两者的**字面重叠率与 Embedding 余弦相似度压低至随机无关轮水平**。	评测 5 类 QA 准确率、无答案对抗题拒答率，以及事实回忆率与认知约束满足率落差（`Δr = r_fact − r_cog`）。
	LongMemEval arXiv:2410.10813 (2024)	· **规模与双档位分布**：**500 道人工精标跨会话评测题**，将证据会话混入海量无关日常会话中，设两个标准上下文长度档位：`LongMemEval_S`（`~40` 个会话，`115k tokens`）与 `LongMemEval_M`（`~500` 个会话，`1.5M tokens`）。	· **① 五大跨会话记忆能力定性切分与判分规则**：将 500 题正交切分为 5 类——**单会话信息提取（IE）、跨会话多跳聚合（MR，需跨 2–5 个不同日期的会话做计数/求和/对比）、知识更新覆写（KU，属性随时间被推翻修改，答出旧值直接判 0 分）、时序推理（TR，基于会话时间戳推算先后与间隔天数）、未提及拒答（ABS，针对历史未出现过的虚假前提提问，必须明确拒答）**。	会话/轮次级检索 `Recall@k / NDCG@k` + 下游生成问答准确率、知识更新覆盖率与未知拒答准确率。
	KnowMe-Bench (2026) **PersistBench** (2026)	· **KnowMe-Bench**：构造跨阶段长程个人叙事流并执行三阶段自洽验证； · **PersistBench**：专测长周期记忆持久化中的跨用户串味、过期记忆复活与虚假记忆注入风险。	· **① 三阶段数据验证与持久化边界定性**：区分当前有效个人事实、历史阶段已归档事实、跨用户隔离事实与未证实诱导信息；通过“提取核对 → 时间线重排验证 → 冲突消解测试”校验自洽性； · **② 防旧值复活与防污染红线**：严格禁止旧阶段作废偏好在无关新任务中复活（Obsolete Revival）或泄露其他用户记录。	跨阶段事实与因果归因准确率、**过期记忆复活率与跨用户污染率**（越低越好）。
二、首轮口语容错、一话多事与越界拒识（首轮输入解析，5 篇）	**Speak & Spell** arXiv:2409.06263 (2024)	· **规模与分布**：在 MultiWOZ 2.1 多轮任务对话集上，利用检索增强（`k=3` 真实 ASR 错例）构造两阶段可控音素错误测试集，覆盖不同词错误率（`WER`）梯度。	· **① 两阶段语音同音错字定性切分**：**Step 1 句级背景错字（Overall Error）**定性为非核心功能词的近音替换（如 `I'd like → I'd hike`）；**Step 2 槽位关键词靶向错字（Keyword Error，用 `<h1>` 标签锁定槽位值 `v`）**定性为专有地名、时间、餐饮名等核心槽位值的同音拆字/吞音变形（如 `vegetarian restaurant → veggie tarian restroom`、`Thursday → thursdae`）。	评测不同 `WER` 等级下的多轮对话状态跟踪联合目标准确率（`JGA`）与槽位错误率（`SER`）。
	Omnilingua-AudioMC arXiv:2611.04390 (2026)	· **规模与分布**：覆盖 **10 种语言**，每语种严格平行对齐 **354 段多轮对话、1,827 个用户轮次、1,404 条评分细则**，设 **10 个参考文本条件 与 11 个真人录音/TTS 语音条件**。	· **① 四大跨轮会话能力定性与精确配比（共 354 段）**：**推理记忆（IM：82 段，23.2%）**定性为跨轮调用前序隐含事实；**指令保持（IR：95 段，26.8%）**定性为跨多轮持续遵守首轮格式/禁忌约束；**自洽性（SC：77 段，21.8%）**定性为多轮追问下前后不矛盾；**语音口头改口（Voice Editing, VE：100 段，28.2%）**定性为用户在后续语音轮中口头撤回或局部修改前序槽位状态。	对比同一对话在参考文本 与语音输入下的跨轮状态保持落差（Text-to-Speech Carryover Gap）。
	BlendX (2403.18277) **Generative Multi-Intent** (2602.08322)	· **规模与分布**：将单意图库（ATIS 4,978 条、SNIPS 14,484 条）合成为每句含 **1~3 个意图**的复杂交织多意图与联合槽位填充集（替代传统机械拼接的 MixATIS / MixSNIPS）。	· **① 机械并列 与 复杂交织多意图定性（BlendX）**：摒弃仅用 `and` 简单拼接，按句间语义相似度配对并构造 **4 类交织句式**：**显式连词并列、隐式因果顺承、条件依赖（If-Then）与局部转折否定排除（`A ∧ ¬B`，防止将否定子句误提取为正向意图）**； · **② 共享槽位与跨子句消歧定性（GEMIS）**：定性考察**单句内多个意图共享同一时间/地点槽位**或**同类实体分属不同子句意图**时的精确绑定。	评测整句多意图+全槽位完全匹配率（`Overall Exact Match`）、意图 Macro-F1 与共享/互斥槽位绑定准确率。
	Beyond the Known (2402.17256) **DROID** (2510.14110)	· **规模与分布**：基于 CLINC-150（**10 域 150 类意图、18,000 条**）与 BANKING-77（**单域 77 类细粒度意图、10,003 条**），按 **已知类比例 `{25%, 50%, 75%}` 与标注样本率 `{0.2, 0.4, 0.6, 0.8, 1.0}`** 构建 15 组开放集测试矩阵。	· **① 已知域内（IND）与未知域外（Near-OOD）三档切分比例阈值**：严格按 **`25% / 50% / 75%` 已知意图比例（Split Ratio）**抽取 38/75/112 类作为域内已知意图（IND），将其余 **75% / 50% / 25% 同域细粒度意图全部划为未知域外（Near-OOD 难负例）**； · **② 伪域外边界校准（DROID）**：融合双互补编码器在特征流形边缘生成合成伪域外点，在仅 `20%` 标注率下仍维持 Known F1 `~90%`、Unknown F1 `90%~97%`。	评测 25%/50%/75% 三档比例下的域内准确率（`Known F1`）、域外拒识率（`Unknown F1`）与调和均值（`H-Score`）。
三、多轮言外之意、中途改口与旁人插话（多轮交互变化，4 篇）	**Read the Room (READI)** arXiv:2608.30270 (2026)	· **规模与分布**：构建**双语多模态语用问答基准（V-PQA）**，将包含社交关系线索的真实场景与表层不含祈使词的“言外之意（间接言语行为 ISA）”口语配对。	· **① 基于 CCSARP 框架的三级间接度（ISA Intensity）定性切分**：按字面形式与真实祈使意图的偏离度定性划分为 3 档——**规约性间接（Conventionally Indirect：礼貌询问能力/意愿）→ 非规约性弱暗示（Strong Hints：提及部分相关物件或状态）→ 高语境强暗示（Mild Hints：仅抱怨环境如“屋里好闷”或反问，与目标动作零词汇重合）**；同步编码权势差、社交距离与强加度三因子。	评测 3 个间接度等级下的深层祈使意图识别准确率，以及移除语境线索后的性能跌落值。
	IntentDelta arXiv:2610.33806 (2026)	· **规模与分布**：全人工构造并交叉核验，横跨 **WebShop 与 TravelPlanner 两大领域，共 638 条多轮轨迹、3,766 个对话轮次（轨迹均长 `5.9` 轮）**，每轮标注累积意图状态真值与参考工具动作。	· **① 意图改口触发条件二元定性切分**：**可行性受挫改口（Feasibility-Driven Shift）**定性为“原定需求在环境中无解（无库存/超预算/售罄），根据环境反馈被迫放宽或替换条件”；**偏好驱动改口（Preference-Driven Shift）**定性为“环境可行，但用户主动新增约束、撤回旧要求或重排优先级”； · **② 硬约束（Hard）与软偏好（Soft）定性**：改口轮次要求**100% 满足最新硬约束并彻底清除已作废旧约束（防 Obsolete Retention）**。	逐轮评测：① **累积意图状态精确恢复率**与**作废旧约束残留率**；② **当轮工具执行准确率**。
	Chain Ambiguity & Intent Drift (TIDE) arXiv:2608.29543 (2026)	· **规模与分布**：采用 **配对因子设计（是否含链式歧义、是否含中途意图漂移）**，在多轮结构化查询交互上构造受控对照基准。	· **① 链式歧义（Chain Ambiguity）与意图漂移（Intent Drift）定性边界**：**链式歧义**定性为“跨轮条件依赖的层级模糊——第 2 层槽位歧义必须等第 1 层澄清解开后才会显现（区别于单轮独立模糊）”；**意图漂移**定性为“非单调承诺撤回（Non-monotonic	评测多轮级联澄清完整率、非单调撤回后的旧承诺清除率及最终结构化查询执行准确率（`EX`）。

研究方向	Benchmark（2024–2026）	评测集规模与分布构建（具体怎么构建分布）	类别定性边界与构建参数（彼此如何定性 & 具体数值规则）	核心评测方法与指标
			Retraction）——用户在中途推翻并替换前序已确认的过滤条件”。	
	Multi-User DST arXiv:2506.10504 (2025)	· **规模与分布**：在 MultiWOZ 多轮对话数据集基础上，按言语行为理论在原用户与 Agent 轮次之间受控插入**第二名同行用户（同伴/家人）的插话轮次**。	· **① 第二发言人插话动作四分类定性与真值采纳阈值**：将同伴插话按言语行为定性切分为 **补充新槽位提议（Suggesting）、条件反驳/改口（Disagreeing/Revising）、附和确认（Confirming）、无关旁白闲聊（Chit-chat）**；严格规定**仅当主叫用户显式采纳或默认同意同伴的有效提议时才写入最终状态真值；纯闲聊或被主叫当场否决的提议严禁入库**。	对比单用户 与 双用户插话下的**零样本联合目标准确率**（`Multi-User JGA`）与槽位级抗干扰率。
四、缺失槽位主动反问与快慢路径分流（主动反问消歧，4 篇）	**IN3 (Intention-in-Interaction)** arXiv:2402.09205 (2024)	· **规模与分布**：面向百余种 Agent 工具调用场景构造多轮交互意图理解基准，逐条标注**初始模糊等级、缺失意图维度清单及完整目标真值**。	· **① 初始指令三档模糊度定性切分与轮次阈值**：**清晰指令（Clear）**定性为执行槽位齐全无歧义，要求 **0 轮追问**直达工具执行（走快路径，若发起多余追问则计入 Over-Clarification 扣分）；**轻度模糊（Slightly Vague）**定性为核心目标明确但缺 `1~2 个` 次要偏好，要求 **1 轮精准追问**或给合理默认配置；**高度模糊（Highly Vague）**定性为仅含宽泛目标、缺失 `≥ 3 个` 核心维度，要求分步追问补齐后再执行（盲目执行判 0 分）。	① **清晰指令零冗余追问率**；② **模糊指令缺失维度召回率（Missing Info Recovery）**；③ 下游工具调用成功率。
	MediQ arXiv:2406.00922 (2024)	· **规模与分布**：将 MedQA 与 iCliniq **1,200+ 个静态病例**改造为由**患者模拟器（Patient System）+ 专家问诊系统（Expert System）**组成的多轮按问给值交互基准。	· **① 首轮可见主诉 与 隐藏原子事实（Atomic Facts）定性隔离**：将完整实例拆为 `1` 句初始主诉（首轮唯一可见） + `N` 条隐藏原子事实（初始全部锁死）；模拟器采用 `Fact-Select` 规则，仅当问题精准命中某条原子事实时才提供该条信息，严禁主动多说； · **② 暂缓作答（Abstention）置信度阈值**：未达置信度门槛时严禁武断作答，必须继续追问（引入置信度过滤使交互准确率提升 `+22.3%`）。	评测**过早武断作答率（Premature Answering）**、每轮追问信息增益效率与最终决策准确率。
	Conformal Intent Clarification (CICC) arXiv:2403.18973 (2024)	· **规模与分布**：横跨 **7 个意图识别基准（Banking77、CLINC150、HWU64、SNIPS 等）**构建带统计覆盖保证的“快慢路径分流 + 最小澄清 + OOS 拦截”评测框架。	· **① 基于保形预测候选集大小 `|C(x)|` 的三路定性与量化分流阈值**：给定目标错误率上限 `α = 0.05`（保证真实意图以 `1 − α = 95%` 概率落在候选集 `C(x)` 内），按校准分位数阈值 `q̂_1-α` 切分： 1. **快路径直通**：`|C(x)| == 1` 时，**0 轮追问**直接执行； 2. **慢路径最小澄清**：`1 < |C(x)| ≤ k_max`（通常 2~5 个候选）时，仅围绕 `C(x)` 内候选生成最短澄清问题； 3. **域外拒识（OOS）**：`|C(x)| == 0`（全类得分低于保形阈值）时，直接判为 OOS 拒答。	评测给定置信水平 `1 − α` 下的**快路径直通率、平均澄清选项数（CQ Size）、澄清后准确率与 OOS 检出率**。
	ClarifyMT-Bench (2512.21120) **FinInteract** (2609.24002)	· **ClarifyMT-Bench**：构建 **多维歧义与不同用户风格**（合作/惜字如金/跑题/暴躁/术语盲/摇摆）多轮交互集； · **FinInteract**：中英双语 **173 个模糊实例**，覆盖 5 类口径歧义。	· **① 多维歧义、用户风格与轮次上限（ClarifyMT-Bench）**：交互轮次硬上限 `T_max = 5 轮`；定性区分**冗余追问（Over-Clarification，槽位已齐却重复反问）与未澄清直接执行（Premature Execution，必填槽位缺失即下发指令）**，量化中途改口时的槽位更新率 `Δ_update` 与遗忘率 `Δ_drop`； · **② “默认常见口径（Default）”与“真实预期口径（Intended）”双真值定性（FinInteract）**：揭露传统单真值评测把“盲猜常见口径”当成“解开歧义”的 **3.1 倍准确率虚高**（给口径后准确率 `> 90%`，自主澄清最高仅 `28.9%`）。	· **ClarifyMT-Bench**：何时问/问什么 F1、单轮信息增益、跨轮槽位保持率； · **FinInteract**：首轮歧义命中率（`AC@1`）与双口径准确率。
五、多轮受控用户模拟与端到端评测（端到端测试闭环，4 篇）	**τ-bench** (2406.12045) **τ²-bench** (2506.07982)	· **τ-bench**：覆盖 **Retail（115 个任务）与 Airline（50 个任务）**，含数据库 API、业务规程与模拟用户； · **τ²-bench**：新增 **Telecom（电信排障）领域**，构建部分可观测双控环境（`Dec-POMDP`）。	· **① Agent 单端操作（Single-Control）与用户-Agent 双端协同（Dual-Control）边界**：`τ-bench` 单控下仅 Agent 能调 API 读写数据库；`τ²-bench` 电信双控下，**模拟用户同样挂载专属物理侧工具（开关飞行模式、插拔 SIM 卡、重置 APN、读信号格与报错码）**，世界状态由 Agent 后台操作与用户终端操作共同改变； · **② `Pass^k` 多轮一致性构建参数**：要求同一工单独立重跑 `k` 次（`k = 1, 2, 4, 8`）**全部 100% 达成目标数据库与设备终态**。	终态数据库与设备状态精确比对 + `Pass^k` **多轮可靠性曲线**。
	UserBench arXiv:2507.22034 (2025)	· **规模与分布**：构建包含 **4,000+ 个多轮交互式规划场景**的 Gym 环境，按每项任务隐藏偏好维度的数量与冲突度划分为多个难度层级。	· **① 显式主干 与 增量隐式偏好定性**：用户首轮提问故意隐去 `> 70%` **的细分偏好槽位**，且模拟器遵循“不问不说、每轮仅释放被问到的单个维度”； · **② 单选惩罚与揭露率实测阈值**：当限制 Agent 每个决策维度只能输出 **1 个最终方案（Single-Choice）**时，模型平均得分暴跌 `> 40%`；实测最强模型通过主动提问挖掘出的用户隐式偏好比例 `< 30%`，完全对齐全部用户意图的比例平均仅 `20%`。	按最终方案满足的显式/隐式偏好加权占比打分，并对超出交互预算的冗余提问扣分。
	CAREFUL-Bench arXiv:2611.02978 (2026)	· **规模与分布**：审计并扩展多轮函数调用榜单 **BFCL（涵盖全部 128 个工具函数、Base 集 734 个参考交互轮次）**，发现原榜单 **734 轮中有 322 轮（`43.9%`）未获确认即执行破坏性操作**。	· **① 只读/幂等函数 与 破坏性写函数（Destructive Boundary）定性切分**：通过比对调用前后服务状态差分（State Diff），将全部 128 个函数严格定性切分为 **只读查询/幂等接口（Read-Only）** 与 **产生不可逆副作用的写接口（删除、扣款、修改配置）**； · **② 确认感知重放（Confirmation-Aware Replay）硬红线**：只读接口要求直接静默调用（多问扣分）；**任何破坏性写接口必须在调用前暂停并向用户发起自然语言确认提问，获显式肯定答复后方可执行**。	无裁判确定性状态与调用序列审计：① **破坏性操作先确认合规率**；② **冗余写调用膨胀倍数**；③ 终态准确率。
	Disclosure-Gated Sim (2609.00982) **UserProxyBench** (2609.38043)	· **Disclosure-Gated**：构建 **5 级分步信息提供规则（合并为表层/中层/深层 3 层）**评测 12 个系统； · **UserProxyBench**：在 `τ-bench` 家	· **① 五级分步信息提供规则（`2609.00982`）**：将隐藏信息分为 **5 个有序阶段**，仅当 Agent 问对当前维度才提供下一级信息；若连续机械追问则停止提供； · **② Agent 得分（`R_τ`）与模拟器规则遵循度**	· **Disclosure-Gated**：**按问提供合规率（防首轮提前透露未问参数）**； · **UserProxyBench**：**模拟**

研究方向	Benchmark（2024–2026）	评测集规模与分布构建（具体怎么构建分布）	类别定性边界与构建参数（彼此如何定性 & 具体数值规则）	核心评测方法与指标
		族 375 个任务上配 4–8 条带原文锚点的可证伪原子准则。	（ UFS ）实测阈值（ 2609.38043 ）：固定 Agent 仅换用户模拟器，任务得分波动达 15.2 个百分点；且在 Agent 得满分（ R_τ = 1 ）的轨迹中，有 24.4% 存在模拟器违反规则（提前透露未问槽位 / 谎称已执行终端操作 / 编造设备状态）； UFS 采用一票否决连乘 f_i = ∏ 1{c_ij passes} 。	器契约忠实度（ UFS ）与终端动作确定性检查点。

2.2 意图理解数据集在“语法 • 语义 • 语用”三层 18 类变体上的拆解与现有盲区

按语言学的**语法（句子结构与表层噪声）、语义（概念映射与逻辑边界）、语用（言外之意与多轮上下文）**三个层次拆解用户意图表达，表 2.2 对照现有评测基准的覆盖情况，列出当前数据集较少覆盖的变体类型。

表 2.2：意图理解在“语法 · 语义 · 语用”三层 18 类变体上的覆盖现状与现有盲区拆解

语言学层级	细分变体类型（共 18 类）	联接业务真实变体例句	2024–2026 Benchmark 覆盖现状	现有数据集普遍欠缺的盲区
一、语法层（Syntax） 句子结构与表层符号噪声	**1. 口语碎片化与主谓宾残缺**	“没网、满格、副卡、高铁上，快看下”	部分覆盖（常规口语改写集含简单短句）	欠缺**极端电报式短语（仅抛 1~2 个名词碎片）且需联合历史工单还原完整动作谓词**的样本。
	2. 语序倒装与话题前置/追补	“先把那个加速包开了，我是说今晚去工体看球用的那张副卡”	少量覆盖（ Omnilingua-AudioMC 2611.04390 测口语追补）	欠缺**跨句追补修饰导致前句槽位绑定关系反转**的精细标注。
	3. 句内口误改口（Self-Repair）	“帮我把周三…不对，周四晚上八点半的游戏加速改到九点”	中等覆盖（ IntentDelta 2610.33806 覆盖跨轮改口）	欠缺**单句话内部连续多次口误折返（“A…不对 B…算了还是 C”）**时的抗作废槽位干扰测试。
	4. 语音 ASR 同音错字与吞音粘连	“把那个**漫游（慢游）**流量包开一下”、“**上行（尚行）**推流掉帧”	重点覆盖（ Speak & Spell 2409.06263 、 Omnilingua-AudioMC 2611.04390 ）	现有 ASR 噪声集中于通用英文音素，欠缺**垂直行业专有名词/设备型号同音误识与个人口头禅同音字**联合恢复。
	5. 多层嵌套条件与例外从句	“要是今晚十点前还没修好，除非已经在走赔付流程了，否则帮我转高级专家”	覆盖较弱（ BlendX 2403.18277 含简单条件句）	极度欠缺**“如果 A 则 B，除非 C 否则 D”多层布尔条件树转结构化执行约束**的评测。
	6. 中英混杂、缩写与数字单位省写	“5G SA 切 NSA 后 ping 抖动 200ms，帮查下 APN 和切片 QoS”	覆盖极少（多数基准为纯英文或标准书面中文）	欠缺**高密度技术缩写 + 口语数字简写（如“晚 8 到 10”、“1080p 升 4K”）**混合解析。
二、语义层（Semantics） 概念映射、命题逻辑与边界	**7. 零字面重合的个人自定义别称**	用户说“**我平时打排位那台机器**” → 对应标准槽位 service=游戏加速，app=王者荣耀	**几乎空白**（仅 PersonaMem-v3 2608.21381 初步涉及跨端画像）	传统同义词改写仍具字面或公共语义重合；**唯有查询该用户个人历史记忆（ expression 映射表）才能解码的私有别称**在现有意图集中几乎缺失。
	8. 上下位概念泛化与具象指代	用上位词“**路上刷视频那几个软件**”指代具体应用，或用具体卡顿现象代指抽象网络保障类别	部分覆盖（ BehaviorMem 2610.34790 测跨类目泛化推理）	欠缺**用户口语粗粒度泛化词与后台细粒度标准目录（Catalog）一对多映射消歧**的系统评测。
	9. 复合多意图与显式否定排除（ A ∧ ¬B ）	“帮我把抖音直播加速开了，**但千万别动我刚才预约好的腾讯会议保障**，顺便查下剩余流量”	中等覆盖（ BlendX 2403.18277 、 Generative Multi-Intent 2602.08322 ）	现有多意图集侧重正向意图切分，**对否定子句（ ¬B ）被错误提取为正向执行参数（否定污染）的专门惩罚评测极少**。
	10. 相对时空与动态周期基准	“**跟上周五那次一样**，今晚再给我开两个钟头”	部分覆盖（ LongMemEval 2410.10813 、 LoCoMo 2402.17753 ）	欠缺**锚定“历史某次具体工单发生时刻”进行相对时长与周期换算（ end - start == duration ）**的联合校验。
	11. 模糊量词与相对比较级修饰	“把延迟弄得**比昨天再稳一点**”、“换个**稍微划算些**的套餐”	少量覆盖（ FinInteract 2609.24002 、 IN3 2402.09205 ）	欠缺**将模糊比较级（“更稳/稍微快点”）结合历史基线数值转化为可量化参数或触发阈值追问**的测试。
	12. 跨表同名实体歧义与域外相似混淆	名下有两张副卡或两条同地点的历史保障单据；或诉求酷似业务内实则属跨界 OOD 手机硬件维修	OOD 覆盖较充分（ DROID 2510.14110 、 Beyond the Known 2402.17256 ）	OOD 识别多为静态单轮分类，欠缺**“用户账户下真实存在多个同名/同类实例，必须核对工作记忆状态才能判断该问还是该办”**的设计。
三、语用层（Pragmatics） 言外之意、多轮上下文与社交潜台词	**13. 间接言语行为（言外之意）**	用户只陈述现象或抱怨：“**这网速连发个微信转圈都得半天，今晚还要不要人开会了？**”（表面抱怨，实为紧急报修+优先保会议）	2026 开始关注（ Read the Room ISA 2608.30270 、 UserBench 2507.22034 ）	现有基准多测试日常看图说话或简单寒暄，极度欠缺**高情绪抱怨背后隐含的“工具调用诉求 + 历史经验防雷约束”双层解码**。
	14. 跨轮零指代、代词省略与历史工单承接	“**老毛病又犯了**，按**上次那个师傅说的办法**直接帮我弄了吧”	重点演进方向（ Chain Ambiguity 2608.29543 、 LoCoMo-Plus 2602.10715 ）	传统指代消解仅回溯当次会话前 2~3 轮；**跨越数周历史会话、指向过往有效工单记录（工作记忆）的远距离跨会话省略指代**仍极少。
	15. 预设错误与事实冲突	用户预设了错误前提：“把我那个**免费赠送的国际漫游包**续上”（实际该包早在一个月前已退订且收费）	少量覆盖（ LoCoMo 2402.17753 含无答案欺骗提问、 LongMemEval 2410.10813 ）	欠缺**“先礼貌指出用户预设与事实记忆/历史工单不符，再给出合规替代方案”**的多轮纠偏动作评测。
	16. 反讽、气话与情绪化反问	“你们这加速包可太厉害了，开了比不开还卡，干脆给我全停了算了！”	**几乎空白**（现有任务型基准假设用户字面诚实）	LLM 极易将情绪化气话（“干脆全停了”）当成真实退订指令直接执行（ CAREFUL-Bench 指出破坏性误调风险），亟需**情绪安抚 + 二次意图核实**测试。
	17. 试探性条件咨询 与 正式下达执行指令	“如果我把今晚直播保障从 4K 降回 1080p，会不会影响推流画质？”（仅做假设咨询，并未授权立刻修改工单配置）	2026 新兴焦点（ CAREFUL-Bench 2611.02978 ）	多数工具调用基准不区分**“What-if 咨询态”与“Commit 执行态”**，导致 Agent 在用户仅咨询时擅自调用写接口改坏环境状态。
	18. 多人旁白插话、背景交谈与主导人意图剥离	主叫用户正在办直播保障，旁边同伴插话“顺便问问视频彩铃多少钱”，主叫立刻说“别管彩铃，先弄我今晚的直播加速”	2025–2026 开始探索（ Multi-User DST 2506.10504 ）	欠缺**主客观发言人权限区分、旁人插话噪声抑制以及主叫用户对旁人提议的即时否决跟踪**。

2.3 多轮会话“用户 ⇄ Agent” 16 对正交动作映射与 6 类多轮组合模式

综合多轮对话行为分类标准与 2024–2026 交互式 Agent 评测基准（`IN3`、`IntentDelta`、`τ²-bench`、`CAREFUL-Bench`、`Multi-User DST`），多轮交互动作从两个正交层面梳理：① **单轮原子动作的触发与响应映射（表 2.3，按四个阶段将用户动作 `U1–U16` 与系统响应 `A1–A16` 逐一对应）**；② **跨轮次的动作组合模式（表 2.4，由单轮动作串联而成的 6 类多轮交互组合模式）**。

表 2.3：多轮会话四阶段“用户触发动作 U1–U16 → Agent 响应动作 A1–A16” 16 对正交一一映射表

正交维度	配对	用户侧触发动作（User Trigger，U1–U16）	Agent 侧必选响应动作（Agent Response，A1–A16）	核心评测红线
一、首轮发起与分流维（4 对）	`U1→A1`	**U1. 全参/常驻习惯发起**：参数齐全，或省写但个人长期记忆可唯一确定（“老规矩开直播加速”）。	**A1. 记忆静默补全与一步快办**：后台查事实/经验记忆补齐槽位并一步下发工单，**0 轮追问**。	多余反问计入**冗余追问（Over-Clarification）**扣分（`IN3`）
	`U2→A2`	**U2. 隐式抱怨与言外之意**：只抱怨掉帧/断流/转圈现象，字面不含指令词（`READI`）。	**A2. 语用诉求解码与关联诊断**：将情绪抱怨映射为保障/排障意图，并联动查当前网络状态。	仅机械安抚不调工具判**解码失败**
	`U3→A3`	**U3. 缺参模糊与多单歧义发起**：缺核心槽位，或历史存在多张冲突单据（“照上次场馆那单办”）。	**A3. 聚焦式最小消歧追问**：进入慢路径，仅针对缺失或冲突的 1~2 个槽位精准提问（`CICC`）。	未问清直接盲猜下发判**抢跑 0 分**
	`U4→A4`	**U4. 复合多意图与否定禁忌**（`A ∧ ¬B`）：一话多事并附带禁忌（“开抖音加速，千万别动会议保障”）。	**A4. 子意图拆分与否定子句隔离**：拆解正向子工单，并将 `¬B` 转为保护约束而非正向参数。	将 `¬B` 误提为执行对象判**否定污染**
二、澄清协同与推进维（4 对）	`U5→A5`	**U5. 槽位直答与终端协同配合**：顺应追问给出参数，或配合反馈手机端状态（`τ²-bench`）。	**A5. 槽位合入与双端协同推进**：合入新槽位；若需终端配合则指导开关飞行模式/重置 APN。	已给槽位重复追问扣**交互冗余分**
	`U6→A6`	**U6. 反问原由与顾虑质询（Why-Query）**：不直接答槽位，先反问“为什么要提前 20 分钟开？”。	**A6. 追问原由释疑与主线回引**：先用历史拥塞依据解答顾虑，再自然引回待确认槽位。	答非所问或丢失原待办槽位扣分
	`U7→A7`	**U7. 记忆模糊与委托后台代查**：表示“我记不清上次用的哪档，你直接查我后台记录选最稳的”。	**A7. 跨表历史工单兜底代查**：主动检索工作记忆历史单据与运行结果，筛出无卡顿正例供确认。	把问题推回给用户让其自查判**失职**
	`U8→A8`	**U8. 跨话题偏离与顺带插问**：主任务未完结时突然插问剩余流量或账单，随后回主线。	**A8. 支线简答与主线挂起恢复**：简短解答支线查询，保持主任务已收集槽位不丢并拉回主线。	支线问答后遗忘主任务槽位判**断链**
三、动态修正与抗扰维（4 对）	`U9→A9`	**U9. 中途改口与槽位覆写**：推翻前序已给参数（“刚才说的八点改到九点半”，`IntentDelta`）。	**A9. 增量状态更新与作废值清除**：覆写目标槽位并重算关联时长，彻底清除旧值防残留。	旧参数残留或连带丢其他槽位判错
	`U10→A10`	**U10. 方案否决与历史踩坑排斥**：否定当前推荐（“上次按默认档卡死了，换个方案”）。	**A10. 失败经验防雷与备选切换**：过滤失败单据（`is_flawed=1`），切换经验库验证过的预热方案。	继续强推已被否决或曾失败方案判 0 分
	`U11→A11`	**U11. 错误预设与冲突条件坚持**：带虚假前提提问（“续上我上月那个免费漫游包”）。	**A11. 预设事实纠偏与合规替代**：温和指出预设与历史记录不符，并提供合规替代包（`ABS`）。	顺从错误前提编造虚假工单判**幻觉 0 分**
	`U12→A12`	**U12. 同伴旁白插话与主叫否决**：旁人插嘴提其他诉求，或被主叫当场否决（`Multi-User DST`）。	**A12. 主授权人锁定与旁人噪声过滤**：仅采纳主叫显式认可的提议，彻底屏蔽旁人闲聊与被否提议。	将旁人未获批插话写入槽位判**串味污染**
四、安全确认与收尾维（4 对）	`U13→A13`	**U13. 试探性假设咨询（What-If）**：仅问“如果把保障从 4K 降回 1080p 会怎样？”，未授权执行。	**A13. 咨询态推演与写接口静默克制**：仅调用只读分析回答影响，**严禁调用写接口改配置**。	咨询态擅自改线上配置判**越权违约 0 分**
	`U14→A14`	**U14. 涉及写操作/资费的指令下达**：要求执行退订、扣费或覆盖现有保障等有副作用操作。	**A14. 破坏性写操作前二次确认**：调用写接口前必须暂停并向用户发起确认，获批后方可执行。	未获确认直接调破坏性写接口判**违规**
	`U15→A15`	**U15. 越界诉求（Near-OOD）与升级**：提出手机硬件维修等域外诉求或强烈要求转人工（`DROID`）。	**A15. 域外拒识与带槽位平滑转接**：明确能力边界拒答域外项，或打包已确认槽位无缝转交专家。	强行应承域外诉求或转接丢上下文扣分
	`U16→A16`	**U16. 确认达成与会话终结**：对确认请求答复“好，就这么办”并结束会话。	**A16. 执行结果核验与异步记忆沉淀**：校验 `end-start==duration` 下发工单，结合运行结果异步沉淀经验。	未核对运行结果即把失败单写入长期习惯判错

上述单轮原子动作可组合为表 2.4 所示的多轮交互组合模式，覆盖从单轮快路径到多轮澄清修正的评测路径。

表 2.4：由 16 对原子动作构成的 6 类多轮交互组合模式

正交动作组合模式	标准动作链序列（Action Chain）	标准轮数	移动网络保障典型交互轨迹	核心考察能力
模式 1：记忆/经验静默快路径模式	`(U1/U2 → A1) → A16`	**1 轮**（0 反问）	用户说“老规矩开今晚直播加速”或“又开始掉帧了” → Agent 静默查长期习惯或场馆经验规则，1 轮直接补齐参数下发工单。	长短期记忆静默补全率、**零冗余追问率**（快路径闭环效率）。
模式 2：慢路径消歧与委托代查模式	`(U3 → A3) → (U7/U5 → A7/A5) → (U16 → A16)`	**2~3 轮**	用户说“照上次鸟巢那单办”（存在两张冲突单）→ Agent 追问选哪张（`A3`）→ 用户让后台代查哪次没卡（`U7`）→ Agent 筛出 4K 正例确认后闭环并**沉淀经验规则**。	慢路径聚焦反问命中率、工作记忆正反单据甄别、**经验规则归纳**。
模式 3：中途改口与支线穿插恢复模式	`(U3 → A3) → (U8 → A8) → (U9 → A9) → (U16 → A16)`	**3~4 轮**	澄清途中用户突然插问剩余流量（`U8→A8`），回主线后又改口“把八点改到九点半、画质改 4K”（`U9→A9`）→ 校验时长自洽后闭环。	跨话题主线槽位保持率、**增量覆写率与作废旧槽位清除率**。
模式 4：试探咨询转高危写确认模式	`(U13 → A13) → (U14 → A14) → (U16 → A16)`	**2~3 轮**	用户先问“如果降回 1080p 会影响推流吗”（`U13`）→ Agent 仅分析不改配置（`A13`）→ 用户随后下令修改，Agent 二次确认（`A14`）获批后执行。	**What-If 咨询态写操作克制率**、破坏性/变更操作二次确认合规率。
模式 5：多源干扰剥离与事实纠偏模式	`(U4+U12 → A4+A12) → (U11 → A11) → (U16 → A16)`	**2~3 轮**	主叫提复合需求且同伴插嘴问视频彩铃（`A4+A12` 剥离噪声并锁定 `¬B`），同时纠正主叫记错的免费漫游包预设（`A11`）。	**否定子句分离过滤**、旁人插话抗扰率、虚假前提拒答纠偏率。
模式 6：双端协同排障（Dual-Control）与越界转人工模式	`(U2 → A2) → (U5 ⇔ A5) → (U15 → A15)`	**2~4 轮**	用户报高铁断流 → Agent 指导重插 SIM 卡/切飞行模式（`A5` 双端协同排障）；若属基站或手机硬件故障（`U15`），带齐已测槽位平滑转人工（`A15`）。	双端协同（Dual-Control）下用户动作引导准确率、**Near-OOD 边界拒识与上下文交接完整率**。

结合 2024–2026 22 篇核心文献对联接 Agent 评测集构建的方法论总结

- **在记忆测试点构造上：**综合 `PersonaMem-v3`、`BehaviorMem`、`Why Bother Me Again?` 与 `LoCoMo-Plus`，不仅要埋入跨周期的事实与习惯（含 77% 稳定、13% 消退、8% 新增、1% 偶发四类轨迹及 `≥ 20 分 / ≥ 3 次` 晋升阈值），还要埋入**用户的交互免打扰边界（哪些已知槽位不准重复追问）**与零字面重合的隐式认知约束。
- **在语法 · 语义 · 语用变体构造上：**针对现有数据集最欠缺的盲区，重点构造**“必须联合三类长期记忆与短期工作记忆才能消解的变体”**——包括语法层的**省略主谓语的简短口语及句内口误改口（Self-Repair）**、语义层的**零字面重合个性化表述映射（查 `expression` 映射）+ 复合意图否定排除（`A ∧ ¬B` 否定子句分离与权重衰减过滤）**、以及语用层的**高情绪抱怨言外之意（`Read the Room ISA`）+ 跨周历史工单省略指代 + 试探性咨询态与执行态区分（`CAREFUL-Bench`）**。

- **在多轮用户–Agent 交互模拟上：**参考 `τ²-bench` 的用户-Agent 双端协同环境（Dual-Control）、`Disclosure-Gated Simulation` 5 级分步信息提供规则与 `UserProxyBench` 契约忠实度审计，严禁模拟用户第一轮吐露全部底牌或无条件配合，而是覆盖 **双向交互动作**（含反问原由、中途改口 `IntentDelta`、旁人插话干扰 `Multi-User DST` 与高危写操作执行前二次确认 `CAREFUL-Bench`）。

2.4 本章小结与拓展阅读

- **评测基准分类梳理：**归纳了长程记忆演化、语法噪声与多意图 OOD、语用言外之意与意图漂移、多轮主动澄清以及受控用户模拟五类基准的样本分布、定性边界与构建参数。
- **语言学变体与双向交互动作汇总：**构建了覆盖语法、语义、语用三层的 18 类变体对照表与会话四阶段 双向交互动作矩阵，明确了双流业务场景最应补齐的数据盲区。
- **拓展阅读：** PersonaMem-v3 (arXiv:2608.21381)；LoCoMo-Plus (arXiv:2602.10715)；IntentDelta (arXiv:2610.33806)；CICC (arXiv:2403.18973)；τ^2-bench (arXiv:2506.07982)；UserProxyBench (arXiv:2609.38043)。

3 从故事线到单据与对话样本的完整构造实例

本章给出两套互补的端到端样本构造实例：**3.1 节（实例一：`USER_001` 巡回技术讲者）**完整展示一条 30 天、21 个事件节点（15 笔网元单据 + 6 场多轮自然语言对话）的双流穿插样本，给出从两层因子选型、人物真值骨架、网元单据明细、双盲输入视图、多轮对话原文到 Day 30 四类记忆真值快照与配套评测题的全套落盘数据；**3.2 节（实例二：`USER_002` 现场运维人员陈宁）**重点展示第 1.4 节所述的关键事件前后状态中间表、前后台业务并发争抢、单据延迟到达截止点校验以及同骨架 “仅单据 / 单据+对话”双输入模式标准答案对照。

3.1 实例一：巡回技术讲者 30 天 21 节点双流穿插完整样本（`USER_001`）

3.1.1 故事线设定与两层因子取值（`USER_001`）

本样本围绕巡回活动讲者林峰（`USER_001`）在 30 天内的专网保障业务展开。下图给出了该样本从故事线设定到 30 天网元单据与多轮对话混合序列的整体演进脉络。

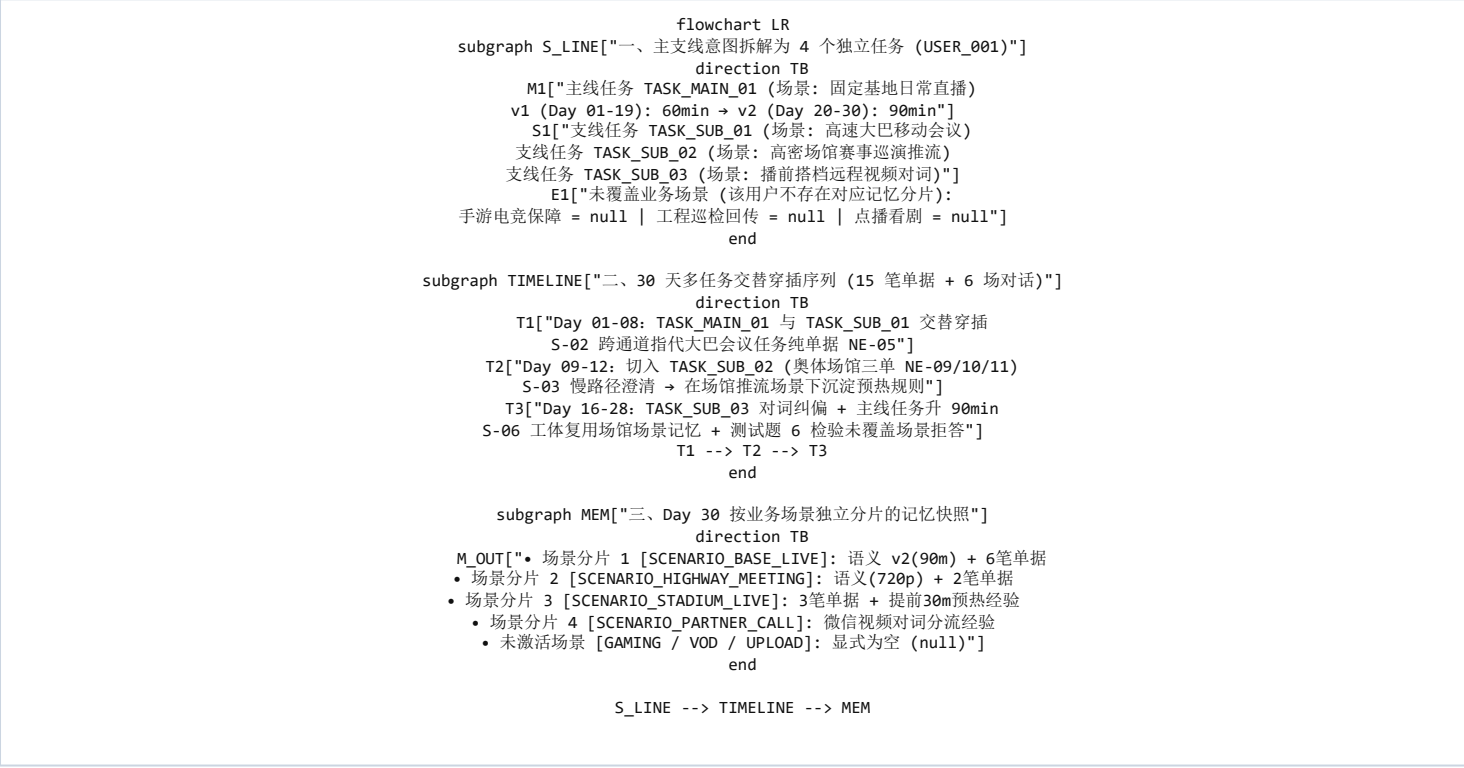


图 1.1：样本 `USER_001` 的故事线设定、30 天单据与对话混合序列及四类记忆真值对应关系图

样本由日常直播主线、大巴移动会议支线、开播前对词支线以及大型场馆短期事件窗交织而成，在 30 天内生成 15 笔网元单据与 6 场多轮自然语言对话。

1.1 排布层与内容层设定参数表

表 1.1 与表 1.2 分别列出了该样本在第一层排布因子和第二层内容因子（用户级、线级、节点级）上的具体设定值。

表 1.1：样本 `USER_001` 的第一层排布因子采样明细表

排布层一级维度	二级控制参数	`USER_001` 实例采样值	在混合数据样本中的具体落点
规模与时间节奏	时间跨度与节点总数	跨度 `30 天`，共 `21` 个业务节点（`15` 笔单据 + `6` 场对话）	覆盖完整的月度周期，满足长期偏好频次累积阈值（≥ 3 次）与版本更替跨度
	节点时间间隔分布	常态节点间隔 `2~4 天`；Day 10 奥体彩排日单日爆发 `3` 笔工单	常态期检验长间隔记忆保持，Day 10 密集爆发期检验同日多单分辨能力
双流构成与穿插模式	单据与对话数量占比	网元单据 `15 笔 (71.4%)`：多轮对话 `6 场 (28.6%)`	还原真实网元业务“后台静默执行工单多、前台人工对话少”的非对称分布
	双流前后因果穿插关系	① 纯单据复刻（`NE-05 → S-02`） ② 单据异常触发对话（`NE-10 → S-03`） ③ 同地多单消歧（`NE-09/10/11 → S-05`）	强制 Agent 必须在自然语言对话中检索后台历史网元单据记录才能补全缺失槽位
主支线拓扑结构	主线、支线与短期事件窗	`1` 条日常直播主线 + `2` 条支线（高速大巴移动会议、游戏联机）+ `1` 个短期事件窗	构造多业务线并存环境，防止模型将短期异地差旅或单次支线误记为全局默认习惯

排布层一级维度	二级控制参数	USER_001 实例采样值	在混合数据样本中的具体落点
		（Day 10~15 异地峰会）	
	多线交替穿插方式	日常主线（NE-01/02/04/06...）与大巴移动支线（NE-03/05/08）、奥体事件窗（NE-09~12, S-03）交错出现	检验记忆抽取与检索在多场景频繁切换下的抗干扰与条件路由能力
偏好形成与演化	习惯形成频次门槛	固定习惯需累积 ≥ 3 次同分布执行（Day 06 NE-04 后正式确立主线习惯）	区分“偶然执行 1 次的临时业务（如 NE-06 腾讯视频）”与“高频稳定习惯”
	偏好转变方式	Day 20（NE-13）起主线午间直播时长从 60min 升级为 90min (12:30-14:00)	构造新旧参数版本更替（v1: 60min → v2: 90min），评测时效覆盖与旧版本抑制
慢转快因果跨度	澄清源点与快路径复用距离	① **因果链 A**：S-03 (Day 12) 慢路径沉淀场馆预热规则 $\rightarrow$ 间隔 16 天（跨 3 笔单据 + 2 场对话）$\rightarrow$ S-06 (Day 28) 异地工体中心 1 轮快路径直通 ② **因果链 B**：S-04 (Day 16) 慢路径纠偏字面陷阱（对词=微信通话）	评测 Agent 能否在长跨度噪声后准确召回适用经验并实现跨地点泛化推理

表 1.2：样本 USER_001 的第二层内容因子采样明细表

内容层归属层级	内容因子名称	USER_001 实例采样内容	对应的记忆构造与评测作用
1. 用户级内容因子	静态身份与绑定终端列表	姓名：林峰（巡回活动讲者，钻石 VIP）；主力直播机 Mate 60 Pro (DEV_M60P)，备用移动办公机 Mate X5 (DEV_MX5)	提供跨业务线的静态实体底座，支持终端切换与套餐等级核验
	口语化别名与自定义词典	“阿抖” → 抖音-开直播；“老规矩/中午那档” → 12:30 起播午间档；“千万别转圈” → latency ≤ 50ms；“超清档” → 1080p	构造口语表达与标准工单字段之间的语义鸿沟，评测个性化表述映射能力
2. 线级内容因子	各业务线空间场景与基站关联	① **主线 M1**：杭州滨江直播基地（固定室内 5G-A_Binjiang_01） ② **支线 S1**：沪杭高速大巴（高速移动跨区切换 G60_HighSpeed_Corridor） ③ **事件窗 E1**：北京奥体中心 / 工体中心（大型高密场馆）	将不同业务参数绑定在明确的空间环境条件上，支撑带空间前提的条件检索
	各业务线网络质量（QoS/KQI）诉求	① **M1 直播主线**：上行带宽 ≥ 20Mbps，时延 ≤ 50ms，1080p ② **S1 移动会议**：防切换掉线，时延 ≤ 80ms，720p	区分不同业务线对上行码率与防抖切换的差异化指标要求
3. 节点级内容因子（单据侧）	业务并发结构与单据时长分布	单业务独立执行（NE-01~08）与同场馆三单密集爆发（NE-09/10/11）；时长覆盖 1min（无效单据）、3min（闪退单）、45min、60min、90min、120min	打破固定时长硬编码，检验参数自洽校验（end - start == duration）与短无效单据过滤
	网元链路状态与异常退化原因	NE-10 (Day 10 12:30) 奥体正赛直播遭遇晚/午高峰基站高负载：PRB = 96%，上行吞吐跌至 6.8Mbps，freeze_count = 8，状态标记为 sla_degraded (congestion)	在网元单据流中埋入客观物理故障，作为后续 S-03 用户抱怨卡顿与沉淀预热规则的真实物理证据
	背景噪声单与中途取消的无效单据混入	① NE-06：单次偶然看剧（腾讯视频-看视频，45min） ② NE-07：3min 未开启保障的后台抖音刷视频短时单据 ③ NE-11：奥体中心误触提交后 1min 主动撤单（aborted）	评测萃取器与工作记忆在汇总时能否剔除偶发单、未保障短时单据与中途取消的无效单据
4. 节点级内容因子（对话侧）	首轮信息缺失度与模糊度	在信息不对称（Information Asymmetry）约束下，用户首轮不直接报出底层标准参数：如 S-02 仅说“按上周四傍晚大巴上那套来”，S-06 仅说“今天 12:30 到 14:00 在工体给阿抖开播，按老规矩走”	逼迫 Agent 依赖长短期记忆主动补全槽位，无法靠单轮字面提取过关
	指代跨度與多候选歧义	① **跨流指代**：S-02 指代 3 天前无对话记录的纯网元工单 NE-05 ② **同地多单歧义**：S-05 指代“上次在奥体办的那笔”，命中 NE-09/10/11 三笔候选	评测工作记忆跨模态记录检索与多候选状态对比消歧能力
	显式纠正类型与单次临时豁免	① **时长扩容纠正**（S-03：因 NE-10 拥塞要求提前半小时预热，90min → 120min） ② **字面陷阱纠正 + 单次豁免**（S-04：“对抖音的词”实为 微信-视频通话；且声明“仅今天改 720p，别改老规矩”）	构造慢路径纠偏源点以沉淀因果经验记忆，同时测试单次临时变更不污染长期画像

1.2 故事线设定 JSON 数据（persona_skeleton.json）

下方 JSON 数据给出了 USER_001 的静态用户画像、口语词典映射、日常直播主线（含 v1 至 v2 时长升级）、两条支线、大型场馆短期事件窗及背景干扰项的完整设定：

数据样本 1.1：USER_001 故事线设定 JSON（persona_skeleton.json） 文件路径：mobile_persona_001/persona_skeleton.json


```
{
  "user_id": "USER_001",
  "persona_id": "mobile_persona_001",
  "static_profile": {
    "name": "林峰",
    "occupation": "巡回活动讲者 / 技术主播",
    "vip_tier": "钻石级 VIP (5G-A 专网保障签约用户)",
    "bound_devices": [
      {"device_id": "DEV_M60P", "model": "HUAWEI Mate 60 Pro", "role": "主力直播终端"},
      {"device_id": "DEV_MX5",  "model": "HUAWEI Mate X5",     "role": "移动办公与大巴会议终端"}
    ],
```

```
    "colloquial_lexicon": {
      "阿抖": {"field": "service_app", "std_value": "抖音-开直播"},
      "老规矩": {"field": "time_window", "std_value": "午间直播档 (12:30 起播)"},
      "超清档": {"field": "resolution",  "std_value": "1080p"},
      "千万别转圈": {"field": "max_latency", "std_value": "50ms"}
    }
  },
  "decomposed_task_definitions_note": "主线与支线在前期意图拆解阶段即拆解为 4 个独立业务任务 (task_id)，分别绑定各自独立的业务场景记忆分片 (scenario_id)：全量场景池中其余未涉足场景在该用
  "periodic_main_storyline": {
    "task_id": "TASK_MAIN_01",
    "scenario_id": "SCENARIO_01_BASE_LIVE",
    "storyline_id": "MAIN_NOON_LIVE",
    "scene_label": "杭州滨江固定直播间日常技术开播",
    "base_location": "杭州-滨江直播基地 (Cell: 5G-A_Binjiang_01)",
    "device_id": "DEV_M60P",
    "service_app": "抖音-开直播",
    "kqi_target": {"resolution": "1080p", "uplink_min_mbps": 20, "max_latency": "50ms"},
    "version_evolution": [
      {
        "version": "v1",
        "effective_days": "Day 01 ~ Day 19",
        "start_time": "12:30", "end_time": "13:30", "duration": "60min",
        "trigger_reason": "初始日常午间 1 小时技术分享直播"
      },
      {
        "version": "v2",
        "effective_days": "Day 20 ~ Day 30",
        "start_time": "12:30", "end_time": "14:00", "duration": "90min",
        "trigger_reason": "增设观众连麦答疑环节，常态直播延长至 90 分钟"
      }
    ]
  },
  "sub_storylines": [
    {
      "task_id": "TASK_SUB_01",
      "scenario_id": "SCENARIO_02_HIGHWAY_MEETING",
      "storyline_id": "SUB_HIGHWAY_MEETING",
      "scene_label": "沪杭高速大巴移动跨城远程视频会议",
      "base_location": "沪杭高速大巴移动走廊 (Cell: G60_HighSpeed_Corridor)",
      "device_id": "DEV_MX5",
      "service_app": "腾讯会议-视频会议",
      "time_slot": {"start_time": "17:30", "end_time": "18:15", "duration": "45min"},
      "kqi_target": {"resolution": "720p", "handover_protection": true, "max_latency": "80ms"}
    },
    {
      "task_id": "TASK_SUB_03",
      "scenario_id": "SCENARIO_04_PARTNER_REHEARSAL",
      "storyline_id": "SUB_PARTNER_REHEARSAL",
      "scene_label": "开播前与搭档一对一远程对词及机位确认",
      "base_location": "杭州-滨江直播基地",
      "device_id": "DEV_MX5",
      "service_app": "微信-视频通话",
      "literal_trap_note": "用户口头常说'对一下抖音直播的词'，真实承载应用为微信视频通话而非抖音开播"
    }
  ],
  "short_term_event_windows": [
    {
      "task_id": "TASK_SUB_02",
      "scenario_id": "SCENARIO_03_STADIUM_LIVE",
      "event_id": "EVT_STADIUM_TOUR",
      "active_days": "Day 10 ~ Day 15 (及 Day 28 异地返场)",
      "venues": ["北京-奥体中心场馆", "北京-工体中心场馆"],
      "risk_profile": "万人高密场馆正赛时段基站 PRB 极易超过 95% 导致上行拥塞卡顿",
      "target_experience_rule": "EXP_PREWARM_BUFFER_01: 大型高密场馆开播需将 start_time 提前 30min 预热锁流，duration 相应 +30min"
    }
  ],
  "distractor_pool": [
    {"type": "one_off_entertainment", "service_app": "腾讯视频-看视频", "duration": "45min", "note": "偶发单次看剧，频次=1"},
    {"type": "unassured_micro_usage", "service_app": "抖音-刷视频",     "duration": "3min",  "note": "后台未开保障短时刷视频"},
    {"type": "aborted_order",         "service_app": "抖音-开直播",     "duration": "1min",  "note": "误触后 1 分钟内撤单 (aborted)"}
  ],
  "uninitialized_business_scenarios": [
    {"scenario_id": "SCENARIO_05_MOBILE_GAMING", "scene_label": "手游电竞低时延排位保障", "memory_status": null, "reason": "该用户从未发生过手游电竞保障任务"},
    {"scenario_id": "SCENARIO_06_VIDEO_VOD", "scene_label": "长视频高清点播保障", "memory_status": null, "reason": "仅 Day 09 偶发 1 次腾讯视频 (NE-06)，未达建档门限"},
    {"scenario_id": "SCENARIO_07_FIELD_INSPECTION_UPLOAD", "scene_label": "现场工程巡检大包回传保障", "memory_status": null, "reason": "属于现场运维人员场景，该主播用户不存在此业务
  ]
}
```


2 30 天网元单据与多轮对话穿插时间轴（21 节点总表）　　故事线到网元单据混合对话的数据样本实例

2 30 天网元单据与多轮对话穿插时间轴（21 节点总表）

根据第 1 节的故事线设定，`15` 笔网元单据（`NE-01 ~ NE-15`）与 `6` 场多轮自然语言对话（`S-01 ~ S-06`）在 Day 01 至 Day 30 时间轴上的具体穿插顺序及节点间关联如下表所示：

表 2.1：`USER_001` 在 30 天周期内的网元单据（15 笔）与自然语言对话（6 场）双流穿插表

日期	节点 ID	通道类型	拆解任务与业务场景（`task_id` / `scenario_id`）	核心业务参数与执行状态	跨节点因果与记忆作用
Day 01	`S-01` + `NE-01`	多轮对话 + 网元工单	`TASK_MAIN_01`（基地固定直播场景 v1）	`12:30-13:30 (60min)` | 滨江基地 | `抖音-开直播` | `1080p, ≤50ms` | `completed`	**冷启动建档**：3 轮澄清对齐全量槽位，写入口语映射（阿抖/老规矩），落地首单 `NE-01`

日期	节点 ID	通道类型	拆解任务与业务场景（`task_id / scenario_id`）	核心业务参数与执行状态	跨节点因果与记忆作用
Day 03	`NE-02`	纯网元工单	`TASK_MAIN_01`（基地固定直播场景 v1）	`12:30-13:30 (60min)` | 滨江基地 | `抖音-开直播` | `1080p, ≤50ms` | `completed`	主线 v1 第 2 次重复执行（后台静默履约，无对话）
Day 04	`NE-03`	纯网元工单	支线 S1 (移动会议)	`17:30-18:15 (45min)` | 沪杭高速大巴 | `腾讯会议-视频会议` | `720p, ≤80ms` | `completed`	首次出现高速移动大巴跨区会议工单（终端 `DEV_MX5`）
Day 06	`NE-04`	纯网元工单	`TASK_MAIN_01`（基地固定直播场景 v1）	`12:30-13:30 (60min)` | 滨江基地 | `抖音-开直播` | `1080p, ≤50ms` | `completed`	**习惯正式成型**：主线 v1 累计达 `3` 次（≥ 3 阈值），沉淀长期语义记忆 `MF_001(v1)`
Day 07	`NE-05`	纯网元工单	支线 S1 (移动会议)	`17:30-18:15 (45min)` | 沪杭高速大巴 | `腾讯会议-视频会议` | `720p, ≤80ms` | `completed`	**跨流指代源点**：周四傍晚纯后台工单，作为次日 `S-02` 跨通道指代的目标记录
Day 08	`S-02`	多轮对话	支线 S1 (移动会议)	用户仅说“按上周四傍晚大巴车上那套会议配置再来一单” $\rightarrow$ 复用 `NE-05` 全套槽位	**跨模态工作记忆检索**：对话历史中无记录，Agent 必须检索网元单据表命中 `NE-05`
Day 09	`NE-06`, `NE-07`	纯网元工单（共 2 笔）	背景噪声单	`NE-06`：`21:00-21:45 (45min)` 腾讯视频看剧（单次偶发） `NE-07`：`22:10-22:13 (3min)` 抖音刷视频（未开保障短时单据）	**噪声抑制测试源**：检验记忆汇总时能否过滤频次为 1 的娱乐单与 3 分钟碎片短时单据
Day 10	`NE-08`	纯网元工单	支线 S1 (移动会议)	`17:30-18:15 (45min)` | 沪杭高速大巴 | `腾讯会议-视频会议` | `720p, ≤80ms` | `completed`	支线 S1 累计达 `3` 次，沉淀第二条条件长期偏好 `MF_002`
Day 10	`NE-09`, `NE-10`, `NE-11`	纯网元工单（共 3 笔）	事件窗 E1 (北京奥体)	① `NE-09`：上午 `09:30-10:15 (45min)` 彩排顺畅单（`PRB=42%, completed`） ② `NE-10`：午间 `12:30-14:00 (90min)` 正赛高负载拥塞单（`PRB=96%, freeze=8, sla_degraded`） ③ `NE-11`：下午 `14:05-14:06 (1min)` 误触主动撤单（`aborted`）	**同地三单并发与异常埋点**：既为 `S-03` 提供基站拥塞物理根因，又为 `S-05` 构造“奥体中心三选一”消歧现场
Day 12	`S-03` + `NE-12`	多轮对话 + 网元工单	事件窗 E1 (北京奥体)	用户抱怨前天奥体卡顿并指出“大型场馆得提前半小时预热调试” $\rightarrow$ 修正为 `12:00-14:00 (120min)` 生成 `NE-12`	**慢路径沉淀因果规则 1**：关联 `NE-10` 拥塞日志与用户纠偏，沉淀经验规则 `EXP_PREWARM_BUFFER_01`
Day 16	`S-04`	多轮对话	支线 S2 + 单次临时豁免	用户说“开播前跟搭档对一下抖音直播的词，今天带宽紧改 720p/100ms，别改老规矩” $\rightarrow$ `微信-视频通话, 30min`	**慢路径纠偏 2 + 临时隔离**：沉淀 `EXP_MULTI_INTENT_PARTITION_01`（对词=微信通话），且严禁覆盖长期画像 `1080p/50ms`
Day 20 ~ 21	`NE-13`, `NE-14`	纯网元工单（共 2 笔）	主线 M1 (**v2 升级**)	`12:30-14:00 (90min)` | 滨江基地 | `抖音-开直播` | `1080p, ≤50ms` | `completed`	**偏好版本演进**：主线午间直播时长正式由 `60min` 升级为 `90min`（`MF_001: v1 → v2`）
Day 22	`S-05`	多轮对话	事件窗回溯复刻	用户说“按上次在奥体办的那笔参数来，时长改 60 分钟” $\rightarrow$ 过滤撤单 `NE-11`、对比 `NE-09/10` 后选中 `NE-09` 修改时长	**同地多单消歧与局部覆写**：检验工作记忆无效单据剔除、异常单提示与跨槽位重算
Day 28	`S-06` + `NE-15`	多轮对话 + 网元工单	事件窗 E1 (异地工体)	用户说“今天 12:30 到 14:00 在工体中心场馆给阿抖开播，按老规矩超清档走” $\rightarrow$ Agent 1 轮自动预热为 `12:00-14:00 (120min)` 落地 `NE-15`	**跨地点快路径闭环**：跨场馆名称召回 `EXP_PREWARM_BUFFER_01` + `MF_001(v2)`，1 轮零追问直通

3 网元单据数据样本（NE-01 ~ NE-15）　　故事线到网元单据混合对话的数据样本实例

3 网元单据数据样本（`NE-01 ~ NE-15`）

本节给出时间轴上全部 15 笔网元单据（`working_records.json`）的具体数据样本。每一笔网元单据包含标准业务槽位（`service_app`、`location_zone`、`start_time`、`end_time`、`duration`、`resolution`、`max_latency`），还携带底层基站的物理测量指标（`telemetry`：无线资源块利用率 `prb_util_pct`、实测上行带宽 `ul_throughput_mbps`、卡顿次数 `freeze_count` 以及工单履约状态 `status`）。

3.1 15 笔网元单据全量槽位与物理指标表

表 3.1 列出了 `USER_001` 在 30 天内产生的全部 15 笔网元单据明细。为了避免评测集退化为固定时长或全成功工单的简单列表，单据流中同时包含了常态周期主线单、跨区移动支线单、单次娱乐偶发单、未开启保障的 3 分钟短时单据、同场馆同日 3 笔并发单（顺畅彩排单、`PRB=96%` 拥塞降级单、`1min` 误触撤单）以及 Day 20 时长升级后的新版本主线单。

表 3.1：`USER_001` 网元单据流（`NE-01 ~ NE-15`）全量业务槽位与物理 Telemetry 记录表

单号	日期	起止时间与时长	空间位置与基站小区	标准业务名（`service_app`）	目标 KQI 槽位	实测 Telemetry 与状态	样本角色定位
`NE-01`	Day 01	`12:30-13:30`（`60min`）	杭州-滨江直播基地（`5G-A_Binjiang_01`）	`抖音-开直播`	`1080p` | `≤50ms` `DEV_M60P`	PRB: `38%` | UL: `24.5Mbps` 卡顿: `0` | `completed`	主线 v1 第 1 单（由 `S-01` 触发）
`NE-02`	Day 03	`12:30-13:30`（`60min`）	杭州-滨江直播基地（`5G-A_Binjiang_01`）	`抖音-开直播`	`1080p` | `≤50ms` `DEV_M60P`	PRB: `41%` | UL: `23.8Mbps` 卡顿: `0` | `completed`	主线 v1 第 2 单（静默工单）
`NE-03`	Day 04	`17:30-18:15`（`45min`）	沪杭高速大巴走廊（`G60_Corridor`）	`腾讯会议-视频会议`	`720p` | `≤80ms` `DEV_MX5`	PRB: `52%` | UL: `12.4Mbps` 卡顿: `0` | `completed`	移动支线 S1 第 1 单
`NE-04`	Day 06	`12:30-13:30`（`60min`）	杭州-滨江直播基地（`5G-A_Binjiang_01`）	`抖音-开直播`	`1080p` | `≤50ms` `DEV_M60P`	PRB: `39%` | UL: `25.1Mbps` 卡顿: `0` | `completed`	主线 v1 满 3 次，确立长期语义记忆

单号	日期	起止时间与时长	空间位置与基站小区	标准业务名（service_app）	目标 KQI 槽位	实测 Telemetry 与状态	样本角色定位
NE-05	Day 07	17:30-18:15（45min）	沪杭高速大巴走廊（G60_Corridor）	腾讯会议-视频会议	720p | ≤80ms DEV_MX5	PRB: 49% | UL: 13.1Mbps 卡顿: 0 | completed	**S-02 跨流指代的目标源工单**
NE-06	Day 09	21:00-21:45（45min）	杭州-西湖住宅区（5G_Xihu_Res_04）	腾讯视频-看视频	1080p | ≤100ms DEV_M60P	PRB: 45% | DL: 65.0Mbps 卡顿: 0 | completed	**偶发干扰单**（频次=1，禁入长期画像）
NE-07	Day 09	22:10-22:13（3min）	杭州-西湖住宅区（5G_Xihu_Res_04）	抖音-刷视频	无保障（Best-Effort） DEV_M60P	PRB: 40% | UL: 4.2Mbps 状态: unassured_short	**短时背景噪声单**（3min 碎片，必须过滤）
NE-08	Day 10	07:30-08:15（45min）	沪杭高速大巴走廊（G60_Corridor）	腾讯会议-视频会议	720p | ≤80ms DEV_MX5	PRB: 47% | UL: 13.5Mbps 卡顿: 0 | completed	移动支线 S1 满 3 次，确立支线偏好
NE-09	Day 10	09:30-10:15（45min）	北京-奥体中心场馆（5G-A_Aoti_Stadium）	抖音-开直播	1080p | ≤50ms DEV_M60P	PRB: 42% | UL: 22.6Mbps 卡顿: 0 | completed	**奥体同日第 1 单**（上午空场彩排，顺畅）
NE-10	Day 10	12:30-14:00（90min）	北京-奥体中心场馆（5G-A_Aoti_Stadium）	抖音-开直播	1080p | ≤50ms DEV_M60P	**PRB: 96% | UL: 6.8Mbps 卡顿: 8次 | sla_degraded**	**奥体同日第 2 单**（正赛拥塞劣化，触发 S-03）
NE-11	Day 10	14:05-14:06（1min）	北京-奥体中心场馆（5G-A_Aoti_Stadium）	抖音-开直播	1080p | ≤50ms DEV_M60P	PRB: 94% | 耗时: 48s 状态: aborted（用户撤单）	**奥体同日第 3 单**（1min 误触中途取消的无效单据）
NE-12	Day 12	12:00-14:00（120min）	北京-奥体中心场馆（5G-A_Aoti_Stadium）	抖音-开直播	1080p | ≤50ms DEV_M60P（含30m预热）	PRB: 89% | UL: 21.4Mbps 卡顿: 0 | completed	S-03 慢路径纠偏后提前 30min 预热成功单
NE-13	Day 20	12:30-14:00（90min）	杭州-滨江直播基地（5G-A_Binjiang_01）	抖音-开直播	1080p | ≤50ms DEV_M60P	PRB: 40% | UL: 24.2Mbps 卡顿: 0 | completed	**主线 v2 升级第 1 单**（时长由 60m 升为 90m）
NE-14	Day 21	12:30-14:00（90min）	杭州-滨江直播基地（5G-A_Binjiang_01）	抖音-开直播	1080p | ≤50ms DEV_M60P	PRB: 37% | UL: 24.9Mbps 卡顿: 0 | completed	**主线 v2 升级第 2 单**（巩固 90min 新版本）
NE-15	Day 28	12:00-14:00（120min）	北京-工体中心场馆（5G-A_Gongti_Stadium）	抖音-开直播	1080p | ≤50ms DEV_M60P（含30m预热）	PRB: 91% | UL: 22.0Mbps 卡顿: 0 | completed	S-06 跨场馆快路径自动预热闭环落地单

3.2 网元单据 JSON 数据样本（NE-05 与奥体同日三单 NE-09/10/11）

为直观展示工作记忆记录的底层数据结构，清单 3.1 给出了 working_records.json 中最具代表性的 4 笔单据原始 JSON：Day 07 的高速大巴移动会议工单 NE-05（无配套对话，供后续 S-02 跨通道指代），以及 Day 10 在北京奥体中心同日产生的 3 笔同地点工单 NE-09、NE-10、NE-11。

数据样本 3.1：网元单据流 JSON 样本片段（NE-05 与奥体同日三单 NE-09/10/11） 文件路径：mobile_persona_001/working_records.json


```
[
  {
    "record_id": "NE-05",
    "day": 7,
    "weekday": "Thursday",
    "channel": "network_element_ticket",
    "linked_session_id": null,
    "slots": {
      "device_id": "DEV_MX5",
      "location_zone": "沪杭高速大巴移动走廊",
      "cell_id": "G60_HighSpeed_Corridor",
      "service_app": "腾讯会议-视频会议",
      "start_time": "17:30",
      "end_time": "18:15",
      "duration": "45min",
      "resolution": "720p",
      "max_latency": "80ms"
    },
    "telemetry": {
      "status": "completed",
      "prb_util_pct": 49,
      "ul_throughput_mbps": 13.1,
      "handover_count": 6,
      "freeze_count": 0
    }
  },
  {
    "record_id": "NE-09",
    "day": 10,
    "channel": "network_element_ticket",
    "slots": {
      "device_id": "DEV_M60P",
      "location_zone": "北京-奥体中心场馆",
      "cell_id": "5G-A_Aoti_Stadium_01",
      "service_app": "抖音-开直播",
      "start_time": "09:30",
      "end_time": "10:15",
      "duration": "45min",
      "resolution": "1080p",
```

```
      "max_latency": "50ms"
    },
    "telemetry": {
      "status": "completed",
      "prb_util_pct": 42,
      "ul_throughput_mbps": 22.6,
      "freeze_count": 0,
      "qos_Diagnostic": "上午空场彩排时段，基站负载正常，推流顺畅"
    }
  },
  {
    "record_id": "NE-10",
    "day": 10,
    "channel": "network_element_ticket",
    "slots": {
      "device_id": "DEV_M60P",
      "location_zone": "北京-奥体中心场馆",
      "cell_id": "5G-A_Aoti_Stadium_01",
      "service_app": "抖音-开直播",
      "start_time": "12:30",
      "end_time": "14:00",
      "duration": "90min",
      "resolution": "1080p",
      "max_latency": "50ms"
    },
    "telemetry": {
      "status": "sla_degraded",
      "degradation_reason": "cell_prb_congestion_at_peak_entry",
      "prb_util_pct": 96,
      "ul_throughput_mbps": 6.8,
      "freeze_count": 8,
      "qos_diagnostic": "12:30 观众集中入场导致 PRB 瞬时飙升至 96%，未提前锁流导致前 15 分钟出现 8 次画面卡顿"
    }
  },
  {
    "record_id": "NE-11",
    "day": 10,
    "channel": "network_element_ticket",
    "slots": {
      "device_id": "DEV_M60P",
      "location_zone": "北京-奥体中心场馆",
      "cell_id": "5G-A_Aoti_Stadium_01",
      "service_app": "抖音-开直播",
      "start_time": "14:05",
      "end_time": "14:06",
      "duration": "1min",
      "resolution": "1080p",
      "max_latency": "50ms"
    },
    "telemetry": {
      "status": "aborted",
      "abort_reason": "user_cancelled_within_60s",
      "actual_active_seconds": 48,
      "qos_diagnostic": "下播后误触重新提交，48 秒后用户主动撤单，属无效无效单据"
    }
  }
]
```


4 自然语言多轮对话数据样本（`S-01 ~ S-06`）

本节给出 6 场自然语言多轮对话（`S-01 ~ S-06`）的完整样本数据，包括对话生成前的用户侧与系统侧双盲输入视图、逐轮真实对话原文以及每场对话落盘后的槽位来源字典（`turn_intents`）。

4.1 用户端与 Agent 端隔离视图数据样本（以 `S-06` 为例）

每一场对话的输入数据由两份物理隔离的 JSON 视图构成：**用户私有视图**（`user_private_view`）仅包含用户的真实业务诉求、口语词典与首轮禁词表（`turn1_forbidden_values`，严禁首轮直接说出被省略的记忆槽位标准值）；**Agent 可观测视图**（`agent_observable_view`）仅包含截止到当前日期之前的历史网元单据记录与已沉淀的四类记忆快照，严禁透视当轮真值槽位。下方数据样本 4.1 说明 `S-06 (Day 28)` 的双盲输入视图数据。

数据样本 4.1：`S-06 (Day 28 工体中心异地开播)` 双盲信息隔离输入视图对比 JSON　　文件路径：mobile_persona_001/isolated_views/S-06.json


```
{
  "session_id": "S-06",
  "day": 28,
  "user_private_view": {
    "current_situation": "今天（Day 28）在北京工体中心场馆有一场 12:30 到 14:00 的午间直播，希望按日常超清直播标准保障，且默认系统已记住之前大型场馆需提前半小时预热的规矩",
    "colloquial_hints": ["阿抖", "老规矩", "超清档"],
    "turn1_forbidden_values": [
      "抖音-开直播", "1080p", "50ms", "DEV_M60P", "提前30分钟", "12:00", "120min"
    ],
    "hidden_ground_truth_intent": {
      "device_id": "DEV_M60P",
      "location_zone": "北京-工体中心场馆",
      "service_app": "抖音-开直播",
      "start_time": "12:00",
      "end_time": "14:00",
      "duration": "120min",
      "resolution": "1080p",
      "max_latency": "50ms"
    }
  },
```

```
  "agent_observable_view": {
    "hidden_ground_truth_intent": "<<< PHYSICALLY MASKED >>>",
    "current_user_utterance_turn_1": "今天 12:30 到 14:00 我在北京工体中心场馆给阿抖开播，按老规矩超清档走，直接帮我把保障单下了吧。",
    "memory_snapshot_before_day_28": {
      "semantic_facts": ["MF_001 (v2): 午间 12:30-14:00 (90min) 抖音-开直播, 1080p, <=50ms, DEV_M60P"],
      "working_tickets": ["NE-01 .. NE-14 (含 NE-10 奥体拥塞单与 NE-12 奥体 120min 预热单)"],
      "experience_rules": [
        "EXP_PREWARM_BUFFER_01: 当 location_zone 属于大型高密场馆且业务为直播时，主动将 start_time 提前 30min 预热锁流，duration 同步 +30min",
        "EXP_MULTI_INTENT_PARTITION_01: 当口语提及'对词/看机位'时路由至微信-视频通话（本轮不触发）"
      ]
    }
  }
}
```


4.2 S-01 ~ S-03 多轮对话原文与槽位结果

下面逐场给出前半程 S-01 （Day 01 冷启动建档）、S-02 （Day 08 跨流指代纯网元工单 NE-05 ）与 S-03 （Day 12 关联 NE-10 基站拥塞退化并慢路径沉淀场馆预热经验规则）的真实多轮对话文本与槽位溯源结构。

会话样本 1：S-01 (Day 01) —— 零记忆冷启动 3 轮澄清与个性化口语词典建档

【背景状态】：Day 01 初始时刻，四类记忆库均为空（ snapshot_before = [] ）。用户首次发起模糊请求。

- **Turn 1 [User]**：“中午我在杭州滨江基地这边准备给阿抖开场直播，帮我把专网保障开一下，千万别转圈。”
- **Turn 1 [Agent]**：“收到，林先生！检测到您当前为首次配置滨江基地直播保障。已为您匹配【抖音-开直播】业务与低时延防卡顿档位（时延 ≤50ms）。为精准锁定专网切片，请确认：1）今天中午具体的起止时间与时长；2）需要绑定的直播终端（您名下有 Mate 60 Pro 与 Mate X5）；3）推流清晰度要求（720p 或 1080p）？”
- **Turn 2 [User]**：“时间定在 12:30 到 13:30 播满 60 分钟，用我那台主力机 Mate 60 Pro，画质肯定要 1080p 超清档。对了，以后我提‘老规矩’或者‘中午那档’，指的就是这套配置。”
- **Turn 2 [Agent]**：“明白！已为您记下【老规矩/阿抖/超清档】的专属配置偏好，并正式下发今日保障工单 NE-01：【终端】Mate 60 Pro (DEV_M60P) | 【位置】杭州-滨江直播基地 | 【业务】抖音-开直播 | 【时段】12:30-13:30 (60min) | 【指标】1080p，时延 ≤50ms。”

【槽位溯源 turn_intents 与记忆沉淀】：全量 7 个槽位来源均为 user_explicit_clarification ；对话结束后注册口语映射表（ 阿抖→抖音-开直播 、 老规矩→12:30起播 、 超清档→1080p 、 千万别转圈→≤50ms ），并生成首笔工单 NE-01 。

会话样本 3：S-03 (Day 12) —— 关联 NE-10 基站拥塞日志与慢路径沉淀场馆预热经验规则

【背景状态】：两天前（Day 10）用户在奥体中心执行正赛直播工单 NE-10 (12:30-14:00, 90min) 时，因 12:30 观众入场高峰导致基站 PRB=96% ，发生 8 次严重画面卡顿（ sla_degraded ）。Day 12 用户再次在奥体中心发起直播。

- **Turn 1 [User]**：“今天中午 12:30 到 14:00 我还在北京奥体中心场馆给阿抖开播，按老规矩来。”
- **Turn 1 [Agent]**：“收到，准备为您按日常直播偏好配置今日奥体中心保障：【时段】12:30-14:00 (90min) | 【业务】抖音-开直播 | 【指标】1080p, ≤50ms | 【终端】Mate 60 Pro。请确认是否下发？”
- **Turn 2 [User]**：“等等！不能直接按 12:30 踩点开！前天（Day 10）中午在奥体中心 12:30 刚开播那会儿卡得厉害，画面连着冻了七八次！这种万人大型场馆人流一进来基站全挤爆了，必须提前半小时从 12:00 就开始预热锁流调试，一直保到 14:00！以后凡是去这种大型高密场馆直播都按这个规矩办！”
- **Turn 2 [Agent]**：“非常抱歉！刚核对了前天奥体中心工单 NE-10 的底层网元日志，12:30 正赛入场高峰时基站 PRB 负载确实飙升至 96%，上行跌至 6.8Mbps 导致了 8 次卡顿。已为您将今日工单 NE-12 修正为【12:00-14:00（总时长 120min，含前 30min 预热锁流）】，同时将【大型高密场馆直播自动提前 30 分钟预热扩容（EXP_PREWARM_BUFFER_01）】写入您的长期经验记忆库，后续去同类场馆将自动为您预热！”

数据样本 3.6：S-03 (Day 12) 慢路径纠偏槽位演化与因果经验规则沉淀 JSON 明细 文件路径：mobile_persona_001/sessions.json (S-03)


```
{
  "session_id": "S-03",
  "day": 12,
  "mode": "slow_path_correction_and_rule_crystallization",
  "linked_ticket_evidence": "NE-10 (Day 10, PRB=96%, freeze_count=8, status=sla_degraded)",
  "slot_revision_trace": {
    "draft_in_turn_1": {"start_time": "12:30", "end_time": "14:00", "duration": "90min"},
    "revised_in_turn_2": {"start_time": "12:00", "end_time": "14:00", "duration": "120min"},
    "revision_action": "prepend_prewarm_buffer(delta_start=-30min, delta_duration=+30min)"
  },
  "crystallized_experience_rule": {
    "rule_id": "EXP_PREWARM_BUFFER_01",
    "trigger_condition": "scene_type == '大型高密场馆/体育中心' AND service_app == '抖音-开直播'",
    "root_cause": "万人场馆正赛入场时刻基站 PRB 瞬时拥塞（>95%），踩点开播易抢不到高优上行切片",
    "action_policy": "自动将用户请求的 start_time 提前 30 分钟开启预热锁流，end_time 不变，duration 同步增加 30 分钟"
  }
}
```


3.1.4.3 S-04 ~ S-06 多轮对话原文与槽位结果

后半程的三场对话重点检验：**字面关键词陷阱纠偏与单次临时豁免隔离（ S-04 ）、工作记忆同地多笔工单（含异常单与无效撤单）的对比消歧（ S-05 ），以及间隔 16 天后在全新场馆（北京工体中心）对沉淀经验的1 轮快路径泛化闭环（ S-06 ）。**

会话样本 4：S-04 (Day 16) —— 字面陷阱慢路径纠偏（“对抖音的词” $\neq$ 抖音直播）与单次临时降档豁免

【背景状态】：用户口头提到“抖音直播”，但真实意图是在正式开播前用备机跟搭档通过微信视频通话对台本；同时因当天驻地网络受限，临时要求本场降为 720p / 100ms ，但严禁修改长期习惯。

- **Turn 1 [User]**：“上午 11:00 到 11:30 我在滨江基地得先跟搭档连线对一下中午抖音直播的词、顺便看眼机位，帮我保一下。”
- **Turn 1 [Agent]**：“收到！检测到关键词‘抖音直播’，准备为您下发【抖音-开直播 | 11:00-11:30 (30min) | 1080p, ≤50ms | Mate 60 Pro】保障单，请确认？”
- **Turn 2 [User]**：“搞错了！我是正式开播前跟搭档一对一连线对台本看机位，用的是备机 Mate X5 打【微信视频通话】，不是直接上抖音开播！另外今天上午基地内网改造带宽紧，单就今天这一场给我降成 720p、时延放宽到 100ms 就行，千万别动我中午正式直播的老规矩！”
- **Turn 2 [Agent]**：“明白！已为您纠正业务映射并记录经验规则【开播前对词/看机位 → 路由至 Mate X5 微信-视频通话（EXP_MULTI_INTENT_PARTITION_01）】。本场保障单已按【微信-视频通话 | 11:00-11:30 (30min) | 720p, ≤100ms | Mate X5】下发，且已标记为单次临时豁免（session_scoped_override），绝不覆盖您 1080p/50ms 的长期直播画像！”

会话样本 5： `S-05 (Day 22)` —— **工作记忆同地多单消歧（过滤** `NE-11` **无效撤单、辨析** `NE-09/10` **）与局部覆写**

【背景状态】：Day 10 用户在奥体中心留下了 3 笔工单：上午顺畅彩排单 `NE-09 (45min, completed)`、午间拥塞劣化单 `NE-10 (90min, sla_degraded)` 与下午 1 分钟撤单无效撤单 `NE-11 (1min, aborted)`。Day 22 用户发起模糊复刻请求。

- **Turn 1 [User]**：“帮我按上次在北京奥体中心彩排那会儿跑通的那笔参数再来一单，不过今天时间改到 10:00 开始，播满 60 分钟。”
- **Turn 1 [Agent]**：“正在检索您在【北京-奥体中心场馆】的历史网元单据：已自动为您剔除 1 分钟内撤单的无效记录 NE-11 (aborted)，并排除午间发生基站拥塞降级的正赛单 NE-10 (PRB=96%, sla_degraded)，精准锁定 Day 10 上午运行顺畅的彩排工单 NE-09（抖音-开直播, 1080p, ≤50ms, Mate 60 Pro）。按您的要求将时段局部覆写为【10:00-11:00 (60min)】，其余参数保持不变，是否确认执行？”
- **Turn 2 [User]**：“完全正确，就按这个下发。”

会话样本 6： `S-06 (Day 28)` —— **跨场馆快路径 1 轮直通闭环（联合召回长期画像** `MF_001(v2)` **+ 场馆预热经验** `EXP_PREWARM_BUFFER_01` **）**

【背景状态】：距离 Day 12（ `S-03` ）沉淀奥体中心预热规则已过去 16 天，期间经历了多次常规直播、微信对词支线以及 Day 20 的主线时长升级（ `v2: 90min` ）。Day 28 用户首次来到全新场馆**“北京工体中心场馆”**。

- **Turn 1 [User]**：“今天 12:30 到 14:00 我在北京工体中心场馆给阿抖开播，按老规矩超清档走，直接帮我把保障单下了吧。”
- **Turn 1 [Agent]**：“收到，林先生！已为您联合匹配长期直播画像与大型场馆保障经验，无需额外追问，直接为您生成今日工体中心专网工单 NE-15： 1）【口语与长期画像补全 (MF_001 v2)】：‘阿抖/超清档/老规矩’映射为【抖音-开直播 | 1080p | 时延 ≤50ms | 主力机 Mate 60 Pro (DEV_M60P)】； 2）【跨场馆经验规则主动介入 (EXP_PREWARM_BUFFER_01)】：识别到【北京-工体中心场馆】同属万人高密场馆，为避免正赛入场基站 PRB 拥塞卡顿，已自动为您将起播时间从 12:30 提前 30 分钟至【12:00】开启预热锁流，保障时段调整为【12:00-14:00（总时长 120min）】。工单已生效！”

数据样本 3.7： `S-06 (Day 28)` **快路径 1 轮直通的全槽位多源溯源字典（** `turn_intents` **）** 文件路径：mobile_persona_001/sessions.json (S-06)


```
{
  "session_id": "S-06",
  "day": 28,
  "interaction_mode": "fast_path_single_turn_closure",
  "total_turns": 1,
  "final_slots_and_provenance": {
    "location_zone": {
      "value": "北京-工体中心场馆",
      "source": "current_turn_utterance"
    },
    "service_app": {
      "value": "抖音-开直播",
      "source": "colloquial_lexicon('阿抖') + semantic_memory('MF_001_v2')"
    },
    "device_id": {
      "value": "DEV_M60P",
      "source": "semantic_memory('MF_001_v2')"
    },
    "resolution": {
      "value": "1080p",
      "source": "colloquial_lexicon('超清档') + semantic_memory('MF_001_v2')"
    },
    "max_latency": {
      "value": "50ms",
      "source": "semantic_memory('MF_001_v2')"
    },
    "start_time": {
      "value": "12:00",
      "raw_user_input": "12:30",
      "source": "experience_memory_override('EXP_PREWARM_BUFFER_01', delta=-30min)"
    },
    "end_time": {
      "value": "14:00",
      "source": "current_turn_utterance + semantic_memory('MF_001_v2')"
    },
    "duration": {
      "value": "120min",
      "raw_user_implied": "90min",
      "source": "experience_memory_recalc('EXP_PREWARM_BUFFER_01', 14:00 - 12:00 = 120min)"
    }
  }
}
```


3.1.5 样本对应的四类记忆真值快照与评测样本对

在 30 天的 15 笔网元单据与 6 场多轮对话执行完毕后，该混合样本在 Day 30 终态对应一份唯一的**四类记忆标准真值快照**（ `gold_memory_snapshot.json` ），以及配套的**记忆萃取（M 与 N 对比）**与**记忆检索（P 与 Q 对比）**评测问答对。

3.1.5.1 Day 30 按业务场景独立分片的四类记忆真值 JSON（ `gold_memory_snapshot.json` ）

数据样本 3.8 给出了 `USER_001` 在 Day 30 结束时的标准记忆状态快照。该快照同时体现两层结构：第一，遵循 `CoALA` 实行**短期工作记忆**（ `1_short_term_working_memory` ）**与三类长期记忆（语义记忆、情景记忆、程序化/经验记忆）分层管理**；第二，在长期记忆层，**按前期意图拆解出的不同业务场景**（ `scenario_id` ）**各自维护一份独立的场景记忆分片**（ `3_per_scenario_long_term_memories` ），且对于该用户未涉足或偶发未达标的业务场景（如手游电竞、长视频点播、工程巡检回传），在 `4_uninitialized_scenarios` 中显式标记为不存在（ `null` ），防止跨业务场景错误套用记忆：

数据样本 3.8： `USER_001` **在 Day 30 终态下按业务场景独立分片的记忆标准快照（** `gold_memory_snapshot.json` **）** 文件路径：mobile_persona_001/gold_memory_snapshot.json


```
{
  "user_id": "USER_001",
  "snapshot_day": 30,
  "1_short_term_working_memory": {
    "lifecycle": "short_term_active_session_scratchpad",
    "active_task_id": "TASK_SUB_02",
    "active_scenario_id": "SCENARIO_03_STADIUM_LIVE",
    "active_session_slots_after_day28_s06": {
```

```
    "location": "北京工体中心", "service_app": "抖音-开直播",
    "start_time": "12:00", "end_time": "14:00", "duration": "120min", "resolution": "1080p"
  },
  "retrieved_long_term_memory_refs": ["MF_001", "EP_STADIUM_TOUR_01", "NE-12", "EXP_PREWARM_BUFFER_01"]
},
"2_user_global_semantic_base": {
  "vip_tier": "钻石级 VIP (5G-A 专网保障签约用户)",
  "bound_devices": {"DEV_M60P": "主力直播终端", "DEV_MX5": "移动办公与视频连线终端"},
  "colloquial_lexicon_mappings": {
    "阿抖": "抖音-开直播",
    "老规矩 / 中午那档": "12:30 起播午间直播主线配置",
    "超清档": "1080p",
    "千万别转圈": "max_latency <= 50ms"
  }
},
"3_per_scenario_long_term_memories": {
  "SCENARIO_01_BASE_LIVE": {
    "bound_task_id": "TASK_MAIN_01",
    "scenario_name": "杭州滨江固定基地日常技术直播场景",
    "semantic_memory": {
      "fact_id": "MF_001",
      "active_version": "v2 (upgraded_on_day_20)",
      "slots": {
        "device_id": "DEV_M60P", "service_app": "抖音-开直播",
        "start_time": "12:30", "end_time": "14:00", "duration": "90min",
        "resolution": "1080p", "max_latency": "50ms"
      },
      "superseded_versions": [
        {"version": "v1", "effective_days": "Day 01~19", "duration": "60min (12:30-13:30)", "status": "superseded"}
      ]
    },
    "episodic_memory": {
      "valid_order_record_ids": ["NE-01", "NE-02", "NE-04", "NE-08", "NE-13", "NE-14"],
      "temporary_event_overrides": [
        {"session_id": "S-04 (Day 16)", "override": {"resolution": "720p", "max_latency": "100ms"}, "status": "expired_single_session_only"}
      ]
    },
    "procedural_experiential_memory": []
  },
  "SCENARIO_02_HIGHWAY_MEETING": {
    "bound_task_id": "TASK_SUB_01",
    "scenario_name": "沪杭高速大巴移动跨城远程视频会议场景",
    "semantic_memory": {
      "fact_id": "MF_002",
      "active_version": "v1",
      "slots": {
        "device_id": "DEV_MX5", "service_app": "腾讯会议-视频会议",
        "start_time": "17:30", "end_time": "18:15", "duration": "45min",
        "resolution": "720p", "max_latency": "80ms", "handover_protection": true
      }
    },
    "episodic_memory": {
      "valid_order_record_ids": ["NE-03", "NE-05"]
    },
    "procedural_experiential_memory": []
  },
  "SCENARIO_03_STADIUM_LIVE": {
    "bound_task_id": "TASK_SUB_02",
    "scenario_name": "大型高密体育场馆巡回技术直播推流场景",
    "semantic_memory": {
      "inherited_base_slot_ref": "MF_001 (抖音-开直播, 1080p, DEV_M60P)"
    },
    "episodic_memory": {
      "episodic_event_window": {
        "episode_id": "EP_STADIUM_TOUR_01",
        "time_span": "Day 10 ~ Day 12 (及 Day 28 返场)",
        "venues": ["北京奥体中心", "北京工体中心"]
      },
      "valid_order_record_ids": ["NE-09 (completed)", "NE-12 (completed, prewarm_30m)", "NE-15 (completed, prewarm_30m)"],
      "degraded_warning_order_ids": ["NE-10 (AppQuality=bad, PRB=96%, freeze=8)"],
      "filtered_invalid_order_ids": ["NE-11 (1min中途取消的无效单据)"]
    },
    "procedural_experiential_memory": [
      {
        "rule_id": "EXP_PREWARM_BUFFER_01",
        "source_evidence": "S-03 (Day 12) + NE-10 (bad) 与 NE-12 (good) 对比",
        "when_condition": "目标业务场景属于大型高密体育场馆/会展中心 (SCENARIO_03_STADIUM_LIVE) AND 业务为上行直播",
        "then_action": "自动将 start_time 提前 30min 开启专网切片预热锁流，end_time 保持不变，duration 同步 +30min",
        "scope_exclude": ["常驻室内固定基地场景 (SCENARIO_01_BASE_LIVE)", "下行视频点播", "普通语音通话"]
      }
    ]
  },
  "SCENARIO_04_PARTNER_REHEARSAL": {
    "bound_task_id": "TASK_SUB_03",
    "scenario_name": "开播前与搭档一对一远程视频对词及机位确认场景",
    "semantic_memory": {
      "slots": {"device_id": "DEV_MX5", "service_app": "微信-视频通话"}
    },
    "episodic_memory": {"source_session": "S-04 (Day 16)"},
    "procedural_experiential_memory": [
      {
        "rule_id": "EXP_MULTI_INTENT_PARTITION_01",
        "when_condition": "用户话语虽含'抖音直播'字眼，但核心任务动作为'开播前跟搭档对词/看机位'",
        "then_action": "切换至任务 TASK_SUB_03 (SCENARIO_04_PARTNER_REHEARSAL)，路由至 微信-视频通话 + 备用机 DEV_MX5，禁止误触发主线任务 TASK_MAIN_01"
      }
    ]
  }
},
"4_uninitialized_scenarios": {
```

```
    "SCENARIO_05_MOBILE_GAMING": null,
    "SCENARIO_06_VIDEO_VOD": null,
    "SCENARIO_07_FIELD_INSPECTION_UPLOAD": null,
    "audit_note": "上述业务场景在该用户下不存在记忆分片（NE-06 腾讯视频仅偶发 1 次未达标，NE-07 僅 3min 未保障短时流量，均已拦截）；当测试题询问快手游戏直播等未覆盖业务场景时，禁止跨场景套
  }
}
```

3.1.5.2 配套记忆萃取（`M` 与 `N` 对比）与记忆检索（`P` 与 `Q` 对比）测试题样本

有了上述混合样本流与真值快照，可进一步派生出两阶段评测基准题：表 5.1 说明针对该样本的**记忆萃取阶段（M 与 N 对比）**核心考核点与正误判分示例；表 5.2 说明针对该样本的**记忆检索阶段（P 与 Q 对比）**六类检索探测题实例。

表 3.3：基于 `USER_001` 混合样本派生的记忆萃取阶段（模型预测集 M 与标准真值集 N 对比）评测实例表

目标记忆类型	萃取评测子能力	输入混合流片段证据	标准真值集 N 要求	典型错误预测 M（扣分项）
【长期记忆 ①】事实 — 语义记忆	偏好抽取与口语映射	`S-01` 口语约定 + `NE-01/02/04` 连续 3 次同分布工单	抽取 `抖音-开直播, 1080p, ≤50ms, DEV_M60P`，建立 `阿抖/老规矩/超清档` 映射	漏掉口语词典映射，或未满 3 次即提前写入长期习惯
	偏好整合（版本覆盖）	Day 01~19 的 `60min` 工单 + Day 20~21 的 `NE-13/14 (90min)`	将 `MF_001` 的活跃时长更新为 `90min (12:30-14:00)`，旧版 `60min` 归档	新旧版本并存冲突，或仍返回旧版 `60min`
	噪声抑制与临时豁免	`NE-06`（单次腾讯视频）、`NE-07`（3min 短时单据）、`S-04`（单场 720p/100ms）	三者均被严格拦截在长期语义记忆之外（噪声混入率 $= 0$）	把单次看剧或 `S-04` 临时降档误写入长期画像
【长期记忆 ②】事实 — 情景记忆（单据流水）	多单状态标记与无效撤单清洗	Day 10 奥体三单 `NE-09 (completed)`、`NE-10 (sla_degraded)`、`NE-11 (aborted)`	剔除 1 分钟撤单 `NE-11`，保留 `NE-09` 为正常基准并标记 `NE-10` 为拥塞劣化	未过滤 `NE-11` 无效撤单，或把 `NE-10` 劣化单当作正常模板
【长期记忆 ③】程序化 / 经验记忆	长流定位澄清案例并提取因果规则	在 21 个混合节点中定位 `S-03 (+NE-10)` 与 `S-04` 两处慢路径纠偏会话	准确提取 `EXP_PREWARM_BUFFER_01` 与 `EXP_MULTI_INTENT_PARTITION_01` 两条结构化规则	漏检 `S-03/S-04` 澄清节点，或把 `S-01` 常规补槽误当成纠偏规则

表 3.4：基于 `USER_001` 混合样本派生的记忆检索阶段（检索返回集 P 与相关真值集 Q 对比）评测实例表

检索评测维度	在线测试 Query 输入	相关记忆真值集 Q（必须召回项）	干扰排除与排序判分要点
1. 口语映射与时效排序检索	“今天中午在滨江基地给阿抖开播，按老规矩走。”（Day 25 发起）	`MF_001 (v2: 12:30-14:00, 90min)` + 口语词典 `阿抖→抖音-开直播`	`v2 (90min)` 必须排在 Top-1；若返回已过期的 `v1 (60min)` 判时效倒置失败
2. 跨模态纯单据指代检索	“按上周四傍晚在沪杭大巴车上办过的那套会议参数再来一单。”（`S-02`）	长期情景记忆中的历史网元单据 `NE-05 (DEV_MX5, 腾讯会议, 17:30-18:15, 45min, 720p, ≤80ms)` 读入短期工作记忆	历史对话流中无记录，仅查对话历史的检索器召回率为 `0`
3. 同地多单消歧与排除检索	“按上次在北京奥体中心彩排跑通的那笔参数来，时长改 60 分钟。”（`S-05`）	召回 `NE-09 (09:30-10:15, completed)`	必须排除撤单无效撤单 `NE-11 (aborted)` 与午间拥塞单 `NE-10 (sla_degraded)`
4. 跨地点经验泛化与组合检索	“今天 12:30 到 14:00 在北京工体中心场馆给阿抖开播，按老规矩超清档走。”（`S-06`）	联合召回 `MF_001 (v2)` + 场馆预热经验规则 `EXP_PREWARM_BUFFER_01`	虽未出现“奥体”字面词，但需识别“工体中心”同属大型场馆并触发提前 30min 预热（`12:00-14:00, 120min`）
5. 字面陷阱经验抑制与精准路由	“开播前我先用备机跟搭档连线对一下中午抖音直播的词。”	召回经验规则 `EXP_MULTI_INTENT_PARTITION_01`（路由至 `微信-视频通话 + DEV_MX5`）	严禁被字面词“抖音直播”误导而召回 `MF_001 (抖音-开直播)` 或 `EXP_PREWARM_BUFFER_01`
6. 缺失槽位诚实拒答与追问	“今晚 20:00 我在广州天河体育中心想用快手开一场游戏直播。”	召回 `EXP_PREWARM_BUFFER_01`（大型场馆预热），但识别出 `快手-游戏直播` 无历史清晰度/结束时间记录	禁止拿抖音参数硬套快手；必须对缺失的结束时间与画质发起澄清追问

3.2 实例二：现场运维人员 4 周 12 事件状态表推演与 “仅单据”与“单据+对话”双输入对照（`USER_002` 现场运维工程师）

为进一步展示第 1.4 节所述**“第 4 步：关键事件前后状态中间表”**、**“主次活动线并发资源争抢”**、**“事件发生时间与单据延迟到达时间分离”**以及**“同故事骨架下纯单据版（仅单据输入）与单据加对话混合版（单据+对话输入）的标准答案对照”**，本节给出第二个完整构造实例：现场工程与设备运维人员陈宁（`USER_002`）跨越 4 周、12 个事件的完整故事线推演。

3.2.1 两层因子选型与主次活动线并发设定

- **人物基底（`USER_002` 现场运维工程师）：**现场工程与设备运维人员；常用位置包括工地驻点宿舍（夜间固定办公区）与施工现场（日间移动巡检区）；持有主力 5G 手机 `D1`（用于移动热点与现场巡检回传）与笔记本电脑 `D2`（夜间通过热点接入培训与同步工程包）。
- **主支线意图拆解为两个独立任务及分场景稀疏记忆：**1）**主线任务 `TASK_MAIN_TRAINING`（绑定业务场景 `SCENARIO_08_DORM_TRAINING`：驻点晚间远程培训视频会议）**：每周二、周四 `20:00-21:30` 在驻点宿舍使用笔记本 `D2` 参加认证培训，理想目标为 `1080p` 高清与语音零卡顿，拥塞时可接受画面降至 `720p`，但**不可接受语音断续或掉线（底线约束）**；2）**支线任务 `TASK_SUB_UPLOAD`（绑定业务场景 `SCENARIO_07_FIELD_INSPECTION_UPLOAD`：工程巡检数据包云端同步上传）**：日常在 `21:30` 培训任务结束后上传当日数 GB 工程日志与巡检图像，但在第 2 周周四（`E05`）因白天巡检任务积压，**支线上传任务提前至 `20:05` 并发启动，与主线培训任务在同一移动热点上发生同窗上行带宽争用**；3）**单用户分场景记忆稀疏性对照：**`USER_002` 仅在 `SCENARIO_08_DORM_TRAINING` 与 `SCENARIO_07_FIELD_INSPECTION_UPLOAD` 两个业务场景下建有独立记忆分片（第 2 周外甥临时借平板看儿童动画 `E07` 被识别为他人借用，不建立点播场景分片），而 `USER_001` 所拥有的固定基地直播（`SCENARIO_01`）、大型场馆推流（`SCENARIO_03`）等业务场景在 `USER_002` 名下均为空（`null`）。
- **排布与可见性设计：**时间跨度 4 周，共 12 个事件（`E01 ~ E12`），其中 `E05 ~ E09` 构成完整因果闭环链；同时在第 3 周设置单据延迟上报（`E08` 发生在周二晚，但网元统计单据延迟至周三上午 `10:30` 才到达系统），并同步输出 仅单据 纯单据版与 单据+对话 混合版。

3.2.2 关键事件前后状态中间表与 12 事件完整演进表

表 3.5 给出了在生成具体记录前先行锁定的**关键事件前后状态中间表**，明确每次状态跳变的触发原因、单据可观测表现与对话补充信息；表 3.6 给出了展开后的 4 周 12 事件排期、发生时间与到达时间对照。

表 3.5：实例二（`USER_002` 现场运维工程师）关键事件前后状态中间表（Intermediate State Table）

关键事件	发生与到达时间	事件前状态（Before State）	触发原因与事件后新状态（After State）	网元单据可观测表现（仅单据可见）	对话补充信息（仅单据+对话可见）
`E01/E03` 基线建立	W1 周二/周四 `20:00–21:30`	初始无长期习惯记录（冷启动）	连续两次周二、周四晚间固定时段完成远程培训会议，错峰在 `21:35` 后执行工程包上传，两线互不干扰。	两条会议单据（`1080p`，时延 \(38\text{ms}\)，零卡顿）+ 两条 `21:35` 后大上行上传单据。	无对话（日常顺畅体验沉默，体现观测选择偏差）。
`E05` 并发冲突爆发	W2 周四 `20:00–21:30`（准时到达）	\(L_1\) 会议与 \(L_2\) 上传默认错峰运行	**触发原因：**日间施工数据积压，后台同步任务在 `20:05` 自动启动，与正在进行的培训会议争抢同一手机热点上行带宽；**新状态：**会议画面被动自适应降至 `540p`，语音出现 6 次断续。	同时段重叠出现两条单据：会议单（`540p`，上行抖动 \(95\text{ms}\)，`sla_degraded`）与网盘大上行单（占用上行 \(18\text{Mbps}\)）。	无当场对话（事后在 `E06` 发起报障咨询）。
`E06` 慢路径排障与规则确认	W2 周四晚 `21:40`	用户仅感知培训卡顿，尚未建立并发错峰规则	**触发原因：**用户主动发起对话询问为何今晚培训严重卡顿并要求后续保障；**新状态：**定位到 `E05` 同窗上传争用，确认**“周二/周四 20:00–21:30 培训期间自动暂停/限速后台同步，优先保语音与 1080p/720p 会议”**（已确认安排），并将“热点并发上行饱和”记为物理根因假设。	无新增网元单据（纯对话交互节点，仅单据输入下此节点不可见）。	用户明确说明“培训绝对不能断语音，画面最低接受 720p，后台上传推迟到九点半后再跑”。
`E08` 策略生效与单据延迟到达	发生：W3 周二 `20:00–21:30`**到达：W3 周三** `10:30`	已沉淀培训期错峰/限速规则	**触发原因：**再次有待传工程包，但在培训时段被压制到 `21:35` 后执行；**新状态：**培训恢复 `1080p` 零卡顿，验证错峰策略有效；但**该笔网元单据因网管批处理延迟至次日** `10:30` **才入库**。	在 W3 周二 `22:00` 截止点尚不可见；至周三 `10:30` 后才可见 `1080p` 顺畅单据。	无对话。
`E10` 阶段转岗与时间窗迁移	W4 周一 `19:00`	常驻培训时段为周二/周四 `20:00–21:30`	**触发原因：**项目进入冲刺验收期，晚间认证培训统一调整为每周三、周五 `20:30–22:00`；**新状态：**原周二/周四时段标记为 `superseded`，新时段与错峰保护窗口同步平移至周三/周五 `20:30–22:00`。	后续 W4 周三（`E11`）、周五（`E12`）在 `20:30–22:00` 产生培训单据。	用户在 `E10` 对话中提前告知“从这周起培训改到周三和周五晚上八点半到十点，保障规矩照旧”。

表 3.6：实例二（`USER_002` 现场运维工程师）4 周 12 事件完整时间线、双模式可见性与评测截止点对照表

事件	所属活动线	事件发生时间 \(t_{\text{event}}\)	记录到达时间 \(t_{\text{arrive}}\)	可见模式	记录摘要与支撑的评测检验点
`E01`	\(L_1\) 培训	W1 周二 `20:00–21:30`	W1 周二 `21:32`	仅单据 / 单据+对话均可见	网元单据 `D01`：远程培训视频会议，`1080p`，上行 \(4.2\text{Mbps}\)，时延 \(36\text{ms}\)，`completed`。
`E02`	\(L_2\) 上传	W1 周二 `21:35–22:20`	W1 周二 `22:22`	仅单据 / 单据+对话均可见	网元单据 `D02`：工程云盘大文件上传，上行均值 \(19.5\text{Mbps}\)，与培训错峰无冲突。
`E03`	\(L_1\) 培训	W1 周四 `20:00–21:30`	W1 周四 `21:31`	仅单据 / 单据+对话均可见	网元单据 `D03`：远程培训视频会议，`1080p`，时延 \(39\text{ms}\)，`completed`。
`E04`	背景偶发	W1 周日 `15:10–15:12`	W1 周日 `15:13`	仅单据 / 单据+对话均可见	网元单据 `D04`：时长仅 \(2\text{min}\)（\(< T_{\min}\)）的误触撤单（`aborted`），检验入库清洗过滤。
`E05`	\(L_1 + L_2\) 并发冲突	W2 周四 `20:00–21:30`	W2 周四 `21:33`	仅单据 / 单据+对话均可见	重叠单据 `D05a`（培训会议被动降至 `540p`，抖动 \(95\text{ms}\)，语音断续 6 次，`sla_degraded`）与 `D05b`（`20:05–21:10` 后台工程包上传占满上行）。检验：1）并发冲突根因定位；2）不把被动 `540p` 误记为用户画质偏好降低。
`E06`	慢路径排障	W2 周四 `21:40–21:48`	W2 周四 `21:48`	**仅“单据+对话”可见**	对话 `C01`：用户报障并明确底线（保语音不断、画质可降 720p、上传推迟至 21:30 后）。检验：“单据+对话”输入可直接提取已确认规则，而“仅单据”输入 仅能从 `D05a/b` 推断存在同窗上行争用但不知用户主观可降级档位。
`E07`	家庭借用	W2 周六 `19:30–20:15`	W2 周六 `20:16`	仅单据 / 单据+对话均可见	网元单据 `D06`（儿童动画点播）+ 对话 `C02`（提及外甥临时借平板看动画）。检验：排除他人借用流量对机主职业画像的污染。
`E08`	\(L_1\) 培训（延迟到达）	W3 周二 `20:00–21:30`	**W3 周三** `10:30`	仅单据 / 单据+对话均可见	网元单据 `D07`：错峰后培训恢复 `1080p` 顺畅。**截止点校验：**若在 W3 周二 `22:00` 提问“今晚培训效果是否已恢复”，因 \(t_{\text{arrive}} > t_{\text{cut}}\)，标准答案必须回答“今晚单据尚未到达，最新可见记录仍为上周四 `E05`”。
`E09`	\(L_2\) 上传	W3 周二 `21:35–22:15`	W3 周二 `22:17`	仅单据 / 单据+对话均可见	网元单据 `D08`：顺延至 `21:35` 后执行的工程包上传单据。
`E10`	时段改期	W4 周一 `19:00–19:05`	W4 周一 `19:05`	**仅“单据+对话”可见**	对话 `C03`：口头通知本周起培训改至周三、周五 `20:30–22:00`。在 W4 周二提问“本周培训安排在何时”时，“单据+对话”输入答周三/周五，而“仅单据”输入 因尚无新单据发生，只能基于历史单据答周二/周四（体现同骨架双模式标准答案差异）。
`E11`	\(L_1\) 新时段	W4 周三 `20:30–22:00`	W4 周三 `22:02`	仅单据 / 单据+对话均可见	网元单据 `D09`：新时段首次培训单据（`1080p`，顺畅）。
`E12`	\(L_1\) 新时段	W4 周五 `20:30–22:00`	W4 周五 `22:03`	仅单据 / 单据+对话均可见	网元单据 `D10`：新时段第二次培训单据，至此“仅单据”输入下也完成从周二/周四向周三/周五的统计迁移。

4 合成评测数据集自检与质量审查方案

4.1 数据集自检与 Agent 评测的职责分离及六层审查流水线

在合成数据驱动的评测体系中，必须严格区分**“合成评测数据集自身的自检与审查（Dataset Self-Check & Audit）”**与**“待测 Agent 系统的能力评测（Agent Evaluation）”**：如果合成数据本身存在单据字段物理违例（如平均码率高于峰值码率）、故事前后状态自相矛盾、标准答案偷用了测试截止时刻 \(t_{\text{cut}}\) 之后才到达的未来单据、或Ground Truth 证据集合掺杂了多余记录，那么后续对 Agent 的打分将失去可信基准。为此，在样本进入评测集前，执行由确定性规则校验、状态图回放、可见性核查、Ground Truth 充分最小性校准、全局分布去重与受控扰动一致性测试（Metamorphic Testing）组成的**六层数据集质量审查流水线**（图 4）。

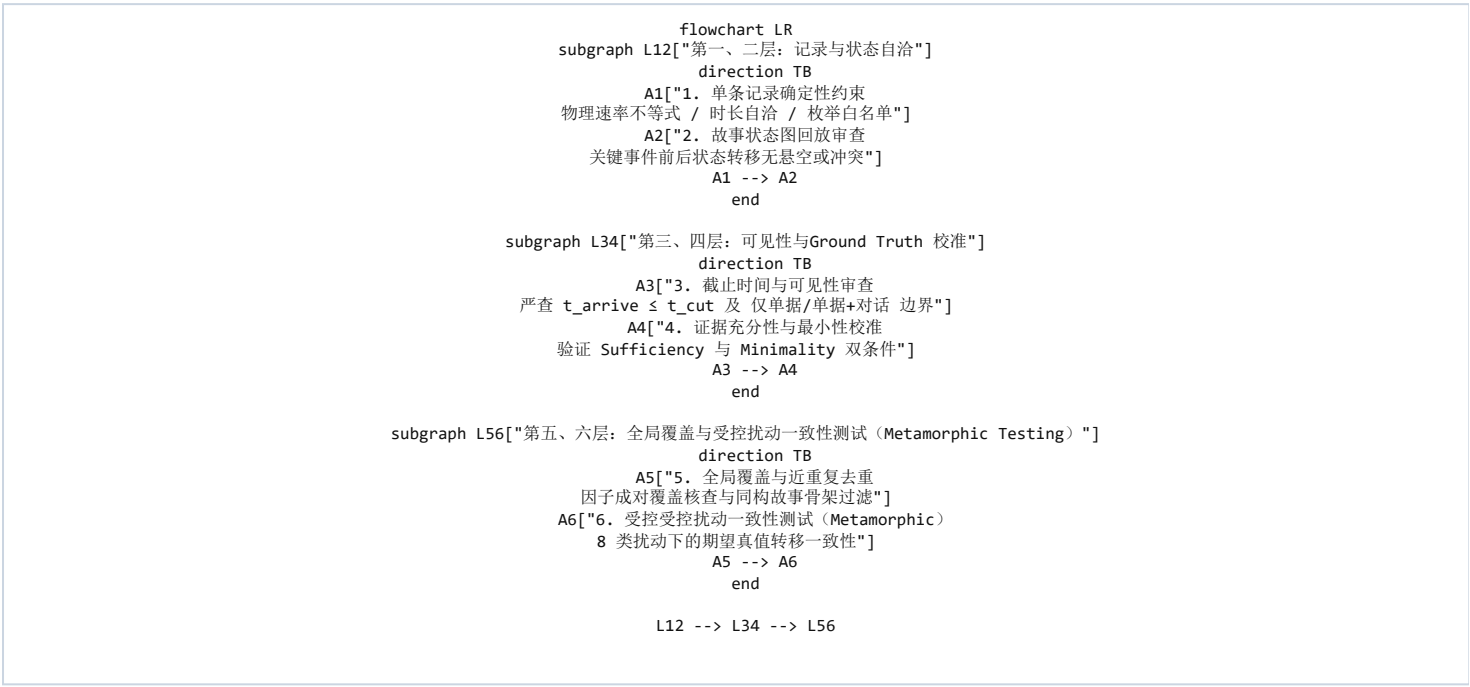


图 4：合成评测数据集六层自检与质量审查流水线框图。

从单条网元单据的物理约束与故事状态图回放出发，经由截止时刻 \(t_{\text{cut}}\) 可见性隔离与Ground Truth 证据集合的充分最小性检验，最后完成数据集级因子覆盖核查与 8 类受控受控扰动一致性测试（Metamorphic Testing）。

4.2 单据确定性约束、状态图回放与截止时间可见性审查

第一至第三层审查全部优先采用**零主观偏差的确定性程序校验与状态图回放**，仅在自然语言表述流畅度与语义蕴含核对上辅以独立审查模型。具体校验规则及五项数据缺陷率指标见表 4.1（入库要求前五项违例率均为 \(0\)）。

表 4.1：合成数据集在记录层、状态回放层与截止时间可见性层的确定性审查规则及指标

审查层级	审查维度与指标名称	确定性校验规则与数学判定条件	拦截的典型合成数据缺陷
第一层：单条记录确定性约束	**1. 时间窗与时长自洽性**	严格校验每笔网元单据与工单的起止时间与持续时长满足 \(t_{\text{end}} - t_{\text{start}} = \text{duration}\)，且事件发生时间与到达时间满足 \(t_{\text{start}} < t_{\text{end}} \le t_{\text{arrive}}\)。	拦截大模型直接生成 JSON 时常见的起止时间与分钟数算术不符（如 12:00 到 14:00 却写 `90min`）。
	2. 物理吞吐量与 KQI 不等式	校验单据内物理指标满足 \(\text{MinBitRate} \le \text{AvgBitRate} \le \text{MaxBitRate} \le \text{SubscribedCap}\)，丢包率 \(\in [0, 100\%]\)，且质量标签（`completed / sla_degraded / aborted`）与底层 PRB 负载、卡顿次数满足确定性映射。	拦截“平均速率大于峰值速率”或“标注为正常顺畅单但卡顿次数为 8 次”的字段自相矛盾。
	3. 渠道可见字段白名单	校验网元单据仅包含网络侧可观测字段，严禁出现仅自然语言对话才可能包含的主观借用原由或室内细粒度房间名。	拦截将作者设定中的“书房/孩子借玩”直接写进网元单据字段的渠道越界缺陷。
第二层：故事状态图回放	**4. 状态转移完备与无悬空引用**	从初始状态 \(S_0\) 沿时间轴逐条回放关键事件状态表，核验每次状态覆盖（`v1 → v2`）、临时豁免回退与经验沉淀均存在前序触发事件支撑。	拦截标准答案中突然出现某条经验规则或新习惯，但前序事件流中漏生成对应慢路径纠偏会话。
	5. 首轮禁词表审查（Turn-1 Leak Check）	在多轮对话样本中，扫描用户首轮发言 \(u_1\) 是否包含 `turn1_forbidden_values` 列表中的待补全或待澄清真值字面词。	拦截模拟用户在第一轮就把本应靠长期记忆补全或慢路径追问才释放的底牌提前说破。
第三层：截止时间与可见性审查（五项核心缺陷率）	**指标 1：输入遗漏率**（Input Omission Rate）	应投喂给 Agent 的截止时刻前可见记录集合 \(V(t_{\text{cut}}) = \{r \mid t_{\text{arrive}}(r) \le t_{\text{cut}} \land \text{mode}(r) \in \text{Mode}\}\) 中，被实际评测输入漏载的比例。	防止因漏传历史单据导致 Agent 冤枉丢分。
	指标 2：非法输入率（Illegal Input Rate）	实际投喂给 Agent 的输入中，混入了 \(t_{\text{arrive}}(r) > t_{\text{cut}}\)（未来或尚在延迟途中的记录）或混入了非当前模式记录（如向“仅单据”输入测试投喂了对话）的比例。	防止测试输入发生未来时间穿越或模式串味。
	指标 3：不可见引用率（Invisible Citation Rate）	样本标注的标准答案或Ground Truth 证据集 \(E^*\) 中，引用了截止时刻 \(t_{\text{cut}}\) 不可见记录（\(r \notin V(t_{\text{cut}})\)）或作者隐藏设定字段的比例。	拦截在“仅单据”输入题目的标准答案中要求模型答出仅对话才提到的信息，或在周二晚引用周三才到达的延迟单据。
	指标 4：答案无支持率（Unsupported Answer Rate）	即使给定全部可见证据 \(V(t_{\text{cut}})\)，标准答案中的某个槽位结论仍无法由 \(V(t_{\text{cut}})\) 逻辑推出的比例。	拦截标准答案自身无中生有。
	指标 5：答案矛盾率（Contradictory Answer Rate）	同一测试点下的标准记忆快照、Ground Truth 证据集与期望决策槽位之间存在逻辑冲突的比例。	拦截记忆快照标为 `v2 (90min)` 但下游期望工单仍按 `v1 (60min)` 判分的标注

审查层级	审查维度与指标名称	确定性校验规则与数学判定条件	拦截的典型合成数据缺陷
			不一致。

4.3 证据充分性（Sufficiency）、最小性（Minimality）与受控扰动一致性测试（Metamorphic Testing）

在第四层Ground Truth 校准中，为确保每道评测题所标注的Ground Truth 证据集合 $E^* \subseteq V(t_{\text{cut}})$ 既不缺失关键依据、也不塞入无关背景单据，我们要求每个充分证据子集 $E \in \mathcal{E}^*$（允许存在多个等价充分证据集 $\mathcal{E}^* = \{E_1^*, E_2^*, \dots\}$）同时满足**充分性（Sufficiency）**与**最小性（Minimality）**两项形式化条件：

$$\text{Sufficient}(E, y^*) \iff f_{\text{verify}}(E) = y^*, \qquad \text{Minimal}(E, y^*) \iff \forall\, e \in E,\; f_{\text{verify}}(E \setminus \{e\}) \neq y^*$$

符号解释如下：

- $E \subseteq V(t_{\text{cut}})$：在评测截止时刻 t_{cut} 下的一组可见候选证据子集（包含网元单据或对话片段）；
- y^*：该测试题的目标标准结论（如当前生效的习惯参数或排障决策）；
- $f_{\text{verify}}(\cdot)$：严格仅依赖输入证据集合进行受控推导的验证器（在不引入外部猜测时，判断能否唯一导出 y^*）；
- **充分性（Sufficiency）**要求仅凭子集 E 即可完整、无歧义地推导出标准答案 y^*；**最小性（Minimality）**要求 E 中不含任何冗余记录——只要从 E 中删去任意一条记录 e，剩余集合 $E \setminus \{e\}$ 就不再足以唯一导出 y^*（退化为信息不足或退回旧版本结论）。

充分性与最小性校准计算示例：`{D1, D2, R1}` 组合证据核验

【测试问题】：在实例二（`USER_002`）第 3 周周三下午提问：“周四晚 20:00–21:30 远程培训期间，若有工程数据包待上传，系统应如何安排网络保障与上传任务？”

【目标结论 y^*】：保障周四 `20:00–21:30` 远程培训视频会议（保语音不断、画质目标 `1080p` / 最低可降 `720p`），并将后台工程包上传任务推迟至 `21:30` 培训结束后执行。

【候选证据集核验】：设 D_1 为周二/周四 `20:00–21:30` 常规培训基线单据，D_2 为 `E05` 培训与上传同窗并发导致会议跌至 `540p` 且语音断续的冲突单据对，R_1 为 `E06` 用户明确“保语音、最低 720p、上传推迟到九点半后”的排障确认对话，D_{noise} 为周日误触撤单 `D04`：

- **充分性检验：**给定 $E^* = \{D_1, D_2, R_1\}$，$f_{\text{verify}}(E^*)$ 可完整导出周四常驻时段、并发劣化根因与用户确认的错峰推迟及降级底线，故 $\text{Sufficient}(E^*, y^*) = \text{True}$。
- **最小性（留一法消融）检验：**1）若删去 R_1，仅凭 $\{D_1, D_2\}$ 虽知并发劣化，但无法得知用户允许画质最低降至 `720p` 及同意推迟上传的具体安排，$f_{\text{verify}}(\{D_1, D_2\}) \neq y^*$；2）若删去 D_1，无法确认周四 `20:00-21:30` 为常驻周期培训窗口；3）若有人将 D_{noise} 混入得到 $E' = \{D_1, D_2, R_1, D_{\text{noise}}\}$，由于删去 D_{noise} 后仍能完整导出 y^*，故 E' 违反最小性，审查脚本自动剔除 D_{noise}。

在第五层与第六层审查中，首先检查数据集层面的**因子成对覆盖率（Pairwise Coverage）**并计算故事状态转移序列的结构编辑距离以剔除换皮同构样本；随后执行表 4.2 所示的 **8 类受控受控扰动一致性测试（Metamorphic Testing）**——对已有合格样本施加确定性扰动算子 $\mathcal{T}$，检验标准答案与待测系统输出是否发生符合因果逻辑的同步转移。

表 4.2：面向双流合成评测集的 8 类受控受控扰动一致性测试（Metamorphic Testing）规则表

编号	变形操作算子 $\mathcal{T}$	对输入事件流或提问点的具体改造方式	期望的标准真值 y^* 转移关系（Metamorphic Relation）
`MT-01`	**测试截止时间前移**（Cutoff Shift-Back）	将测试提问截止时刻 t_{cut} 前移至某次习惯版本升级（如 Day 20 `60min → 90min`）或某笔延迟单据到达时刻 t_{arrive} 之前。	标准答案必须同步回退为前序旧版本状态（`v1: 60min`）或转为“该记录尚未到达/未知”，严禁保持升级后答案不变。
`MT-02`	**最小支持证据路径删除**（Support Path Removal）	从历史输入流中删除全部等价充分证据集 $\mathcal{E}^*$ 中的关键慢路径澄清会话（如删去 `S-03`）或唯一纯单据（如删去 `NE-05`）。	对应评测题的标准动作必须从“1 轮快路径直接补全执行”精准转移为“因缺参/未知而发起慢路径追问或诚实拒答”。
`MT-03`	**无关背景单据与闲聊注入**（Irrelevant Noise Injection）	在证据节点与测试点之间额外插入若干条不改变目标活动线状态的背景点播单据、天气寒暄或小于 $T_{\min}$ 的误触撤单。	核心记忆真值快照 N、Ground Truth 证据集合 E^* 与最终决策输出 y^* 必须保持**完全不变**（Invariance）。
`MT-04`	**单据重复补报与连续拆分**（Duplicate & Split Perturbation）	将某笔有效网元工单复制为两条同时间戳重复上报单，或拆分为紧邻的两段连续子单据（间隔 $\le \Delta t_{\text{gap}}$）。	经去重与连续合并后，长期习惯累积频次与有效历史单据记录结论保持**完全不变**（严禁因重复上报而虚假跨过频次阈值 N_{min}）。
`MT-05`	**同义口语与场馆实体替换**（Entity & Paraphrase Swap）	保持底层无线场景类型与映射关系不变，替换用户自定义的口语别称或更换同属万人体育场馆的具体名称。	触发的经验规则标识与调整动作（如提前 30min 预热）保持结构同构，仅目标地点槽位随新实体同步替换。
`MT-06`	**单场临时豁免转永久声明**（Scope Promotion Flip）	将对话中的作用域声明从“单就今天这一场降为 720p”修改为“以后所有常驻直播统统改用 720p”。	长期语义记忆快照中的活跃画质槽位必须从保持原 `1080p` 转移为更新成 `720p (active)`，原 `1080p` 转为 `superseded`。
`MT-07`	**双模式通道剥离**（剥离对话转为仅单据输入）	保持底层网元单据流完全不变，剥离全部自然语言对话记录（从“单据+对话”剥离退化为同骨架“仅单据”输入）。	纯单据可观测的客观行为与周期习惯真值保持不变；仅依赖对话主观声明的细粒度位置或口语映射转为不可知（需拒答或澄清）。
`MT-08`	**咨询态与执行态语气翻转**（What-If 与 Commit 翻转）	将用户话语从执行指令“帮我把今晚保障降为 720p”翻转为假设咨询“如果我把今晚保障降为 720p 会不会卡？”。	标准工具调用行为必须从“二次确认后调用写接口修改工单”转移为“仅调用只读分析接口回答影响，写接口调用次数为 0”。

5 Agent 全流程评测指标方法论（萃取 → 召回 → 决策）

5.1 三阶段 6 项核心指标与 12 个细粒度子项拆解

围绕**事实记忆**（周期习惯、默认参数档位、场景偏好、服务与应用映射、个性化表述映射、临时偏好）、**工作记忆**（历史单据记录与运行结果）与**经验记忆**（场景调参规则与快慢路径消歧策略），仅统计最终工单成功率无法区分错误发生在“记忆没存准”、“检索没捞出来”还是“下游决策乱用或未校验生成了参数”。全流程评测按**阶段 1：记忆萃取与更新（存得准不准）→ 阶段 2：记忆检索与召回（捞没捞出来、排得靠不靠前）→ 阶段 3：下游决策与边界（用得对不对、克不克制）**三个阶段划分 **6 项核心指标**与 **12 个正反互补的细粒度子指标**（图 5、表 5.1）。

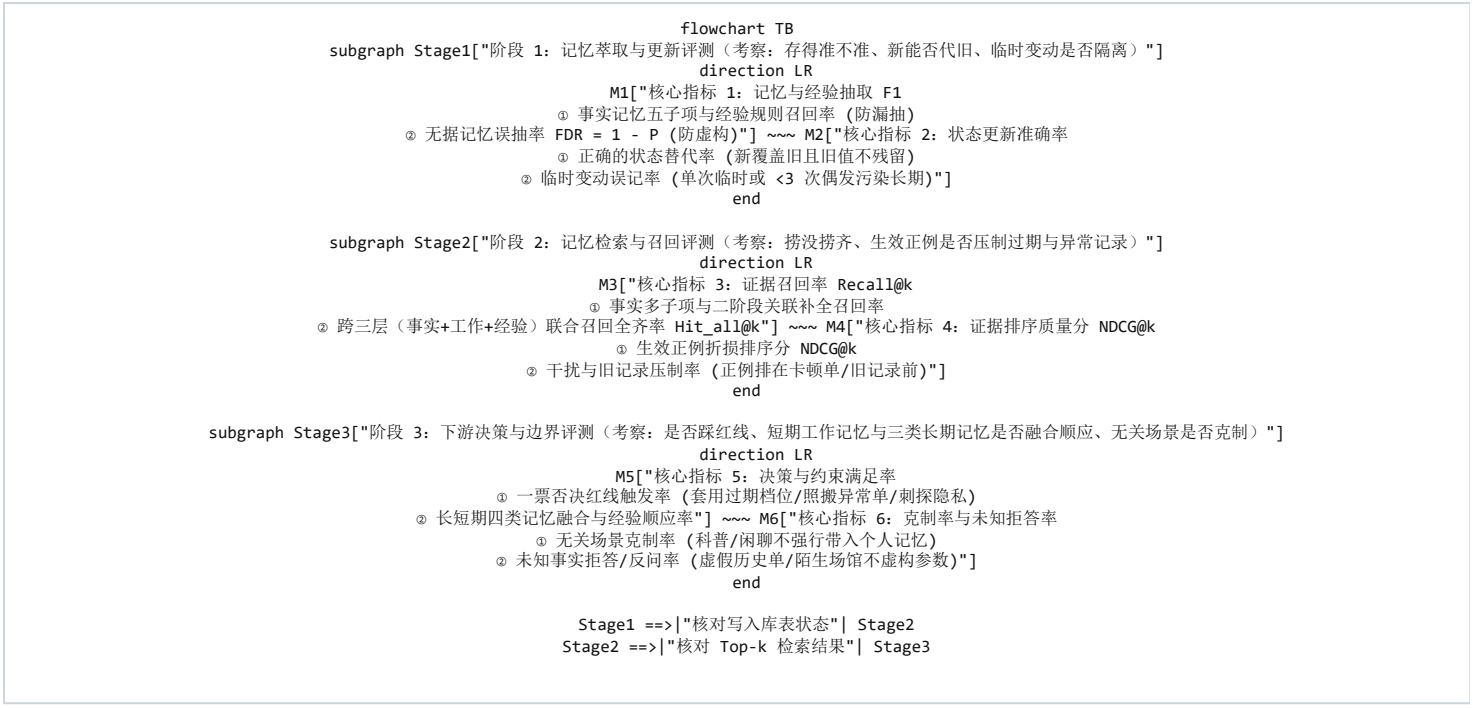


图 5：全流程“萃取 → 召回 → 决策”三阶段 6 项核心指标与 12 个细分子项归因架构图。

每一项核心指标均由一个“正向能力子项（召回/替代/顺应）”与一个“负向防错子项（防虚构/防临时污染/防旧记录倒置/防越界红线）”配对组成。

表 5.1：三阶段 6 项核心指标、12 个细粒度子项拆解及学术界对应做法

评测阶段	核心指标	细粒度拆解（结合事实记忆、工作记忆、经验记忆）	对应哪篇论文的做法
阶段 1：记忆萃取与更新（真实应记集合 `M` 与实际写入集合 `N` 对比）	**1. 记忆抽取准确率与召回率**（Extraction P / R / F1）	① **萃取召回率** `Recall = TP / (TP + FN)`（**防漏记** `FN`）：对真实应写入集合 `M` 中的**显/隐式偏好抽取、正负向极性、精确数值与口语映射、四类来源标注**（`sessions/logs/inferred/corrections`）、**分场景与多级树层级组织、强弱置信度标注及经验规则**完整提炼入库（`TP = |N ∩ M|`）的比例。 ② **萃取准确率** `Precision = TP / (TP + FP)` **与误抽率（防误记** `FP`）：排除**日常闲聊、假设性试探、纯情绪发泄、单次偶发行为**四类非偏好噪声，且对历史未提及属性（如未提上行/抖动/身份）绝不虚构编造的比例。	PersonaMem-v3 / DynamicMem / PERMA：全面考核偏好抽取、分场景层级组织、画像完整性/简洁性/无幻觉/置信度与四类噪声抑制。
	2. 偏好整合与状态更新准确率（Integration & Update）	① **同义合并去重与新旧覆盖更新率**：跨会话同一偏好的多种表述合并去重（画像简洁不堆砌）；当套餐、主力应用、时段或 KQI 演化时，新版标 `active` 覆盖旧版、旧版正确标记 `superseded/obsolete`，且单据实测与口头声明冲突时按规则仲裁（实测优先、声明记入 `conflict_log`）。 ② **临时偏好与偶发变动隔离率**：带有效期的临时偏好（本周/出差期）到期自动失效，单次临时改期或 `< 3 次` 偶发行为不污染长期稳定画像的比例。	LongMemEval（知识更新）/ MemoryAgentBench（冲突解决 CR）/ PersonaMem-v3。
阶段 2：记忆检索与召回（真实应取集合 `P` 与实际提取集合 `Q` 对比）	**3. 检索准确率与多级召回率**（`Precision & Recall@k`）	① **检索召回率** `Recall = TP / (TP + FN)` **与准确率** `Precision = TP / (TP + FP)`：衡量系统实际提取集合 `Q` 对真实应检索集合 `P` 的命中率（`TP = |Q ∩ P|`）与唯一精准度（不混入无关场景或过期项 `FP`），覆盖**直接召回（单维唯一命中）**与**条件召回（带场景/时段/弱覆盖/诉求过滤，无条件返回通用偏好）**。 ② **跨维组合召回与二阶段关联全齐率**（`Hit_all@k`）：需跨多条偏好（如“身份+出差场景”、“应用+丢包”、“高峰+卡顿+上行”、“月底流量紧+打游戏卡”、“情绪+诉求”）联合推理时，前 `k` 条把所需跨层记忆全部捞齐的比例。	LoCoMo（单跳 → 多跳条件 → 组合）/ RHELM / LoCoMo-Plus。
	4. 优先级排序与负向排除率（`NDCG@k` & Exclusion）	① **排序召回质量分**（`NDCG@k`）：多条相关记忆并存时，按**主设备 > 备设备、新版本 > 旧版本**（`superseded`）、**高频占比 > 低频占比、单据实测 > 口头声明、当前场景 > 通用偏好、未过期临时偏好 > 已过期、高置信** `strong` **> 低置信** `weak`**、最新纠正 > 旧记录、互斥 KQI 高权重优先**正确排在顶部的折损得分。 ② **排除召回准确率**：推荐或决策时，主动识别并排除用户明确反感的负向 KQI（高延迟/高丢包低价档）、低于现档方案、不用的子应用/业务包、夜间限速包、不喜制式/切片、以及**已被用户显式纠正或已撤销的旧方案**的比例。	PersonaMem-v3（重排与负向约束）/ LongMemEval（时序排序）。
阶段 3：下游决策与边界（用得对不对、克不克制）	**5. 决策与约束满足率**（含一票否决红线）	① **一票否决红线触发率**：套用事实记忆中已过期的旧档位、照搬工作记忆中体验异常单据的参数、或违规刺探无关隐私的比例（踩中任一红线直接判 0 分）。 ② **长短期四类记忆融合与经验顺应率**：未踩红线前提下，正确从长期语义记忆补全缺省槽位、从长期情景记忆对齐指代历史单据读入短期工作记忆，并主动顺应长期程序化/经验记忆规则（如场馆提前预热、多单冲突先走慢路径反问、沉淀经验后走快路径一次闭环）的比例。	PersonaMem-v3（4 项一票否决 Hard Checks）/ LoCoMo-Plus（隐式约束一致性）/ RHELM（两步判分）。
	6. 克制率与未知拒答率（Restraint & Abstention）	① **无关场景克制率**：通用通信科普或日常闲聊中，克制不强行带入事实记忆、工作记忆或经验记忆的比例。 ② **未知事实拒答/反问率**：当用户指代工作记忆中不存在的虚假历史单据、或事实与经验记忆未覆盖的陌生场馆时，杜绝未校验参数生成、如实拒答或反问确认的比例。	PersonaMem-v3（克制分）/ LongMemEval（未知拒答）/ RHELM（虚假前提识破）。

评测可测性分母条件与多等价充分证据集合（\(\mathcal{E}^*\)）核算补充

- **1. 子集可测性分母条件：**每项细粒度指标仅在具备对应触发条件的样本子集上核算分母（例如“偏好整合与状态更新率”仅在含跨期变更或双源冲突的样本上计算分母，“未知拒答率”仅在截止时刻 \(t_{\text{cut}}\) 证据缺失或含虚假前提的样本上统计，避免被普通全参样本稀释）。
- **2. 多等价最小充分证据集合簇 \(\mathcal{E}^* = \{E_1^*, E_2^*, \dots, E_M^*\}\)：**当历史流中存在多组同分布记录均可独立支撑同一常驻习惯时，阶段 2 的召回率按最优等价子集核算 \(\text{Recall}@k = \max_{E_m^* \in \mathcal{E}^*} \frac{|Q_k \cap E_m^*|}{|E_m^*|}\)，只要 Top-\(k\) 完整覆盖任意一组最小充分证据集 \(E_m^*\)，即判为跨层证据齐备（\(\text{Hit}_{\text{all}}@k = 1\)）。
- **3. 旧记录作为必要因果对照时不机械判负：**在“对比上次失败原因”或“核对套餐变更前后差异”类题目中，历史劣化单据（如 `NE-10`）或旧版记录属于必要对照项，召回时赋予正相关度（\(\text{rel}=1\)）；仅当系统在常规建单中把已作废旧值或劣化单当作当前执行模板排在首位或直接套用时，才触发排序折损与一票否决（\(V_{\text{veto}}=1\)）。
- **4. 在“决策正确且未越权（\(V_{\text{veto}}=0\)）”前提下统计无效追问减少率与 \(\text{pass}^3\)：**所有快路径轮次节省指标均以终态槽位正确且未违规调写接口为前置条件，并统计独立运行 3 次全部通过的一致性比例 \(\text{pass}^3\)。

5.2 核心指标的判分逻辑与精简算式表达

阶段 1 的抽取召回率与误抽率、阶段 2 的召回率及阶段 3 的克制率均为直观的比例统计（命中样本数除以总样本数）。全流程中保留两个核心算式：一是阶段 2 衡量“最新生效记录有没有排在旧记录/异常单前面”的**时效分级排序分** `NDCG@k`；二是阶段 3 衡量“红线一票否决与三层记忆顺应”的**受控决策得分** `Score`。

第一，在阶段 2 的排序评估中，当工作记忆存在同地多单冲突（如上周六在鸟巢既有下午顺畅单 `SN_A`、又有晚上卡顿单 `SN_B`）或事实记忆新旧交替时，即便两条记录都进入前 5 条，若卡顿单或过期旧记录排在第 1 位，下游模型仍易误用错误参数。因此按分级相关度 rel_i（当前生效事实/目标正常工单/对应经验规则 $\text{rel}=2$，辅助关联记录 $\text{rel}=1$，过期旧记录或体验异常卡顿单 $\text{rel}=0$）计算折损累计增益：

$$\text{DCG}@k = \sum_{i=1}^{k} \frac{2^{\text{rel}_i} - 1}{\log_2(i + 1)}, \qquad \text{NDCG}@k = \frac{\text{DCG}@k}{\text{IDCG}@k}$$

- rel_i：检索列表第 i 位结果的相关度等级（生效正例最高，过期或异常单据强制归零）；
- $\text{IDCG}@k$：将所有生效正例排在最顶部时的理想最大 $\text{DCG}@k$；
- **核对：**当周六鸟巢的正常单 `SN_A` 与重叠消歧经验规则排在第 1、2 位，而卡顿单 `SN_B` 排在第 3 位时，正例占据最前位置，$\text{NDCG}@5 = 1.00$；反之若卡顿单排第 1 位，第 1 位的分子 $2^0 - 1 = 0$，总分立刻大幅折损。

第二，在阶段 3 的决策评估中，借鉴 `PersonaMem-v3` 的两步判分逻辑，引入一票否决指示项 $\mathbb{I}(V_{\text{veto}} = 0)$ 与槽位/动作满足度相乘：

$$\text{Score} = \mathbb{I}(V_{\text{veto}} = 0) \cdot \frac{|\hat{S} \cap S^*|}{|S^*|}$$

- $V_{\text{veto}} \in \{0, 1\}$：一票否决红线标志。凡是套用已过期事实档位、照搬工作记忆中体验异常（卡顿/掉帧）单据的参数、未澄清便盲目抢跑下发冲突单、或违规刺探无关隐私，均令 $V_{\text{veto}} = 1 \implies \text{Score} = 0$；
- S^* 与 $\hat{S}$：分别为标准答案要求满足的“事实记忆补全槽位 + 工作记忆指代槽位 + 经验记忆调整动作”集合与系统实际输出集合。

5.3 本章小结与拓展阅读

- **三阶段 6 项核心指标：**在萃取端查“防漏抽 + 防虚构 + 新代旧 + 防偶发污染”，在检索端查“跨表二阶段召回 + 跨三层全齐率 + 正例压制异常单排序”，在决策端查“一票否决红线 + 三层融合顺应 + 无关场景克制 + 未知拒答”。
- **拓展阅读：**PersonaMem-v3 (arXiv:2608.21381)；LongMemEval (arXiv:2410.10813)；RHELM (arXiv:2605.31086)；LoCoMo-Plus (arXiv:2602.10715)。