TOTAL TOKENS /query

CATEGORY	TASK	GPT-5.5 Long Context	GPT-5.5 Textual Memory	GPT-5.5 Mem0 w/ RAG	GPT-5.5 Codex High	Gemini-3.5-Flash Long Context	Gemini-3.5-Flash Textual Memory	Opus-4.8 Claude Code High	Sonnet-4.6 Claude Code High
Total	Overall	417.2k	5.3k	3.6k	131.6k	416.5k	**3.3k**	246.7k	116.9k
Personalization	Personalized chatbot response	294.2k	3.6k	2.4k	85.7k	294.1k	**2.2k**	105.1k	64.8k
	Local recommendation after geo shift	138.8k	3.0k	2.3k	81.7k	138.7k	**1.8k**	134.7k	77.5k
	Personal-fact hallucination probe	307.0k	3.6k	2.3k	229.4k	307.0k	**2.1k**	306.2k	134.0k
	Understanding hidden persona	94.4k	1.9k	1.9k	65.2k	94.3k	**1.4k**	122.0k	81.6k
	Tracking preference changes	412.6k	4.6k	2.8k	74.4k	412.5k	**2.7k**	148.3k	95.9k
Recommendation	Proactive feed ranking	280.6k	3.9k	2.9k	207.1k	280.6k	**2.6k**	488.9k	205.4k
	@AI directive follow-up	316.2k	4.3k	3.0k	77.9k	316.2k	**2.8k**	57.3k	11.5k
	Hidden-persona recommendation	93.6k	2.2k	2.3k	150.7k	93.6k	**1.6k**	205.2k	120.0k
	Short-term preference lifecycle	364.5k	4.1k	**1.6k**	207.1k	364.5k	**4.0k**	488.9k	205.4k
Over-personalization	Generic chatbot restraint	348.3k	4.3k	2.7k	58.8k	348.3k	**2.6k**	63.8k	36.0k
	Sensitive-event chatbot restraint	213.6k	3.2k	2.4k	56.9k	213.6k	**2.1k**	36.8k	14.1k
	Do-not-personalize follow-up	412.4k	4.3k	**2.6k**	61.4k	412.5k	2.7k	63.8k	21.9k
	Repetitive feed personalization	4344.9k	46.7k	27.7k	930.9k	4337.3k	**27.1k**	1508.8k	1022.5k
	Repetitive chatbot personalization	3663.3k	39.4k	23.2k	671.8k	3622.5k	**22.6k**	803.2k	246.2k
Agentic	Community voice draft	284.7k	4.7k	3.7k	28.0k	284.6k	**3.4k**	11.7k	7.9k
	DM inbox digest	251.4k	3.7k	2.8k	40.8k	251.4k	**2.5k**	11.3k	8.2k
	Cross-app repost adaptation	249.7k	4.3k	3.5k	43.7k	249.7k	**3.1k**	14.2k	9.7k
	Personalized DM reply	272.0k	3.9k	2.9k	53.8k	272.0k	**2.6k**	110.8k	27.0k
	Vague memory refind	277.9k	3.2k	2.3k	138.2k	278.0k	**2.0k**	309.3k	187.0k
	Proactive daily catch-up	275.2k	5.9k	4.8k	35.9k	275.1k	**4.5k**	13.3k	11.0k
	Personalized trend alert	269.6k	3.7k	2.7k	39.8k	269.6k	**2.4k**	34.3k	17.1k
Agentic Proactiveness	Close-friend DM update	140.1k	2.8k	2.3k	100.6k	140.0k	**1.8k**	223.5k	69.8k
	Sensitive-event silence	387.5k	4.5k	2.7k	100.3k	387.5k	**2.6k**	196.3k	84.2k
	Friend-post update	111.9k	2.8k	2.3k	98.9k	111.9k	**1.8k**	210.3k	78.9k
	Trending-topic surfacing	118.5k	2.6k	2.3k	99.9k	118.5k	**1.7k**	187.6k	75.3k
	Mistake-prevention alert	440.5k	4.5k	**2.6k**	230.7k	440.7k	2.6k	464.1k	202.1k
	Idle-moment silence	57.6k	1.6k	1.8k	83.3k	57.5k	**1.2k**	199.7k	80.1k

low high *(the lower the better)*

bold = best in row